



**UNIVERSIDADE ESTADUAL PAULISTA
“JÚLIO DE MESQUITA FILHO”**

VITOR MARCHETTI CRAVEIRO

**TÉCNICAS DE VISUALIZAÇÃO DE DADOS E APLICAÇÃO DO MODELO DE
MISTURAS GAUSSIANAS NA DETECÇÃO DE FRAUDES EM CARTÕES DE CRÉDITO**

Presidente Prudente

2026

Vitor Marchetti Craveiro

Técnicas de Visualização de Dados e Aplicação do Modelo de Misturas Gaussianas na Detecção de Fraudes em Cartões de Crédito

Projeto para Trabalho de Conclusão de Curso
apresentado ao Curso de Graduação em Estatística da FCT/Unesp para aproveitamento na disciplina de Trabalho de Conclusão de Curso I.

Universidade Estadual Paulista “Júlio de Mesquita Filho”

Faculdade de Ciências e Tecnologia

Curso de Estatística

Orientador: Prof. Guilherme Aparecido Santos Aguiar

Presidente Prudente

2026

Agradecimentos

Primeiramente, agradeço a Jesus pela concessão da vida, da saúde e pela fortaleza espiritual, sabedoria e perseverança concedidas não apenas ao longo da graduação, mas em toda a minha vida.

Expresso minha profunda gratidão ao meu orientador, Prof. Guilherme Aparecido Santos Aguilar. Sua condução foi indispensável para a conclusão deste trabalho e mais do que isso, agradeço pelas portas abertas por meio dos programas de iniciação científica e de aluno mentor, experiências que transformaram minha trajetória acadêmica e profissional. À minha família, estendo meu mais sincero obrigado. O apoio emocional e financeiro contínuo, somado à compreensão e ao auxílio nos momentos de abdicção, foram os alicerces que tornaram possível a chegada a esta etapa. À minha noiva, agradeço imensamente pelo companheirismo e pelo suporte incondicional já que sua presença e incentivo constantes se fizeram sentir e foram determinantes, mesmo nos períodos em que a distância geográfica se fez presente. Presto também minha homenagem aos pesquisadores e à comunidade *open source* pois seus esforços e contribuições ao longo de gerações pavimentaram os caminhos da Estatística, do Aprendizado de Máquina e da Ciência de Dados, fornecendo a base teórica e prática que sustenta esta pesquisa.

Por fim, agradeço aos amigos, colegas de curso e demais docentes que, direta ou indiretamente, compartilharam desta jornada, colaborando para a minha formação acadêmica e pessoal.

Resumo

Com o aumento da geração de dados em vários locais da sociedade, a identificação de padrões anormais se tornou uma tarefa cada vez mais importante em áreas ligadas à segurança cibernética, transações financeiras e e-commerce. Nesse sentido, as técnicas de aprendizado de máquina, do inglês *machine learning* (ML) são comumente aplicadas para a detecção de anomalias e fraudes, principalmente no cenário em que os dados possuem alta complexidade, alta dimensionalidade e grande desbalanceamento entre observações normais e suspeitas.

Diante deste cenário, o presente trabalho tem o objetivo geral de aplicar técnicas de visualização e de aprendizagem de máquinas na detecção de anomalias associadas a possíveis fraudes em transações financeiras, tendo em especial a aplicação do modelo de Misturas Gaussianas, do inglês *Gaussian Mixture Model* (GMM) e na redução de dimensionalidade, com o uso da Análise de Componentes Principais, do inglês *Principal Component Analysis* (PCA), e também da Incorporação de vizinhos estocásticos distribuída pela distribuição t de student, do inglês *t-Distributed Stochastic Neighbor Embedding* (T-SNE).

A metodologia que foi proposta conta com etapas de pré-processamento da base de dados, têm tratamento e padronização das variáveis, também tem etapas de diminuição de dimensionalidade, ajuste do modelo GMM e ainda cálculo de responsabilidades estimadas e baseadas nas regiões de densidade probabilística. . O projeto propõe-se a trabalhar com a modelagem estatística, bem como a explorar representações em uma, duas e três dimensões, visando tornar a interpretação mais intuitiva e a avaliação visual, além de verificar a eficiência do modelo em cada uma delas.

Palavras-chave: Aprendizado de Máquina; Visualização de Dados; Detecção de fraudes; Gaussian Mixture Model; PCA; t-SNE.

Abstract

With the rise of data generation across various sectors of society, identifying anomalous patterns has become an increasingly vital task in fields like cybersecurity, financial transactions, and e-commerce. In this context, machine learning (ML) techniques are commonly applied to anomaly and fraud detection, especially in scenarios involving highly complex, high-dimensional data with a severe imbalance between normal and suspicious observations.

Given this scenario, the main objective of this study is to apply visualization and machine learning techniques to detect anomalies associated with potential fraud in financial transactions. Specifically, it focuses on the application of the Gaussian Mixture Model (GMM) alongside dimensionality reduction techniques, such as Principal Component Analysis (PCA) and t-Distributed Stochastic Neighbor Embedding (t-SNE).

The proposed methodology includes data preprocessing steps, such as variable treatment and standardization, as well as dimensionality reduction, GMM model fitting, and the calculation of estimated responsibilities based on probability density regions.

The project aims to work with statistical modeling while exploring one, two and three dimensional representations to make interpretation more intuitive for visual evaluation, ultimately verifying the model's efficiency in each of these dimensions.

Keywords: Machine Learning; Data Visualization; Fraud detection; Gaussian Mixture Model; PCA; t-SNE.

Lista de ilustrações

Lista de tabelas

Tabela 1 – Ambiente Python utilizado	39
Tabela 2 – Principais bibliotecas utilizadas	40
Tabela 3 – Resumo do processo inicial de ETL	42
Tabela 4 – Estrutura das variáveis da base de dados	43

Lista de abreviaturas e siglas

GMM	Gaussian Mixture Model
PCA	Principal Component Analysis
T-SNE	T-Distributed Stochastic Neighbor Embedding
KDE	Kernel density estimation
MCC	Matthews correlation coefficient
AUC-PR	Area under the precision recall curve
GSFS	Genealized sequential foward selection
AI	Artificial intelligence
ML	Machine learning
EM	Expectation-Maximization algorithm
MB	Megabyte
GB	Gigabyte
ODS	Objetivos De Desenvolvimento Sustentável
ONU	Organização Das Nações Unidas

Sumário

1	INTRODUÇÃO	11
1.1	Contextualização	11
1.1.1	Contextualização Global	11
1.2	Problema De Pesquisa	12
1.2.1	Problemas A Serem Contornados	12
1.3	Objetivo	13
1.3.1	Objetivos Gerais	13
1.3.2	Objetivos Específicos	13
1.3.2.1	Visualização Dos Dados E Estudo Sobre Principais Variáveis	13
1.3.2.2	Aplicação Do GMM Com Todas As Variáveis Disponíveis E Comparação Com Outros Modelos	14
1.4	Justificativa	15
1.4.1	Organização Do Trabalho	16
2	REFERENCIAL TEORICO	17
2.0.1	Sinópse	17
2.0.1.1	Resumo	17
2.1	Aprendizado De Máquina	17
2.1.1	Visão Geral	17
2.1.2	Aprendizado Supervisionado	18
2.1.3	Aprendizado Não Supervisionado	18
2.1.4	Abordagem Do Problema	18
2.2	Dados Desbalanceados	19
2.2.1	Definição E Consequências	19
2.3	Redução De Dimensionalidade	20
2.3.1	PCA	20
2.3.2	T-SNE	20
2.3.2.1	Formulação Matemática E Espaço De Origem	20
2.3.2.2	O Espaço De Destino E O Problema De Aglomeração	23
2.3.2.3	Otimização Via Divergência De Kullback-Leibler	24
2.3.2.4	Perplexidade	25
2.4	Modelos Utilizados	25
2.4.1	GMM	25
2.5	Seleção de Features	29
2.5.1	Motivação	29

2.5.2	Métricas Analíticas de Avaliação	30
2.5.2.1	AUC-PR	30
2.5.2.2	Coeficiente De Correlação De Matthews	31
2.5.2.3	Log Loss	32
2.5.3	Métricas Gráficas De Avaliação	33
2.5.3.1	Boxplot	33
2.5.3.2	Matriz De Confusão	33
2.5.3.3	Matriz De Correlação De Spearman	34
2.5.3.4	Visualização Das Responsabilidades Estimadas Pelo GMM	35
2.5.4	Seleção De Variáveis	35
2.5.4.1	Busca Exaustiva Combinatória Para Seleção De Variáveis	35
2.5.4.2	GSFS	36
3	METODOLOGIA	38
3.1	Caracterização da pesquisa	38
3.1.1	Natureza da pesquisa	38
3.1.2	Abordagem metodológica	38
3.2	Ferramentas e ambiente computacional	38
3.2.1	Importância	38
3.2.2	Ambiente de execução	39
3.2.3	Linguagem de programação e ambiente interativo	39
3.2.4	Bibliotecas utilizadas	39
3.2.5	Repositório do projeto	40
3.2.6	Ferramentas de escrita e documentação	40
3.3	Base de dados	40
3.3.1	Origem da base de dados	40
3.3.2	Descrição da base	41
3.3.3	Processo de Extração, Transformação e Carga dos Dados	41
3.3.4	Estrutura das variáveis	42
3.3.5	Padronização dos dados	43
3.4	Divisão da base de dados	44
3.4.1	Uso da base completa para análise exploratória e seleção visual de variáveis	44
3.4.2	Divisão para modelagem final por <i>holdout</i> estratificado	45
3.5	Seleção de variáveis	46
3.5.1	Objetivo	46
3.5.2	Critério de seleção	46
3.5.3	Construção do score de avaliação e ranqueamento	47
3.5.4	Aplicação da GSFS	48
3.5.5	Definição do Número de Variáveis Seleccionadas	50
3.6	Redução de Dimensionalidade	50

3.6.1	Aplicação do PCA	50
3.6.2	Aplicação do t-SNE	51
3.7	Aplicação do modelo GMM	52
3.7.1	Ajuste do modelo	53
3.7.2	Definição do número de componentes	53
3.7.3	Tipo de matriz de covariância	53
3.7.4	Inicializações e reprodutibilidade	54
3.7.5	Regularização da matriz de covariância	54
3.7.6	Definição do Limiar de Decisão	54
3.8	Modelos Comparativos	55
3.8.1	Ideia Central	55
3.9	Síntese do Fluxo Metodológico	56
3.9.1	Fluxo Metodológico	56
4	DESENVOLVIMENTO	57
5	CONCLUSAO	58
	REFERÊNCIAS	59

1 Introdução

1.1 Contextualização

1.1.1 Contextualização Global

O que se percebe é que com o crescimento das transações digitais da últimas décadas, em particular o crescimento acelerado do comércio eletrônico, também houve um aumento significativo na geração de dados por consumidores, empresas e instituições financeiras sendo que simultaneamente houve um aprimoramento na segurança digital, podemos assim ver os casos de fraudes em cartão de crédito, casos esses que se mostram como um problema importante para instituições financeiras, empresas de tecnologia, plataformas de e-commerce e consumidores que acabam por pagar por isso, pois geram prejuízos financeiros, perda de confiabilidade e necessidade constante de ampliação dos sistemas de monitoramento.

De acordo com dados do portal The Financial Brand (2024), as perdas globais de fraude no cartão foram acima de US\$ 36 bilhões de dólares e estima-se que perdas acumuladas devem rondar a casa dos 397,4 bilhões de dólares na próxima década.

Segundo este, esses números demonstram a dimensão econômica do problema e a necessidade de métodos cada vez mais eficazes para identificar comportamentos suspeitos em volumes de transações muito elevado

Conforme o estudo de Santos, Santos e Toma (2024), as fraudes com cartões de crédito no Brasil requerem uma análise profunda da sua realidade, dado que os dados do Mapa da Fraude da ClearSale indicam que em 2023, foram analisadas cerca de 277,4 milhões de transações, sendo que mais de 3 milhões foram tentativas de fraude, além disso, totalizam valores de perda que arredondam a ordem de R\$3,5 bilhões, essas métricas reafirmam a relevância do problema no Brasil, além da necessidade da utilização da automatização e melhora de estratégias para análise e identificação de operações fraudulentas.

A gravidade do problema e o aumento constante da quantidade de dados torna a aplicação das técnicas automatizadas para detecção de fraude não só desejável mas necessária, nessa situação o aprendizado de máquina surge como uma alternativa importante uma vez que pode ser utilizado para reconhecer padrões, estruturas e comportamentos atípicos a partir dos dados e em particular, os métodos não supervisionados são úteis quando se têm dados previamente rotulados em quantidade não suficiente ou quando inexiste ou ainda quando se verifica uma alteração nos padrões de fraude ao longo do tempo.

Uma vez que o aprendizado de máquina não supervisionado se destaca pela habilidade de conseguir identificar agrupamentos e anomalias em dados sem necessidade de que eles dependam da classe ser definidos antes, demonstra que é uma característica relevante para problemas de fraude já que a maioria das transações suspeitas não são conhecidas a priori e muitas vezes se alteram e se aprimoram ao decorrer do tempo. Entre os algoritmos a serem usados para essa finalidade estão o algoritmo K-Médias, do inglês K-Means, apresentado em MacQueen (1967) e o GMM que permite representar os dados por meio de agrupamentos probabilísticos, tais misturas em geral são um tema discutido por McLachlan e Peel (2000).

No entanto, as bases de dados com transações financeiras são, de um modo geral, complexas e multidimensionais, pois podem ter um elevado número de variáveis relacionadas aos valores, geolocalização, horário, perfil do utilizador, padrões de compra etc, essa alta dimensionalidade, por um lado, pode dificultar a visualização e interpretação dos dados analisados e, por outro lado, também pode afetar a performance computacional dos algoritmos, então afim de evitar esses males são aplicadas técnicas de redução de dimensionalidade, como a PCA formalizada por Hotelling (1933) e a T-SNE proposta por Maaten e Hinton (2008).

Nesse sentido, sugere-se a opção da utilização de técnicas de visualização de dados que associadas a modelos probabilísticos possam auxiliar na identificação de anomalias que possam ser relacionadas a fraudes financeiras, logo a proposta consiste em reduzir a dimensionalidade dos dados, visualizá-los graficamente e aplicar o modelo GMM, fazendo análises sobre a posteriori.

1.2 Problema De Pesquisa

1.2.1 Problemas A Serem Contornados

A detecção de fraudes é um problema complexo, pois os dados geralmente apresentam alto desbalanceamento entre as classes, grande quantidade de variáveis e padrões difíceis de serem identificados visualmente, além disso em muitos casos as observações fraudulentas representam uma pequena parcela do conjunto de dados, o que dificulta o treinamento e a avaliação dos modelos.

Dessa forma, este trabalho busca responder à seguinte questão: técnicas de redução de dimensionalidade combinadas com o modelo Gaussian Mixture Model podem auxiliar na identificação de anomalias e possíveis fraudes em conjuntos de dados?

1.3 Objetivo

1.3.1 Objetivos Gerais

O objetivo geral deste trabalho é aplicar técnicas de visualização de dados e aprendizado de máquina na detecção de fraudes em transações com cartões de crédito, utilizando o modelo GMM para identificação de anomalias e análise de padrões nos dados, para isso foram construídos scores de avaliação destinados à seleção de variáveis e combinações de variáveis mais relevantes para visualização e predição, além disso, busca-se analisar diferentes representações dos dados por meio de técnicas de redução de dimensionalidade, como PCA e T-SNE; Após todo o processo e escolha dos hiperparâmetros, tem-se como o objetivo a comparação com o modelo supervisionado de regressão logística, com o modelo não supervisionado de Estimativa de Densidade por Kernel, do inglês *Kernel Density Estimation* (KDE) e com a base de dados real rotulada.

1.3.2 Objetivos Específicos

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

1.3.2.1 Visualização Dos Dados E Estudo Sobre Principais Variáveis

- Pré-processar a base de dados mediante o tratamento, a normalização ou a padronização das variáveis do ponto.
- Mapear, de forma individual, todas as variáveis disponíveis que compõem a base de dados, a fim de avaliar como estas se comportam em função da variável rótulo.
- Mapear todas as combinações duas a duas das variáveis, de forma a analisar pares de variáveis que tenham maior capacidade de separação entre transações normais e fraudulentas.
- Mapear todas as combinações três a três das variáveis, de forma a analisar trios de variáveis que tenham melhor desempenho
- Analisar a variável rótulo, do inglês *label*, observando a distribuição das classes e o desbalanceamento entre transações normais e fraudulentas.
- Usar o GMM e, em seguida, as métricas Área Sob a Curva Precisão-Revocação, do inglês *Area Under the Precision-Recall Curve* (AUC-PR), Coeficiente de Correlação de Matthews, do inglês *Matthews Correlation Coefficient* (MCC) e Perda Logarítmica, do inglês *Log Loss*, para a construção de scores de avaliação sobre as variáveis e suas combinações.

- Preparar as visualizações de dados em uma, duas e três dimensões, a partir das 3 melhores combinações escolhidas pelos scores de avaliação aplicados às representações obtidas por PCA, tendo em vista obter padrões, agrupamentos e separações entre as transações normais e fraudulentas.
- Realizar uma comparação gráfica e analítica das representações obtidas, pelo PCA e pelo T-SNE, em relação a combinações de variáveis e regiões associadas a possíveis anomalias.
- Analisar os resultados finais

1.3.2.2 Aplicação Do GMM Com Todas As Variáveis Disponíveis E Comparação Com Outros Modelos

- Escolher as melhores combinações de variáveis através da seleção sequencial progressiva generalizada, do inglês *Generalized Sequential Forward Selection* (GSFS).
- Aplicar o GMM sobre subconjuntos de variáveis selecionadas para identificação de padrões, agrupamentos e possíveis anomalias associadas a fraudes em cartões de crédito.
- Testar diferentes configurações de hiperparâmetros do GMM, incluindo número de gaussianas, tipo de matriz de covariância e tipo de critério de inicialização, e diferentes pontos de corte para a classificação das observações, avaliando quais que se comportam melhor.
- Aplicar o modelo supervisionado de Regressão Logística ao subconjuntos das variáveis selecionadas utilizando como variável rótulo para avaliar a sua habilidade classificativa entre as transações normais e fraudulentas, além de avaliar diferentes cortes para a classificação das observações, ao fim concluir qual é a configuração que melhor se comporta.
- Realizar testes no modelo da Regressão Logística, mais especificamente em relação ao tipo de penalização e à função de ligação, o objetivo é melhorar o desempenho da Regressão Logística numa base desbalanceada.
- Aplicar o modelo KDE sobre subconjuntos de variáveis selecionados com o intuito de identificar observações com comportamentos anômalos , e posteriormente lhe avaliar pelos mesmos métodos dos outros modelos.
- Avaliar o desempenho dos modelos pelas métricas visuais: Matriz de Confusão, Matriz de Correlação de Spearman, gráfico que mostra os dados plotados e pela visualização das responsabilidades estimadas.

- Comparar os resultados proporcionados pelo GMM com um método supervisionado (Regressão Logística) e um não supervisionado (KDE), todos métodos probabilísticos, tendo como critério o desempenho quantitativo e a separação entre transações normais e fraudulentas.
- Analisar os resultados das previsões dos vários modelos e comparar com a base de dados.
- Verificar os resultados finais.

1.4 Justificativa

A fraude em cartões de crédito é um problema cada vez mais sério, com consequências econômicas e sociais profundas, por um lado, a digitalização dos meios de pagamento democratizou o acesso a serviços financeiros, por outro, expôs consumidores, empresas e bancos a uma onda crescente de golpes e fraudes.

Com isso, o uso combinado de métodos estatísticos, de aprendizado de máquina e técnicas de visualização de dados ingles *data visualization* se tornam uma estratégia indispensável para o mapeamento de comportamentos inadequados e robustecimentos da segurança do ecossistema financeiro.

Este trabalho se justifica, exatamente, pela necessidade de se desenvolver e testar metodologias adequadas e eficazes no rastreamento de anomalias em grandes volumes de dados financeiros, usando GMM para analisar o múltiplo ângulo das transações e também os transformando em base de dados visuais. Para enriquecer o debate, também se confronta o presente trabalho com métodos supervisionados e não supervisionados da questão, para entender qual ferramenta se adapta melhor à volatilidade do problema.

Essa pesquisa tece uma conexão direta com os Objetivos de Desenvolvimento Sustentável (ODS), da Organização das Nações Unidas (ONU), do inglês *united nations organization*, especialmente com a meta 8, 9 e 16 (Nações Unidas Brasil, 2025). No que diz respeito a ODS 8, que diz respeito ao crescimento económico inclusivo e ao trabalho digno, salvaguardar a integridade das transações digitais é um passo vital para a construção de uma economia digital resiliente.

A ODS 9 que se trata da inovação e a infraestrutura resiliente, da promoção da industrialização inclusiva e sustentável e do fomento a inovação, a aplicação de técnicas de análise dados, aprendizado de máquina e visualização computacional contribui para a modernização de sistemas financeiros e para o desenvolvimento tecnológico.

Por fim, mediante a sua implementação, o projeto converge para o ODS 16, que preconiza a transparência e a solidez institucional. Em suma, os estudos são justificados

pela modificação da estatística e do ML que se transformaram em vetores de inovação e responsabilidade social.

1.4.1 Organização Do Trabalho

O trabalho se divide em cinco capítulos articulados entre si para que haja linearidade e clareza no desenvolvimento da pesquisa.

O primeiro capítulo trata da comoção que deu ensejo à contextualização do tema, delimitação do problema de pesquisa, justificção e objetivos gerais e específicos.

A partir do momento seguinte inicia-se a fundamentação teórica já no Capítulo 2, nele acoplam-se as principais ideias que são necessárias para a sustentação do trabalho com as técnicas de redução de dimensionalidade, seleção de atributos, modelos probabilísticos, métricas de desempenho e as abordagens mais usadas na literatura para a detecção de anomalias e fraudes.

No Capítulo 3, a metodologia utilizada na pesquisa será abordada, além dos procedimentos práticos, este segmento corresponde à categorização da pesquisa, descrição do banco de dados e as etapas de preparação e pré-processamento, do mesmo modo, definem-se os critérios de seleção de variáveis, particionamento dos dados, implementação de técnicas de redução de dimensionalidade, configurações dos modelos de previsão e ajuste das métricas de avaliação.

O Capítulo 4 mostra como foi a pesquisa e os resultados. Na seção prática e analítica do artigo, demonstra-se a realização do delineamento metodológico, que compreende a utilização de uma análise exploratória dos dados dos experimentos computacionais, resultados quantitativos obtidos e interpretação das visualizações e dos cálculos das métricas.

Por fim, as considerações finais da pesquisa estão no capítulo 5, esse fechamento traz de volta os objetivos, resume o principal resultado e apresenta as contribuições da pesquisa tanto acadêmicas, quanto práticas, sugestões para o futuro foram abordadas, bem como limitações do estudo

2 Referencial Teorico

2.0.1 Sinópse

2.0.1.1 Resumo

Este capítulo apresenta as definições e conceitos presentes neste estudo, primeiramente são delimitados os conceitos básicos de aprendizado de máquina.

A seguir, destaca-se o problema das fraudes em cartão de crédito, o que acontece sob o desbalanceamento severo das bases de dados. Posteriormente são apresentados os métodos de redução de componentes, das quais foram utilizados o PCA e o T-SNE como proposta de mitigação da alta dimensionalidade e facilitar a visualização.

A elaborada escolha de variáveis, como o GFSF e a combinação de buscas exaustiva combinatória também são detalhadas por último, e antes se apresentam os modelos estatísticos que foram utilizados, com destaque para o GMM, seguido das métricas de avaliação que fundamentam a comparação dos resultados.

2.1 Aprendizado De Máquina

2.1.1 Visão Geral

A Inteligência Artificial, do inglês, *Artificial Intelligence* (AI) é um ramo da ciência que abrange o estudo e desenvolvimento de sistemas que são capazes de executar tarefas que se pressupõem envolver algum tipo de inteligência humana, como reconhecimento, decisão, classificação ou previsão. O aprendizado de máquina é uma ferramenta relevante para a detecção de fraudes em cartões de crédito, isso porque esse tipo de modelo permite analisar padrões de comportamento em conjuntos grandes e complexos, além do mais, fraudes costumam ser pequenas em comparação ao total de observações e mudam ao longo do tempo, dessa forma, modelos capazes de obter padrões não informados, são uma boa ferramenta de tomada decisão.

A aprendizagem máquina pode ser dividida essencialmente em aprendizagem supervisionada, aprendizagem não supervisionada e aprendizagem por reforço, dado que os modelos supervisionados se utilizam dos dados rotulados para aprender uma relação entre as variáveis explicativas e a resposta, ou seja, no caso dos dados já serem rotulados, o que significa que já sabemos a resposta que queremos, dessa forma os modelos conseguem aprender de forma eficiente, uma vez que já tem um padrão que serve como base para procurar as soluções, já no caso da aprendizagem não supervisionada, o objetivo é organizar

os dados e identificar estruturas, agrupamentos ou anomalias que não estão explicitamente rotulados, neste tipo de situação como os dados não têm rótulos e o algoritmo ou modelo deve aprender com os dados a estrutura dos dados, por fim e não trabalhada nesse projeto, a aprendizagem por reforço que envolve agentes que aprendem a tomar decisões a partir de uma interação com o ambiente.

2.1.2 Aprendizado Supervisionado

Segundo a IBM, o aprendizado supervisionado pode ser definido da seguinte forma:

Aprendizado supervisionado é uma técnica de aprendizado de máquina que usa conjuntos de dados rotulados para treinar modelos de inteligência artificial (IA) para identificar os padrões e as relações subjacentes. O objetivo do processo de aprendizado é criar um modelo capaz de prever saídas corretas em novos dados do mundo real.

(IBM, 2024b)

2.1.3 Aprendizado Não Supervisionado

Ainda segundo a IBM, o aprendizado não supervisionado pode ser definido da seguinte forma:

O aprendizado não supervisionado, também conhecido como aprendizado de máquina não supervisionado, utiliza algoritmos de aprendizado de máquina (ML) para analisar e agrupar conjuntos de dados sem rótulos. Esses algoritmos descobrem padrões ocultos ou agrupamentos de dados sem a necessidade de intervenção humana. A capacidade do aprendizado não supervisionado de identificar semelhanças e diferenças nas informações o torna uma solução ideal para análise exploratória de dados, estratégias de venda cruzada, segmentação de clientes e reconhecimento de imagens.

(IBM, 2024a)

2.1.4 Abordagem Do Problema

Neste trabalho, a abordagem executada é uma abordagem híbrida, isso porque o modelo GMM é primeiramente ajustado, sem o uso da variável rótulo em que as componentes gaussianas são estimadas sem que a variável rótulo entre em cena, contudo após o ajuste, a variável rótulo é utilizada para interpretação das componentes obtidas, assim são verificadas a proporção de transações fraudulentas e não fraudulenta em cada componente deduzindo assim qual gaussiana gera as fraudes e qual gera as transações normais, além disso, a variável rótulo também é utilizada na construção dos scores de avaliação e seleção de variáveis, assim, embora o primeiro ajuste sob a metodologia GMM

tenha um caráter não supervisionado, a posterior avaliação, interpretação e seleção de variáveis passam a incorporar informação supervisionada, dessa forma a metodologia proposta pode ser entendida como uma abordagem misturada de ajuste não supervisionado com avaliação supervisionada; essa estratégia é adequada ao problema de detecção, pois permite explorar a estrutura dos dados por meio de componentes probabilísticas e, ao mesmo tempo, utilizar a variável rótulo disponível para a avaliação da qualidade das representações, seleção de variáveis e interpretação dos agrupamentos encontrados.

2.2 Dados Desbalanceados

2.2.1 Definição E Consequências

Os dados desbalanceados caracterizam-se por apresentar uma disparidade significativa na quantidade de observações entre as classes de uma base de dados. Em problemas de classificação binária, essa condição implica que uma das categorias dispõe de um volume de registros substancialmente superior à outra. A classe com maior representatividade é denominada majoritária, ao passo que aquela com menor quantitativo de registros é chamada de minoritária.

Esse fenômeno é frequente em aplicações reais de aprendizado de máquina, manifestando-se sobretudo em cenários onde o evento de interesse é estocasticamente raro. No contexto da detecção de fraudes em cartões de crédito, o desbalanceamento assume um papel central: a esmagadora maioria das transações financeiras é legítima, enquanto as operações fraudulentas correspondem a uma fração ínfima do montante global.

Nesse sentido, Castro e Braga (2011) destacam que, em um problema com classes desbalanceadas, “a solução ótima (f^*), buscada pelas máquinas de aprendizado, naturalmente deve favorecer a classe majoritária”.

Para mitigar esse viés, a abordagem metodológica deste estudo preconiza o emprego de métricas de desempenho estritamente adequadas à avaliação da categoria minoritária. Dessa forma, utilizam-se os critérios da Área Sob a Curva de Precisão e Recall (AUC-PR), o Coeficiente de Correlação de Matthews (MCC) e a perda logística (Log Loss). Essas métricas viabilizam uma análise rigorosa e abrangente da capacidade preditiva dos modelos na identificação de fraudes, ponderando tanto os erros de classificação quanto a calibração das probabilidades estimadas.

Desse modo, o enfrentamento do desbalanceamento de dados transcende a escolha do algoritmo isolado, englobando a definição criteriosa das métricas e da estratégia de validação. Nesta pesquisa, tal peculiaridade é considerada tanto na formulação dos escores de avaliação das variáveis quanto na análise comparativa entre o Modelo de Mistura Gaussiana (GMM), a Regressão Logística e a Estimção de Densidade por Kernel (KDE).

2.3 Redução De Dimensionalidade

2.3.1 PCA

A Análise de Componentes Principais é um dos procedimentos de estatística multivariada que serve para transformar, um conjunto de variáveis que normalmente estão correlacionadas entre si, em um novo conjunto de variáveis que são não correlacionadas. A combinação linear das variáveis originais dá origem às novas variáveis e estas recebem o nome de componentes principais. Os componentes são organizados pela quantidade de variância que explicam, assim, os primeiros componentes são aqueles que concentram a maior parte da informação existente na base.

A PCA é importante, pois permite dimensionalmente reduzir o número de variáveis com perdas mínimas. Em bases com várias variáveis, pode ocorrer a repetição de parte da informação ou a sua distribuição em variáveis correlacionadas e nesses casos, permite-se de forma mais fácil representar os dados em um espaço de menor dimensão em comparação a representação original, além disso, como os componentes principais são ortogonais, a técnica também serve para reduzir os problemas da multicolinearidade.

Devido a essas razões, PCA é muitas vezes utilizado em diferentes estágios de pré-processamento, compactação, visualização e exploração de dados. Nesse trabalho foi utilizada com a finalidade de ter uma diminuição da dimensão da base de dados, exclusão de multicolinearidade, mas em paralelo, ter uma proteção aos dados sensíveis da Instituição e dos clientes.

2.3.2 T-SNE

Conforme explica SONI (2024), a ideia do método é mapear dados de alta dimensão para um espaço bem menor, geralmente em duas ou três dimensões, buscando preservar a estrutura local dos dados. Em outras palavras, o método procura fazer com que pontos próximos no espaço original continuem próximos na representação visual final.

Em bases financeiras complexas, é comum que existam relações não lineares entre as variáveis, nesses casos, o PCA pode não capturar toda a estrutura presente nos dados. O t-SNE atua justamente nesse ponto, pois ajuda a trazer à tona agrupamentos, ou em inglês *clusters*, que podem estar pouco evidentes no espaço original. Para isso, o algoritmo não trabalha apenas com distâncias de forma direta; ele transforma essas distâncias em medidas probabilísticas de similaridade.

2.3.2.1 Formulação Matemática E Espaço De Origem

Para formalizar o problema, considere inicialmente uma matriz contendo (n) transações vetorizadas. Essas observações são representadas pelos vetores:

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n. \quad (2.1)$$

Assume-se que cada uma dessas observações pertence a um espaço (p)-dimensional. Assim:

$$\mathbf{x}_i \in \mathbb{R}^p. \quad (2.2)$$

O objetivo do t-SNE é encontrar uma configuração correspondente em baixa dimensão, representada pelos vetores:

$$\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n. \quad (2.3)$$

Nesse novo espaço, a dimensão de destino é representada por (q) sendo menor que a dimensão original (p). Portanto:

$$\mathbf{y}_i \in \mathbb{R}^q, \quad q < p. \quad (2.4)$$

A construção do método começa pelo cálculo da distância euclidiana ao quadrado entre cada par de observações $\mathbf{x}_i$ e $\mathbf{x}_j$. Essa distância é dada por:

$$d_{ij}^2 = |\mathbf{x}_i - \mathbf{x}_j|^2. \quad (2.5)$$

Os resultados dessas distâncias cruzadas formam uma matriz global de distâncias ao quadrado, indicada por $\mathbf{D}^2$. Como a distância de um ponto para ele mesmo é igual a zero, tem-se $d_{ii}^2 = 0$. Além disso, como a distância euclidiana é simétrica, tem-se $d_{ij}^2 = d_{ji}^2$. Dessa maneira, a matriz pode ser escrita como:

$$\mathbf{D}^2 = \begin{bmatrix} 0 & d_{12}^2 & \cdots & d_{1n}^2 \\ d_{21}^2 & 0 & \cdots & d_{2n}^2 \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1}^2 & d_{n2}^2 & \cdots & 0 \end{bmatrix}. \quad (2.6)$$

O passo seguinte consiste em transformar essa matriz de distâncias em probabilidades. Para isso, o t-SNE considera uma distribuição gaussiana centralizada em cada ponto $\mathbf{x}_i$. A densidade multivariada resultante, considerando um ponto vizinho $\mathbf{x}_j$, é modelada por:

$$f(\mathbf{x}_j | \mathbf{x}_i, \sigma_i^2) = \frac{1}{(2\pi\sigma_i^2)^{p/2}} \exp\left(-\frac{|\mathbf{x}_i - \mathbf{x}_j|^2}{2\sigma_i^2}\right). \quad (2.7)$$

O parâmetro σ_i^2 representa a variância associada à vizinhança ao redor de $\mathbf{x}_i$. A partir dessa densidade, define-se $(s_{j|i})$, para $j \neq i$, como:

$$s_{j|i} = \frac{1}{(2\pi\sigma_i^2)^{p/2}} \exp\left(-\frac{|\mathbf{x}_i - \mathbf{x}_j|^2}{2\sigma_i^2}\right), \quad j \neq i. \quad (2.8)$$

Para transformar essa similaridade em uma probabilidade condicional, normaliza-se $(s_{j|i})$ pela soma das similaridades entre $\mathbf{x}_i$ e todos os demais pontos:

$$p_{j|i} = \frac{\frac{1}{(2\pi\sigma_i^2)^{p/2}} \exp\left(-\frac{|\mathbf{x}_i - \mathbf{x}_j|^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \frac{1}{(2\pi\sigma_i^2)^{p/2}} \exp\left(-\frac{|\mathbf{x}_i - \mathbf{x}_k|^2}{2\sigma_i^2}\right)}. \quad (2.9)$$

Utilizando a notação $d_{ij}^2 = |\mathbf{x}_i - \mathbf{x}_j|^2$, chega-se à forma compacta:

$$p_{j|i} = \frac{\exp\left(-\frac{d_{ij}^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{d_{ik}^2}{2\sigma_i^2}\right)}, \quad j \neq i. \quad (2.10)$$

Essa normalização garante que, para cada ponto $\mathbf{x}_i$, a soma das probabilidades condicionais em relação aos demais pontos seja igual a 1. Portanto:

$$\sum_{j \neq i} p_{j|i} = 1. \quad (2.11)$$

Note que cada ponto possui seu próprio parâmetro σ_i . Essa flexibilidade é importante, pois permite que o método adapte a largura da vizinhança de acordo com a densidade local dos dados. Apesar disso, as probabilidades condicionais ainda apresentam uma assimetria. Em geral:

$$p_{j|i} \neq p_{i|j}. \quad (2.12)$$

Essa assimetria ocorre porque cada ponto possui seu próprio desvio padrão local σ_i . Para contornar esse problema e construir uma matriz de probabilidades conjuntas simétrica, o T-SNE combina as probabilidades condicionais $p_{j|i}$ e $p_{i|j}$. A probabilidade conjunta p_{ij} é definida por:

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}, \quad i \neq j. \quad (2.13)$$

Definindo:

$$p_{ii} = 0. \quad (2.14)$$

O denominador $(2n)$ aparece porque:

$$\sum_{j \neq i} p_{j|i} = 1 \quad \Rightarrow \quad \sum_i \sum_{j \neq i} p_{j|i} = n. \quad (2.15)$$

De forma análoga:

$$\sum_{i \neq j} p_{i|j} = 1 \quad \Rightarrow \quad \sum_j \sum_{i \neq j} p_{i|j} = n. \quad (2.16)$$

Portanto, ao somar as duas contribuições, obtém-se o valor $(2n)$.

Assim, a matriz de probabilidades conjuntas $\mathbf{P}$ pode ser representada por:

$$\mathbf{P} = \begin{bmatrix} 0 & p_{12} & \cdots & p_{1n} \\ p_{21} & 0 & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{n1} & p_{n2} & \cdots & 0 \end{bmatrix}. \quad (2.17)$$

Como $p_{ij} = p_{ji}$, a matriz $\mathbf{P}$ é simétrica. Cada elemento p_{ij} representa a probabilidade conjunta de vizinhança entre as observações $\mathbf{x}_i$ e $\mathbf{x}_j$ no espaço original de alta dimensão.

2.3.2.2 O Espaço De Destino E O Problema De Aglomeração

Após a construção da matriz $\mathbf{P}$, o próximo passo é obter uma representação dos dados em um espaço de menor dimensão. Neste trabalho, em vez de inicializar os pontos de forma totalmente aleatória, considera-se a inicialização via PCA. Essa escolha fornece um ponto de partida linearmente mais organizado para as coordenadas $\mathbf{y}_i$.

No espaço reduzido, calcula-se uma nova matriz de probabilidades, chamada $\mathbf{Q}$. A diferença importante é que, nessa etapa, o t-SNE não utiliza uma distribuição normal para medir a proximidade entre os pontos $\mathbf{y}_i$ e $\mathbf{y}_j$, em vez disso utiliza uma distribuição T de Student com um grau de liberdade, equivalente à distribuição de Cauchy.

Essa escolha busca mitigar o chamado *crowding problem*, ou problema de aglomeração. Ao reduzir muitas dimensões para apenas duas ou três, pode faltar espaço no plano para representar adequadamente todas as relações de distância. Se fosse utilizada uma distribuição normal, pontos moderadamente distantes poderiam colapsar em uma região muito concentrada. Como a distribuição T possui caudas mais pesadas, ela permite maior separação entre agrupamentos no espaço reduzido.

A probabilidade condicional $q_{i|j}$ no espaço projetado é calculada por:

$$q_{i|j} = \frac{\left(1 + |\mathbf{y}_i - \mathbf{y}_j|^2\right)^{-1}}{\sum_{k \neq l} \left(1 + |\mathbf{y}_k - \mathbf{y}_l|^2\right)^{-1}}, \quad i \neq j, \quad q_{i|i} = 0. \quad (2.18)$$

A partir desse ponto, repete-se a ideia utilizada para $\mathbf{P}$, obtendo-se a matriz de probabilidades no espaço reduzido:

$$\mathbf{Q} = \begin{bmatrix} 0 & q_{12} & \cdots & q_{1n} \\ q_{21} & 0 & \cdots & q_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ q_{n1} & q_{n2} & \cdots & 0 \end{bmatrix}. \quad (2.19)$$

Como os valores q_{ij} são normalizados, a soma total das probabilidades conjuntas no espaço reduzido é igual a 1. Logo:

$$\sum_{i=1}^n \sum_{j \neq i} q_{ij} = 1 \quad (2.20)$$

2.3.2.3 Otimização Via Divergência De Kullback-Leibler

O objetivo final do t-SNE é aproximar a matriz de probabilidades do espaço reduzido, $\mathbf{Q}$, da matriz de probabilidades do espaço original, $\mathbf{P}$. Para medir essa diferença, utiliza-se a divergência de Kullback-Leibler como função de custo:

$$C = KL(\mathbf{P} \parallel \mathbf{Q}) = \sum_{i=1}^n \sum_{j \neq i} p_{ij} \log \left(\frac{p_{ij}}{q_{ij}} \right). \quad (2.21)$$

Minimizar C significa penalizar configurações nas quais pontos próximos no espaço original aparecem distantes no espaço reduzido. Dessa forma, o método procura preservar, principalmente, as relações locais entre as observações.

Essa otimização é resolvida de forma iterativa por meio do gradiente descendente. A atualização das posições dos pontos a cada iteração pode ser escrita como:

$$\mathbf{y}_i^{(t+1)} = \mathbf{y}_i^{(t)} \eta \frac{\partial C}{\partial \mathbf{y}_i}. \quad (2.22)$$

Nessa expressão, η representa a taxa de aprendizado, $\mathbf{y}_i^{(t)}$ é a posição do ponto i na iteração t , e $\frac{\partial C}{\partial \mathbf{y}_i}$ representa o gradiente da função custo em relação à posição do ponto $\mathbf{y}_i$.

O gradiente utilizado para direcionar essa movimentação é dado por:

$$\frac{\partial C}{\partial \mathbf{y}_i} = 4 \sum_j (p_{ij} - q_{ij})(\mathbf{y}_i - \mathbf{y}_j) \left(1 + |\mathbf{y}_i - \mathbf{y}_j|^2\right)^{-1}. \quad (2.23)$$

Ao longo das iterações, esse processo ajusta a posição dos pontos no espaço reduzido. Quando o algoritmo converge, obtém-se uma representação visual que busca preservar a estrutura local dos dados originais. No contexto de transações financeiras, essa representação pode auxiliar na identificação de padrões, agrupamentos e possíveis separações entre transações legítimas e fraudulentas.

2.3.2.4 Perplexidade

Um hiperparâmetro importântissimo do T-SNE é a perplexidade que está diretamente ligada ao σ_i^2 , em que pode ser interpretada como uma medida suave do número efetivo de vizinhos relevantes.

De acordo com Maaten e Hinton (2008), a *perplexity* é definida por:

$$\text{Perp}(P_i) = 2^{H(P_i)}, \quad (2.24)$$

em que $H(P_i)$ representa a entropia de Shannon de P_i , dada por

$$H(P_i) = - \sum_j p_{j|i} \log_2 p_{j|i}. \quad (2.25)$$

2.4 Modelos Utilizados

2.4.1 GMM

O GMM, ou modelo de Mistura de Gaussianas, assume, conforme descrito em Papa (2021), que as observações são independentes e identicamente distribuídas e que podem ter sido gerados por uma mistura de K distribuições gaussianas. Cada componente da mistura representa uma parte da estrutura dos dados, e sua contribuição é controlada por um peso. Assim, a densidade total não é descrita por uma única gaussiana, mas por uma combinação ponderada de várias delas.

De modo geral, uma mistura de densidades pode ser escrita como:

$$p(\mathbf{x}|\Theta) = \sum_{k=1}^K w_k p(\mathbf{x}|\theta_k). \quad (2.26)$$

Nessa expressão, (w_k) representa o peso do (k) -ésimo componente da mistura. Já $p(\mathbf{x}|\theta_k)$ indica a densidade de probabilidade associada a esse componente, enquanto Θ representa o conjunto de parâmetros do modelo. Em termos práticos, o peso w_k indica a participação relativa de cada componente na formação da densidade total.

Para que essa mistura possa ser interpretada como uma função densidade de probabilidade, os pesos devem satisfazer duas condições. Eles não podem ser negativos e precisam somar 1. Portanto:

$$w_k \geq 0, \quad \sum_{k=1}^K w_k = 1. \quad (2.27)$$

Essas restrições garantem que a densidade resultante continue válida do ponto de vista probabilístico. Ou seja, a função assume apenas valores não negativos e sua integral, considerando todo o espaço amostral, é igual a (1).

No caso específico do GMM, cada componente da mistura é representado por uma distribuição normal multivariada e com isso, a densidade do modelo pode ser escrita como:

$$p(\mathbf{x}|\Theta) = \sum_{k=1}^K w_k \times \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (2.28)$$

O conjunto de parâmetros do modelo reúne os pesos, os vetores de médias e as matrizes de covariância de cada componente. Assim:

$$\Theta = w_k, \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k. \quad (2.29)$$

Nessa notação, w_k é o peso da k -ésima componente, $\boldsymbol{\mu}_k$ representa seu vetor de médias e $\boldsymbol{\Sigma}_k$ representa sua matriz de covariância. Esses parâmetros definem não apenas a posição das componentes no espaço, mas também sua dispersão e orientação.

A distribuição normal multivariada associada a cada componente é dada por:

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = \frac{1}{(2\pi)^{d/2}|\boldsymbol{\Sigma}_k|^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1}(\mathbf{x} - \boldsymbol{\mu}_k) \right]. \quad (2.30)$$

Nessa equação, d indica a dimensão dos dados, $\boldsymbol{\mu}_k$ é o vetor de médias e $\boldsymbol{\Sigma}_k$ é a matriz de covariância da componente k . A presença da matriz de covariância é importante porque permite que cada componente represente diferentes formatos de dispersão no espaço dos dados.

A densidade da mistura descreve o comportamento global dos dados. No entanto ela não informa diretamente qual componente gaussiana foi responsável por gerar cada observação. Para representar essa informação não observada, introduz-se uma variável latente z_i , associada à observação $\mathbf{x}_i$. Essa variável indica a qual componente da mistura a observação está vinculada:

$$z_i \in 1, 2, \dots, K. \quad (2.31)$$

Na prática, observa-se apenas $\mathbf{x}_i$. O valor de z_i , por sua vez, permanece desconhecido. Por isso, z_i é chamada de variável latente. Ela existe na formulação do modelo, mas não aparece diretamente na base de dados.

Como não se sabe previamente qual componente gerou cada observação, o GMM estima essa relação de forma probabilística. Em vez de classificar cada ponto em apenas um grupo, o modelo calcula a probabilidade de esse ponto pertencer a cada componente da mistura. Essa probabilidade recebe o nome de responsabilidade. Formalmente:

$$\gamma_{ik} = P(z_i = k | \mathbf{x}_i, \Theta). \quad (2.32)$$

Aplicando o Teorema de Bayes, a responsabilidade da componente k pela observação $\mathbf{x}_i$ é dada por:

$$\gamma_{ik} = \frac{w_k \times \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K w_j \times \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}. \quad (2.33)$$

O valor de γ_{ik} indica o grau de associação da observação $\mathbf{x}_i$ com a componente k . Esse ponto diferencia o GMM de métodos de agrupamento rígido, como o k-médias porque Enquanto o k-médias força cada observação a pertencer a um único grupo, o GMM permite uma atribuição mais flexível, deste modo Uma mesma observação pode estar fortemente associada a uma componente e, ao mesmo tempo, manter alguma probabilidade de pertencer a outras.

Essa característica é relevante quando as fronteiras entre grupos não são bem definidas. Em dados financeiros, por exemplo, algumas transações podem apresentar comportamento intermediário. Nesses casos, uma classificação probabilística pode oferecer uma interpretação mais rica do que uma separação rígida.

As responsabilidades de todas as observações podem ser reunidas em uma matriz, chamada matriz de responsabilidades:

$$\mathbf{\Gamma} = \begin{bmatrix} \gamma_{11} & \gamma_{12} & \cdots & \gamma_{1K} \\ \gamma_{21} & \gamma_{22} & \cdots & \gamma_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_{N1} & \gamma_{N2} & \cdots & \gamma_{NK} \end{bmatrix}. \quad (2.34)$$

Cada linha dessa matriz corresponde a uma observação, enquanto cada coluna corresponde a uma componente gaussiana. Assim, o elemento γ_{ik} informa a responsabilidade da componente k sobre a observação i . Dessa forma, a matriz $\mathbf{\Gamma}$ resume o grau de pertencimento de cada observação a cada componente do modelo. Ela também funciona como uma ponte entre os dados observados e a estrutura latente da mistura.

A densidade marginal de uma observação $\mathbf{x}_i$ é obtida somando-se sobre todos os possíveis valores da variável latente z_i . Assim:

$$p(\mathbf{x}_i|\Theta) = \sum_1^K p(\mathbf{x}_i, z_i = k|\Theta). \quad (2.35)$$

Pela regra do produto $p(A, B) = p(A|B) \times P(B)$, a probabilidade pode ser decomposta em duas partes:

$$p(\mathbf{x}_i, z_i = k|\Theta) \rightarrow p(\mathbf{x}_i|z_i = k, \Theta) \times p(z_i = k|\Theta). \quad (2.36)$$

No GMM, a probabilidade de uma observação pertencer ao componente (k), antes de observar seus valores, é dada pelo peso da mistura:

$$p(z_i = k|\Theta) \rightarrow w_k. \quad (2.37)$$

Além disso, ao condicionar a observação ao componente (k), assume-se que ela segue a distribuição gaussiana associada a esse componente:

$$p(\mathbf{x}_i|z_i = k, \Theta) \rightarrow \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (2.38)$$

Substituindo essas relações, chega-se à densidade marginal da observação:

$$p(\mathbf{x}_i|\Theta) = \sum_{k=1}^K w_k \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (2.39)$$

Essa expressão mostra que cada observação é avaliada em relação a todas as componentes gaussianas, e não apenas em relação a uma delas. A densidade final é resultado da soma das contribuições de cada componente, ponderadas pelos pesos da mistura.

Considerando agora um conjunto de dados com (N) observações independentes e identicamente distribuídas, denotado por $\mathbf{X} = \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$, a função de verossimilhança é dada pelo produto das densidades marginais de todas as observações:

$$p(\mathbf{X}|\Theta) = \prod_{i=1}^N \sum_{k=1}^K w_k \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (2.40)$$

Aplicando o logaritmo nessa expressão, obtém-se a log-verossimilhança:

$$\mathcal{L}(\Theta) = \sum_{i=1}^N \log \left[\sum_{k=1}^K w_k \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right]. \quad (2.41)$$

Estimar os parâmetros do GMM significa encontrar os valores de w_k , μ_k e Σ_k que maximizam essa log-verossimilhança. A ideia é escolher os parâmetros que tornam os dados observados mais prováveis segundo o modelo. Apesar disso, a otimização não é direta. O obstáculo aparece porque o logaritmo envolve uma soma de componentes gaussianas, o que impede separar facilmente a contribuição individual de cada componente.

Para lidar com essa dificuldade, utiliza-se o algoritmo de Maximização da Expectativa, conhecido em inglês como *Expectation-Maximization* (EM). O algoritmo funciona de forma iterativa. Primeiro, na etapa E, calculam-se as responsabilidades, ou seja, as probabilidades de pertencimento de cada observação a cada componente. Depois, na etapa M, os parâmetros do modelo são atualizados usando essas responsabilidades como base.

Esse ciclo se repete até que a log-verossimilhança apresente convergência ou até que algum critério de parada seja satisfeito. Com isso, o EM permite ajustar o modelo de Mistura de Gaussianas mesmo quando existem variáveis latentes não observadas, como z_i . No contexto deste trabalho, essa formulação é importante porque permite analisar os dados de maneira probabilística, sem obrigar que cada observação pertença exclusivamente a um único padrão.

2.5 Seleção de Features

2.5.1 Motivação

A seleção de variáveis é uma etapa importante em problemas de aprendizado de máquina, análise estatística e visualização de dados, principalmente quando a base possui muitas variáveis explicativas. Em conjuntos multidimensionais, nem todas as variáveis ajudam da mesma forma na identificação de padrões, algumas carregam pouca informação, outras repetem sinais já presentes em variáveis correlacionadas e há aquelas que acabam colocando ruído no processo de modelagem.

No contexto deste trabalho, essa etapa ganha importância porque o objetivo não se limita à detecção de fraudes, mas também se busca construir visualizações em duas e três dimensões, por isso, escolher variáveis, ou combinações de variáveis, com maior capacidade de separação entre transações normais e fraudulentas pode facilitar a leitura gráfica dos dados e destacar regiões associadas a possíveis anomalias.

Além disso, uma boa seleção pode melhorar o desempenho computacional, reduzir a complexidade da análise e tornar os resultados mais interpretáveis. Em modelos como o GMM, variáveis pouco informativas ou muito correlacionadas podem dificultar a estimação das componentes gaussianas e prejudicar a identificação de estruturas relevantes nos dados.

Assim, antes da aplicação final dos modelos, este trabalho considera uma etapa de seleção e avaliação de variáveis, buscando subconjuntos que favoreçam tanto a modelagem

quanto a clareza das visualizações.

2.5.2 Métricas Analíticas de Avaliação

2.5.2.1 AUC-PR

Em detecção de fraudes, a classe positiva corresponde às transações fraudulentas, que são o principal interesse da análise. A classe negativa corresponde às transações não fraudulentas.

Quando o modelo classifica uma transação como fraude e ela realmente é fraude, tem-se um verdadeiro positivo (VP). Quando o modelo classifica uma transação como fraude, mas ela não é fraude, tem-se um falso positivo (FP). Já quando uma transação é fraude, mas o modelo a classifica como não fraude, tem-se um falso negativo (FN).

Com esses valores, calculam-se a precisão e a revocação. A precisão mede, entre todas as observações classificadas como positivas, quantas realmente pertencem à classe positiva. Neste trabalho, isso significa verificar, entre todas as transações apontadas como fraude, quantas de fato são fraudulentas:

$$Precisao = \frac{VP}{VP + FP}. \quad (2.42)$$

A revocação, também chamada de sensibilidade, mede, entre todas as observações realmente positivas, quantas foram corretamente identificadas. No caso da detecção de fraudes, indica quantas fraudes reais foram encontradas:

$$Revocacao = \frac{VP}{VP + FN}. \quad (2.43)$$

A precisão está ligada à qualidade dos alertas gerados pelo modelo, enquanto a revocação está associada à capacidade de encontrar as fraudes existentes. Uma precisão alta indica poucos alertas falsos; uma revocação alta indica poucas fraudes não detectadas.

Muitos modelos não produzem diretamente uma classe final, mas sim uma probabilidade associada à classe positiva. Esse é o caso de modelos probabilísticos, como o GMM. Para transformar essa probabilidade em classificação binária, define-se um limiar de decisão, também chamado de ponto de corte, ou *classification threshold*. Para um limiar t , a classe predita pode ser escrita como:

$$\hat{y}_i(t) = \begin{cases} 1, & \text{se } s_i \geq t, \\ 0, & \text{se } s_i < t. \end{cases} \quad (2.44)$$

em que s_i representa a probabilidade atribuído pelo modelo à observação i , e $\hat{y}_i(t)$ representa a classe predita a partir do limiar (t). O valor 1 indica fraude, enquanto 0 indica não fraude.

A escolha do limiar influencia diretamente a precisão e a revocação. Um limiar mais baixo tende a classificar mais observações como fraude, aumentando a chance de detectar fraudes reais, mas também elevando falsos positivos. Já um limiar mais alto gera menos alertas e pode aumentar a precisão, mas algumas fraudes podem passar despercebidas.

A curva Precisão-Revocação é construída variando esse limiar. Para cada valor de t , calcula-se um par formado pela revocação e pela precisão:

$$(Revocação(t), Precisão(t)). \quad (2.45)$$

Graficamente, a revocação fica no eixo horizontal e a precisão no eixo vertical. Cada ponto da curva mostra o desempenho do modelo para um determinado limiar.

A AUC-PR corresponde à área sob essa curva. Ela resume, em um único valor, a capacidade do modelo de manter bons níveis de precisão e revocação ao longo de diferentes limiares. Em geral, quanto maior a AUC-PR, melhor é o desempenho na identificação da classe positiva.

Como precisão e revocação variam entre 0 e 1, a AUC-PR também assume valores nesse intervalo:

$$0 \leq AUC-PR \leq 1. \quad (2.46)$$

Um valor igual a 1 representa o caso ideal, em que o modelo separa perfeitamente as classes. Valores menores indicam menor capacidade de separação entre a classe positiva e a negativa.

Na prática, a curva Precisão-Revocação é construída empiricamente a partir das probabilidades produzidas pelo modelo. O algoritmo avalia diferentes limiares, calcula precisão e revocação em cada ponto e forma a curva.

Neste trabalho, a AUC-PR é usada para avaliar variáveis e combinações de variáveis na etapa de seleção. Combinações com maiores valores de AUC-PR são consideradas mais adequadas, pois indicam maior capacidade de identificar transações fraudulentas mantendo bom equilíbrio entre precisão e revocação.

2.5.2.2 Coeficiente De Correlação De Matthews

O Coeficiente de Correlação de Matthews, conhecido como MCC, é uma métrica utilizada para avaliar modelos de classificação binária. Ele considera todos os elementos

da matriz de confusão: verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos. Por isso, costuma oferecer uma visão mais equilibrada do desempenho do modelo.

Em problemas de classificação, a matriz de confusão permite comparar as classes reais com as classes preditas. O MCC foi originalmente proposto por Matthews (1975) e pode ser interpretado como uma medida de correlação entre essas duas informações. Sua fórmula é:

$$MCC = \frac{VP \cdot VN - FP \cdot FN}{\sqrt{(VP + FP)(VP + FN)(VN + FP)(VN + FN)}}. \quad (2.47)$$

O valor do MCC varia entre -1 e 1 . Um valor igual a 1 indica classificação perfeita. Um valor igual a 0 indica ausência de correlação entre predições e classes reais, representando desempenho semelhante ao aleatório. Já um valor igual a -1 indica classificação completamente invertida.

Essa métrica é especialmente útil em bases desbalanceadas. Em problemas de fraude, a classe de interesse costuma ser muito menor do que a classe majoritária. O MCC considera simultaneamente o desempenho nas classes positiva e negativa, penalizando classificações desequilibradas e fornecendo uma medida mais robusta do desempenho global.

2.5.2.3 Log Loss

De acordo com Filho (2023), “Log loss (ou perda logarítmica) é uma métrica de avaliação de modelos de classificação em machine learning, tanto binários quanto multiclasse”.

Diferentemente de métricas baseadas apenas na classe final predita, a *Log Loss* considera o grau de confiança atribuído à classe correta. Modelos que atribuem alta probabilidade à classe correta recebem perdas menores. Quando o modelo atribui baixa probabilidade à classe correta, a penalização aumenta.

Em classificação probabilística, é comum que o modelo produza, para cada observação, uma probabilidade associada à classe positiva. Neste trabalho, considerando fraude como classe positiva, seja p_i a probabilidade estimada de que a observação i pertença à classe fraudulenta, e seja y_i a classe real, com $y_i = 1$ para fraude e $y_i = 0$ para não fraude. A *Log Loss* binária é definida por:

$$LogLoss = -\frac{1}{n} \sum_{i=1}^n [y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)], \quad (2.48)$$

em que n representa o número total de observações e $\ln$ representa o logaritmo natural.

Essa expressão pode ser entendida separando os dois casos possíveis. Quando a observação pertence à classe positiva, isto é, $y_i = 1$, a perda individual é:

$$LogLoss_i = -\ln(p_i). \quad (2.49)$$

Nesse caso, quanto maior a probabilidade atribuída à classe correta, menor será a perda. Se o modelo atribuir probabilidade muito baixa a uma fraude real, a penalização será alta.

Quando a observação pertence à classe negativa, isto é, $y_i = 0$, a perda individual é:

$$LogLoss_i = -\ln(1 - p_i). \quad (2.50)$$

Nesse caso, $1 - p_i$ representa a probabilidade estimada de a observação pertencer à classe não fraudulenta. Assim, a *Log Loss* avalia se o modelo atribuiu alta probabilidade à classe correta, seja ela positiva ou negativa.

A *Log Loss* assume valores não negativos, e valores menores indicam melhor desempenho. O mínimo é 0, obtido quando o modelo atribui probabilidade 1 para a classe correta em todas as observações. Por outro lado, quando o modelo atribui probabilidade próxima de zero à classe correta, a perda cresce rapidamente.

2.5.3 Métricas Gráficas De Avaliação

2.5.3.1 Boxplot

Segundo Tukey (1977), o *box-and-whisker plot*, mais usualmente chamado por boxplot, é uma representação gráfica baseada em medidas resumo de um conjunto de dados, especialmente os extremos, a mediana e os quartis. A caixa representa o intervalo entre os quartis, enquanto a mediana é indicada por uma linha interna, permitindo visualizar de forma sintética a posição, a dispersão e possíveis valores extremos da distribuição.

Usar essa ferramenta pode ser muito útil pois se avalia as diferenças entre as variáveis e a quantidade de outliers nelas, ajudando a ter uma primeira impressão da capacidade de separação.

2.5.3.2 Matriz De Confusão

A matriz de confusão é um recurso clássico para mapear o desempenho de modelos de classificação, cruzando as classes reais com as previsões feitas pelo algoritmo. Como

apontado por IBM (2024c), ela facilita o diagnóstico do modelo ao organizar os acertos e erros em uma estrutura prática e visualizável.

Em cenários de classificação binária onde lidamos com apenas duas respostas possíveis, costuma-se convencionar uma delas como a classe positiva e a outra como a negativa. A partir daí, a matriz estrutura quatro métricas fundamentais: os verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

Essa estrutura pode ser representada da seguinte forma:

	Predito Negativo	Predito Positivo
Real Negativo	VN	FP
Real Positivo	FN	VP

(2.51)

Nessa matriz, VP representa os verdadeiros positivos; VN , os verdadeiros negativos; FP , os falsos positivos; e FN , os falsos negativos.

2.5.3.3 Matriz De Correlação De Spearman

Para entender a força da associação entre pares de variáveis, recorremos à matriz de correlação de Spearman. Diferente do coeficiente de Pearson, que foca estritamente em relações lineares, o método de Spearman avalia relações monotônicas. Como o cálculo se baseia nos postos (ranques) dos valores observados, a métrica se torna bem mais robusta contra distribuições não normais e *outliers*.

O coeficiente de correlação de Spearman entre duas variáveis X e Y é denotado por ρ_s e varia no seguinte intervalo:

$$-1 \leq \rho_s \leq 1. \quad (2.52)$$

Resultados próximos de 1 indicam uma forte associação monotônica positiva (quando uma variável cresce, a outra tende a acompanhar). Valores perto de -1 apontam para uma forte associação negativa (o crescimento de uma implica no decréscimo da outra). Já os valores que orbitam o 0 sugerem que não há uma dependência monotônica expressiva entre elas.

No processo de seleção de atributos, essa matriz ajuda a detectar redundâncias. Quando duas variáveis apresentam uma alta correlação em módulo, significa que compartilham praticamente a mesma informação. Manter ambas pode inflar o modelo sem necessidade e prejudicar sua interpretabilidade. Em contrapartida, correlações baixas indicam que as variáveis trazem perspectivas diferentes e complementares para a análise.

Para um conjunto amplo de variáveis $\{X_1, X_2, \dots, X_p\}$, a matriz de correlação de Spearman é estruturada como:

$$\mathbf{R}_s = \begin{bmatrix} 1 & \rho_{12} & \cdots & \rho_{1p} \\ \rho_{21} & 1 & \cdots & \rho_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ \rho_{p1} & \rho_{p2} & \cdots & 1 \end{bmatrix}, \quad (2.53)$$

onde ρ_{ij} é o coeficiente de Spearman específico entre as variáveis X_i e X_j .

2.5.3.4 Visualização Das Responsabilidades Estimadas Pelo GMM

Plotar as responsabilidades estimadas por um modelo probabilístico é fundamental para abrirmos entendemos como o algoritmo se comporta ao longo do espaço amostral.

Matematicamente, a responsabilidade de uma componente k sobre uma observação $\mathbf{x}_i$ é dada por:

$$\gamma_{ik} = P(z_i = k \mid \mathbf{x}_i), \quad (2.54)$$

onde z_i é a componente latente da observação i , e γ_{ik} quantifica o nível de pertencimento dessa amostra $\mathbf{x}_i$ à respectiva componente k .

Se uma dessas componentes estiver diretamente ligada à nossa classe de interesse (como a classe positiva), podemos usar essas responsabilidades para desenhar um mapa probabilístico de pertencimento.

Esses gráficos deixam claro como o modelo espalha suas incertezas e certezas pelo espaço. Em cenários unidimensionais, conseguimos ilustrar esse comportamento com uma curva de responsabilidade. Na segunda dimensão, podemos gerar um mapa de calor (ou de contorno), colorindo o plano conforme a intensidade da probabilidade calculada. Já em dimensões mais altas, o caminho mais comum é utilizar gráficos em 3D ou a combinação das variáveis no 2d.

A grande vantagem dessas representações está na interpretação das fronteiras de decisão. Elas mostram nitidamente onde o classificador assume maior ou menor segurança, ajudando a validar a estrutura probabilística capturada pelo modelo, além de escancarar zonas de ambiguidade e o comportamento de dados atípicos.

2.5.4 Seleção De Variáveis

2.5.4.1 Busca Exaustiva Combinatória Para Seleção De Variáveis

A busca exaustiva combinatória é uma estratégia de seleção baseada em uma premissa simples, mas poderosa: testar absolutamente todas as combinações de variáveis dentro de um limite de tamanho predefinido para comparar seus desempenhos em vez de

avaliar os atributos isoladamente ou um a um, o método examina o cenário completo. Isso garante uma segurança muito maior para identificar quais subconjuntos de fato otimizam os resultados do modelo.

Diferente dos métodos sequenciais tradicionais nos quais os atributos entram ou saem do modelo de forma gradual, a busca exaustiva faz um pente fino direto em todas as combinações permitidas. Essa abordagem blindar a análise contra o risco de deixar um arranjo altamente promissor passar despercebido.

2.5.4.2 GSFS

A GSFS, *Generalized Sequential Forward Selection*, por sua vez, introduz uma abordagem sequencial e inteligente para mitigar essa barreira. A ideia central é expandir o subconjunto de variáveis de maneira gradual, mas sem a restrição de incluir apenas uma variável por vez. Em cada iteração, o método analisa blocos candidatos compostos por r variáveis que ainda estão disponíveis. Cada bloco é acoplado temporariamente ao conjunto já selecionado nas etapas anteriores e o desempenho dessa nova combinação é medido por uma função de avaliação. O grupo que injeta o maior ganho de eficiência é promovido definitivamente para o subconjunto selecionado.

Partindo do mesmo conjunto de variáveis originais:

$$\mathcal{X} = \{X_1, X_2, \dots, X_p\}. \quad (2.55)$$

O algoritmo inicia os trabalhos com um subconjunto de seleção completamente vazio:

$$\mathcal{S}_0 = \emptyset. \quad (2.56)$$

Ao alcançar a etapa t , o modelo toma como base o subconjunto acumulado até ali, denotado por $\mathcal{S}_t$. Com os atributos que restaram no banco de dados, estruturam-se os grupos candidatos $\mathcal{G}_r$, cada um contendo exatamente r variáveis:

$$\mathcal{G}_r \subseteq \mathcal{X} \setminus \mathcal{S}_t, \quad |\mathcal{G}_r| = r. \quad (2.57)$$

Para testar o potencial de cada grupo candidato, simula-se um novo subconjunto composto, unindo o que já havia sido selecionado ao novo bloco em teste:

$$\mathcal{C} = \mathcal{S}_t \cup \mathcal{G}_r. \quad (2.58)$$

Em seguida, o algoritmo calcula o *score* correspondente a esse arranjo combinado:

$$Score(\mathcal{S}_t \cup \mathcal{G}_r). \quad (2.59)$$

O bloco escolhido para integrar o modelo na etapa t é aquele que maximiza a função critério adotada:

$$\mathcal{G}_r^* = \arg \max_{\mathcal{G}_r \subseteq \mathcal{X} \setminus \mathcal{S}_t} Score(\mathcal{S}_t \cup \mathcal{G}_r). \quad (2.60)$$

Definido o melhor grupo, o subconjunto de variáveis selecionadas é oficialmente atualizado para a rodada seguinte:

$$\mathcal{S}_{t+1} = \mathcal{S}_t \cup \mathcal{G}_r^*. \quad (2.61)$$

Esse ciclo se repete de forma contínua até esbarrar em algum critério de parada preestabelecido, que pode ser o alcance do número máximo de atributos desejado, a estagnação do **score** (ausência de melhora significativa) ou o esgotamento do limite computacional configurado.

Dessa forma, a GSFS atua como um excelente meio-termo entre uma busca exaustiva global e uma seleção puramente individual. Ao avaliar grupos de variáveis de maneira síncrona em vez de recursos isolados, o método ganha velocidade sem abrir mão de capturar a sinergia entre os atributos.

Esse aspecto é vital, pois certas variáveis podem parecer pouco expressivas quando analisadas sozinhas, mas ganham enorme poder preditivo quando combinadas. Em cenários complexos como a detecção de fraudes, por exemplo, padrões suspeitos raramente se isolam em um único comportamento; eles costumam emergir justamente da interação oculta entre diferentes dados. A GSFS oferece essa resposta equilibrada, mesmo que segundo Pudil, Novovičová e Kittler (1993) isso ocorra à custa de um tempo de computação muito mais longo, especialmente com o aumento dos valores dos parâmetros, além de não haver uma maneira sem ser testando de determinar os valores corretos dos parâmetros a fim de obter o melhor subconjunto .

3 Metodologia

3.1 Caracterização da pesquisa

3.1.1 Natureza da pesquisa

Este trabalho se define como uma pesquisa aplicada. A escolha por essa vertente se justifica pelo próprio objetivo do estudo: explicar e usar o ferramental científico para intervir em um problema real e complexo: a segurança e a detecção de fraudes no sistema financeiro. Trata-se, portanto, de colocar a ciência de dados e a estatística a serviço de uma necessidade prática, sem abrir mão do rigor metodológico e das demonstrações matemáticas que validam cada passo da análise.

3.1.2 Abordagem metodológica

Para dar conta desse desafio, o caminho escolhido foi a abordagem quantitativa. Isso significa que a matéria-prima são os dados numéricos e as métricas estatísticas, processados por modelos computacionais. É importante salientar o quanto a lente matemática é fundamental, pois com ela, conseguimos medir e comparar matematicamente o desempenho de cada cenário, separando impressões subjetivas de resultados concretos de classificação.

Somado a isso, o trabalho ganha um contorno essencialmente experimental. A pesquisa não se limita a rodar um algoritmo padrão; ela desenha um ambiente de testes onde testa e confronta diferentes arranjos; Varia os hiperparâmetros dos modelos, muda as combinações de variáveis e experimenta técnicas distintas de projeção matemática para entender quais dessas estruturas conseguem capturar com maior precisão o comportamento sutil das fraudes em cartões de crédito.

3.2 Ferramentas e ambiente computacional

3.2.1 Importância

Detalhar o *hardware* e as versões dos pacotes utilizados é o que garante a reprodutibilidade do estudo, permitindo que outros pesquisadores rodem o mesmo código e entendam a relação entre o tempo de processamento e os recursos disponíveis.

3.2.2 Ambiente de execução

Todas as etapas de modelagem e processamento foram executadas localmente. Para isso, foi utilizado um *notebook* Acer Nitro AN515-55 equipado com o sistema operacional Windows 10. A máquina conta com uma arquitetura de 64 bits, processador Intel Core i5 da décima geração e cerca de 8 GB de memória RAM ativa, distribuídos em uma estrutura de 4 núcleos físicos e 8 núcleos lógicos de processamento.

3.2.3 Linguagem de programação e ambiente interativo

A espinha dorsal de todo o código do projeto foi escrita em Python (versão 3.13.3). A escolha pela linguagem foi natural, dado o seu protagonismo indiscutível no ecossistema de ciência de dados e aprendizado de máquina; Para que esses testes acontecessem de forma organizada e visual, os scripts foram desenvolvidos dentro do ambiente interativo do Jupyter Notebook, contando com o suporte dos motores *IPython* e *IPykernel*. Essa dinâmica de desenvolvimento em blocos foi crucial para que pudéssemos investigar os resultados parciais de cada algoritmo e documentar o raciocínio analítico passo a passo.

Tabela 1 – Ambiente Python utilizado

Item	Versão
Python	3.13.3
Notebook	7.4.2
IPython	9.2.0
IPykernel	6.29.5

Fonte: Elaborado pelo autor.

3.2.4 Bibliotecas utilizadas

Para colocar os dados em ordem e realizar as operações matemáticas mais densas, conta-se com a eficiência das bibliotecas *pandas* e *NumPy*.

A aplicação dos modelos e o cálculo das métricas de validação são feitas pela biblioteca *scikit-learn*, uma ferramenta de referência para o aprendizado de máquina. Para a criação de gráficos compreensíveis, recorreremos ao trio *matplotlib*, *seaborn* e *plotly*. Por fim, pacotes especializados como *SciPy* (para suporte estatístico), *tqdm* (para acompanhar o progresso dos loops mais demorados) e *openTSNE* (para a redução dimensional não linear) completaram a caixa de ferramentas computacionais.

Tabela 2 – Principais bibliotecas utilizadas

Biblioteca	Versão
<i>pandas</i>	2.2.3
<i>NumPy</i>	2.2.5
<i>scikit-learn</i>	1.7.2
<i>matplotlib</i>	3.10.5
<i>seaborn</i>	0.13.2
<i>plotly</i>	6.7.0
<i>SciPy</i>	1.15.3
<i>ipykernel</i>	6.29.5
<i>tqdm</i>	4.67.3
<i>openTSNE</i>	1.0.4

Fonte: Elaborado pelo autor.

3.2.5 Repositório do projeto

Para que este trabalho não seja apenas um documento estático, mas um ponto de partida para outros estudos, toda a estrutura de códigos, tabelas auxiliares e relatórios interativos foi organizada em um repositório digital público. Essa transparência garante que qualquer pessoa possa acessar, auditar e reproduzir fielmente os caminhos tomados nesta pesquisa.

O código-fonte completo e os artefatos do projeto estão disponíveis em:

<<https://github.com/Vitor-Craveiro-Unesp/Bachelor-s-Thesis-in-Statistics---2026>>

3.2.6 Ferramentas de escrita e documentação

A escrita e a formatação deste documento foram totalmente desenvolvidas em $\text{\LaTeX}$. Essa escolha técnica garantiu que toda a estrutura de fórmulas matemáticas, tabelas analíticas e citações bibliográficas seguisse um padrão visual rigoroso, limpo e profissional. Além disso, manter a documentação teórica alinhada com os testes interativos dos cadernos de código evitou qualquer distorção entre a teoria descrita e os resultados práticos obtidos.

3.3 Base de dados

3.3.1 Origem da base de dados

Os dados reais que dão vida a este trabalho vêm da plataforma Kaggle, extraídos do célebre repositório *Credit Card Fraud Detection* (Machine Learning Group - ULB, 2018).

Esse conjunto traz o histórico de transações financeiras feitas por cartões de crédito na Europa durante o mês de setembro de 2013. Trata-se de um retrato de dois dias de operações, que carrega o desafio do mundo real: o registro misto de compras legítimas e fraudes confirmadas. Por ser uma base de acesso público e amplamente consagrada pela comunidade científica, ela funciona como um excelente *benchmark*, permitindo que os resultados conversem diretamente com a literatura internacional sobre o tema.

3.3.2 Descrição da base

A estrutura dos dados funciona como uma grande planilha onde cada linha representa uma transação comercial isolada e as colunas revelam os detalhes técnicos daquela operação. Ao todo, lidamos com um universo de 284.807 registros. O grande desafio analítico aqui é o desbalanceamento desse cenário: desse montante massivo de dados, apenas 492 são transações fraudulentas confirmadas.

O vetor de características que descreve cada transação é composto pelas colunas originais *Time*, *Amount*, a variável resposta *Class*, além de 28 atributos numéricos identificados de *V1* a *V28*.

A variável *Class* funciona como a variável alvo do inglês, *target*, assumindo o valor 0 quando a transação é perfeitamente legítima e 1 quando é uma fraude. Um detalhe importante sobre as colunas de *V1* a *V28* é que elas não revelam as informações comerciais puras, como nome do estabelecimento ou dados do cliente; por questões de segurança e privacidade da empresa e de seus usuários, esses dados passaram por uma transformação matemática via (PCA) antes de se tornarem públicos. Fechando o conjunto, a variável *Time* mede o tempo em segundos decorrido entre a transação atual e o primeiro registro do histórico, e a *Amount* indica o valor monetário movimentado na transação.

3.3.3 Processo de Extração, Transformação e Carga dos Dados

Antes de submeter os dados aos algoritmos de seleção de variáveis, redução de dimensionalidade e modelagem, foi necessário estruturar a esteira de Extração, Transformação e Carga, amplamente conhecida pela sigla ETL Extract, Transform and Load. O objetivo central dessa engrenagem é organizar, sanear e preparar o banco de dados bruto, deixando-o no formato ideal para as análises estatísticas e o treinamento dos classificadores.

A etapa de extração consistiu no resgate da base de dados em formato CSV, disponível publicamente na plataforma Kaggle. Após o *download*, o arquivo original foi importado para o ambiente Python, permitindo o mapeamento inicial de todas as observações e variáveis disponíveis.

Na fase de transformação, foram conduzidas as primeiras auditorias na estrutura dos dados, checando as dimensões da base, a tipagem das variáveis, a existência de valores

ausentes, a contagem de registros únicos e a distribuição da variável resposta. Para tornar a interpretação dos resultados mais intuitiva, algumas colunas estratégicas foram renomeadas: a variável *Time* passou a se chamar *tempo_desde_a_primeira_transacao*; *Amount* foi traduzida como *valor_de_transacao*; e a variável alvo *Class* foi convertida em *status_fraude*.

Ainda nessa etapa de higienização, removeu-se o excedente de linhas duplicadas, preservando apenas uma ocorrência única de cada registro, além de descartar linhas com eventuais dados faltantes. Eliminar essas inconsistências é um passo crítico na modelagem, pois evita distorções matemáticas nas análises descritivas, atenua redundâncias na base e assegura que os algoritmos operem apenas com dados completos e íntegros.

Na sequência, realizou-se a separação clássica entre a matriz de variáveis explicativas e o a variável que é um vetor de respostas. Os atributos foram reservados para alimentar as etapas subsequentes de seleção, projeção e modelagem, ao passo que o vetor *status_fraude* foi guardado para atuar como o gabarito de avaliação do desempenho dos modelos.

Finalmente, a etapa de carga organizou os dados já tratados em estruturas de dados otimizadas para processamento em memória, como matrizes estruturadas e vetores de rótulos. Concluído o tratamento, essa nova base consolidada foi exportada para um novo arquivo intitulado *creditcard.csv*, que serviu de matéria-prima para o restante do estudo.

O processo de ETL cumpriu, assim, o seu papel fundamental: garantir a consistência, a organização e o alinhamento dos dados para as fases analíticas do projeto, minimizando ruídos e blindando a reprodutibilidade de todo o fluxo metodológico.

Tabela 3 – Resumo do processo inicial de ETL

Etapa	Quantidade antes	Quantidade depois
Colunas da base	31 colunas	31 colunas
Remoção de duplicatas	284.807 linhas	283.726 linhas
Remoção de dados faltantes	283.726 linhas	283.726 linhas
Base final tratada	284.807 linhas	283.726 linhas

Fonte: Elaborado pelo autor.

3.3.4 Estrutura das variáveis

Após a consolidação da base no ambiente Python, realizou-se um mapeamento detalhado da arquitetura das variáveis, identificando a tipagem de dados alocada para cada coluna. Essa verificação é um pré-requisito indispensável para entender como os recursos são interpretados computacionalmente e assegurar que as variáveis numéricas e categóricas estejam nos formatos exigidos pelas rotinas de pré-processamento e modelagem.

Tabela 4 – Estrutura das variáveis da base de dados

Variável	Tipo	Não nulos	Nulos	% nulos	Valores únicos	Memória (MB)
V1 a V28	float64	283.726	0	0,0%	275.663	2,1647
tempo_desde_a_primeira_transacao	float64	283.726	0	0,0%	124.592	2,1729
valor_de_transacao	float64	283.726	0	0,0%	32.767	2,1647
status_fraude	int64	283.726	0	0,0%	2	2,1647

Fonte: Elaborado pelo autor.

A métrica **Tipo** aponta a classe primitiva reconhecida pelo Python, o formato **float64** denota variáveis numéricas contínuas armazenadas com alta precisão de casas decimais, ao passo que o **int64** indica variáveis do tipo inteiro, com isso, constata-se que todos os atributos preditivos entraram no sistema como valores contínuos, enquanto o rótulo *status_fraude* foi assimilado como um número inteiro, condizente com sua natureza discreta que assume apenas as respostas 0 ou 1.

As colunas **Não nulos** e **Nulos** confirmam a completude do banco de dados pós-higienização. Como todas as variáveis exibem rigorosamente 283.726 registros válidos e nenhuma lacuna vazia, confirma-se o sucesso do descarte de dados omissos na fase de ETL.

A coluna **Valores únicos** reflete a grande quantidade de valores distintos observada de V1 a V28 que ratifica seu caráter contínuo. Em contrapartida, a variável *status_fraude* condensa apenas dois valores únicos, o que corrobora matematicamente a estrutura de uma classificação binária pura, garantindo que o rótulo não carregue ruídos ou classificações espúrias.

Por fim, o campo **Memória (MB)** rastreia a pegada de armazenamento físico em megabytes que cada variável consome no Python. Esse monitoramento é essencial para antecipar o estresse computacional e otimizar o consumo de *hardware*, principalmente nas rotinas que realizam buscas combinatórias exaustivas ou iterações pesadas em matrizes de alta dimensão.

3.3.5 Padronização dos dados

Antes de aplicar os modelos estatísticos e as técnicas de projeção espacial, as variáveis preditivas precisam ser submetidas a um processo de padronização, trazendo todas para uma mesma escala de grandeza, essa etapa é mandatória porque a grande maioria dos algoritmos de aprendizado de máquina e modelagem estatística é altamente sensível à escala dos dados de entrada. Atributos com ordens de magnitude muito discrepantes tendem a enviesar os cálculos que envolvem distâncias, covariâncias, densidades ou variâncias, conferindo um peso artificial e desproporcional a certas variáveis e prejudicando a estabilidade do modelo.

Neste trabalho, a harmonização das escalas utilizou o módulo **StandardScaler** da

biblioteca *scikit-learn*. Segundo as especificações técnicas do pacote, essa rotina opera centrando a média das variáveis em zero e escalonando os dados de forma a obter uma variância unitária (Scikit-learn developers, 2026b).

A transformação é executada de forma independente em cada coluna preditiva. Esse cuidado preserva as distribuições relativas originais de cada recurso, mas neutraliza os abismos de escala entre variáveis distintas, um passo vital para o bom funcionamento do PCA, t-SNE e do Modelo de Mistura Gaussiana (GMM).

Para garantir o rigor metodológico e blindar contra o vazamento de informações do inglês *data leakage*, os parâmetros de padronização são calibrados estritamente com os dados destinados ao treinamento. As estatísticas de média e desvio padrão resultantes desse primeiro ajuste são salvas e aplicadas de forma passiva para transformar os dados de validação e teste. Esse protocolo segue rigidamente o fluxo operacional do **StandardScaler**, que mapeia as propriedades dos dados por meio do método **fit** e estende essa mesma régua matemática aos demais subconjuntos utilizando o método **transform** (Scikit-learn developers, 2026a).

A padronização consolida-se, portanto, como uma etapa de infraestrutura analítica indispensável, assegurando a comparabilidade justa entre os recursos e estabilizando o comportamento dos estimadores que virão adiante.

3.4 Divisão da base de dados

O ciclo de vida dos dados foi planejado e segmentado para atender aos requisitos específicos de cada etapa da pesquisa. Num primeiro momento, a base completa e saneada serviu de insumo para as análises descritivas e mapeamentos visuais. Posteriormente, para as rodadas de modelagem definitiva e homologação dos classificadores, adotará-se um protocolo de divisão estratificada, garantindo a manutenção exata das proporções das classes e mitigando vieses de validação.

3.4.1 Uso da base completa para análise exploratória e seleção visual de variáveis

A base de dados integral depois do fim ETL funcionou como o ponto de partida para a análise exploratória e para a geração dos primeiros mapas visuais, essa estratégia de olhar para o conjunto completo de dados justifica-se pela necessidade de obter um panorama abrangente sobre a distribuição dos recursos, identificar possíveis padrões geométricos naturais e mensurar a escala real do desbalanceamento entre as operações normais e os episódios de fraude.

Durante essa sondagem, o volume total de dados sustentou o cálculo de estatísticas

descritivas, tabelas de distribuição de frequência, diagramas de boxplot, e matrizes de correlação.

Além de abrir caminhos na exploração inicial, a base completa também deu suporte ao processo de seleção de variáveis, esse filtro preliminar teve como objetivo detectar quais variáveis e combinações de variáveis possuíam a maior capacidade de gerar projeções gráficas interpretáveis, tanto ao analisar o espaço original reduzido via PCA quanto ao estudar as coordenadas de baixa dimensão geradas pelo t-SNE.

3.4.2 Divisão para modelagem final por *holdout* estratificado

Para a etapa de modelagem definitiva e homologação dos resultados, a estratégia escolhida para gerenciar os dados foi o método conhecido na literatura como *holdout*.

Esse procedimento consiste em segmentar a base original em subconjuntos disjuntos e mutuamente exclusivos. Uma parte dos dados é destinada exclusivamente ao desenvolvimento e ajuste fino dos algoritmos, enquanto a parcela restante é rigidamente preservada para a validação final.

De acordo com Kohavi (1995), uma prática comum é reservar cerca de $(2/3)$ dos dados para treinamento e $(1/3)$ para teste. O autor enfatiza também que o método *holdout* pode produzir uma estimativa pessimista do desempenho retratado, pois apenas uma fração da base é, de fato, entregue ao indutor durante a fase de treinamento. Mesmo assim, separar os dados entre treino e avaliação é uma prática que proporciona uma estimativa mais honesta da capacidade de generalização do modelo face a observações que não foram utilizadas no ajuste.

No escopo deste trabalho, implementará-se o *holdout* estratificado. Essa variação do *holdout* tradicional garante que cada um dos subconjuntos gerados mantenha exatamente a mesma proporção entre transações legítimas e fraudulentas observada na base original. Trata-se de um cuidado metodológico vital ao lidar com dados severamente desbalanceados pois impede que a divisão aleatória crie subconjuntos distorcidos, desprovidos de amostras da classe minoritária.

A divisão estratificada blinda a modelagem final, assegurando que o veredito sobre a eficiência dos algoritmos ocorra em um ambiente de testes puro. Esse isolamento neutraliza o risco de sobreajuste, em inglês *overfitting* e fornece métricas realistas sobre como o classificador se comportará ao processar transações que ele nunca viu.

3.5 Seleção de variáveis

3.5.1 Objetivo

Neste estudo, o processo de seleção de variáveis foi conduzido sob duas perspectivas complementares. A primeira delas é orientada à interpretação visual, buscando extrair um conjunto enxuto de atributos capaz de gerar representações gráficas claras e inteligíveis, isso tanto no espaço original transformado por PCA quanto nas projeções de baixa dimensão geradas pelo t-SNE. A segunda vertente foca estritamente no poder preditivo da modelagem final, onde os subconjuntos de variáveis são selecionados e testados por meio de métricas quantitativas, sem qualquer restrição quanto ao volume de atributos utilizados.

O fluxo de triagem segue uma lógica sistemática: para cada subconjunto de variáveis testado, o modelo era ajustado e suas respectivas métricas de desempenho eram calculadas. Na sequência, esses indicadores eram normalizados para uma escala comum e combinados em um índice sintético *score* final. Os arranjos que alcançaram as maiores pontuações foram promovidos para as etapas posteriores de análise e treinamento.

3.5.2 Critério de seleção

O critério para avaliar o potencial de cada variável baseou-se em um *score* composto por três métricas quantitativas distintas. A meta desse índice unificado foi fundir diferentes dimensões do desempenho do classificador em uma única métrica padronizada, permitindo um ranqueamento justo e direto de todos os subconjuntos candidatos.

O *score* combinou a AUC-PR, o MCC e a Log Loss. Essas três métricas foram escolhidas por cobrirem facetas perfeitamente complementares da eficiência de um modelo.

A AUC-PR mediu a capacidade geral das responsabilidades calculadas pelo modelo em segregar a classe positiva da negativa ao longo de toda a variação dos limiares de decisão. Como essa métrica, por definição, já transita naturalmente no intervalo entre 0 e 1, ela foi integrada diretamente à fórmula do *score*:

$$AUC-PR_{norm} = AUC-PR. \quad (3.1)$$

O MCC foi convocado para auditar o equilíbrio da classificação binária, pesando em uma mesma equação os verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos. Dado que o MCC original oscila entre -1 (discordância total) e 1 (classificação perfeita), aplicou-se uma transformação linear para transportá-lo de forma justa para a régua de 0 a 1:

$$MCC_{norm} = \frac{MCC + 1}{2}. \quad (3.2)$$

Com essa calibração, os cenários onde $MCC = -1$, $MCC = 0$ e $MCC = 1$ passaram a equivaler, respectivamente, a $MCC_{norm} = 0$, $MCC_{norm} = 0,5$ e $MCC_{norm} = 1$. Vale destacar que essa abordagem também foi utilizada para rastrear o ponto de corte ideal com base nos critérios intrínsecos do próprio MCC.

Por fim, a Log Loss avaliou a qualidade e a calibração das probabilidades estimadas pelo modelo. Ao contrário da AUC-PR e do MCC, a Log Loss é uma métrica de erro, o que significa que quanto menor o seu valor, melhor é a previsão do algoritmo. Para que ela pudesse somar forças com as outras métricas em uma escala ascendente onde números maiores indicam maior qualidade foi necessário inverter a sua lógica matemática. Tomando como referência os limites mínimos e máximos observados em todos os testes, a normalização invertida foi estruturada da seguinte forma:

$$LogLoss_{padrao} = \frac{LogLoss_{max} - LogLoss}{LogLoss_{max} - LogLoss_{min}}. \quad (3.3)$$

Nessa equação, $LogLoss$ representa a perda logarítmica do subconjunto sob análise, enquanto $LogLoss_{min}$ e $LogLoss_{max}$ delimitam o melhor e o pior caso registrados em todo o experimento, respectivamente. Graças a essa transformação, o arranjo com a menor perda recebe uma nota próxima de 1, enquanto aquele com o pior erro é penalizado com uma nota perto de 0.

Essa inversão garantiu que todas as métricas passassem a apontar para o mesmo norte de otimização, ou seja:

$$LogLoss_{padrao} \approx 1 \quad \Rightarrow \quad \text{melhor desempenho}, \quad (3.4)$$

$$LogLoss_{padrao} \approx 0 \quad \Rightarrow \quad \text{pior desempenho}. \quad (3.5)$$

Para blindar o sistema contra instabilidades numéricas que pudessem empurrar o cálculo para fora do intervalo $[0, 1]$, impôs-se um teto e um piso matemáticos à função. Desse modo, qualquer resultado inferior a 0 foi fixado em 0, e qualquer valor acima de 1 foi limitado a 1:

$$LogLoss_{norm} = \min(1, \max(0, LogLoss_{padrao})). \quad (3.6)$$

3.5.3 Construção do score de avaliação e rankeamento

Com as três métricas dentro do intervalo de 0 a 1, o passo seguinte foi consolidar o *score* final de avaliação. Esse índice unificado cumpre o papel prático de resumir a qualidade

de cada variável ou subconjunto em um único indicador, viabilizando um ranqueamento padronizado de todos os candidatos.

Dada a uniformidade das escalas, tornou-se metodologicamente viável combiná-las diretamente por meio de uma média aritmética simples. Assim cada subconjunto foi definido por:

$$Score(\mathcal{S}) = \frac{AUC-PR_{norm}(\mathcal{S}) + MCC_{norm}(\mathcal{S}) + LogLoss_{norm}(\mathcal{S})}{3}, \quad (3.7)$$

onde $\mathcal{S}$ representa a variável ou o subconjunto de variáveis sendo julgado.

Nesta arquitetura, optou-se por atribuir pesos idênticos a cada um dos componentes. Essa escolha se justifica pelo fato de que cada indicador audita uma dimensão totalmente independente da performance do classificador: a AUC-PR afere a capacidade global de ordenação dos scores ao longo de múltiplos limiares; o MCC valida o equilíbrio da matriz de confusão para uma classificação binária estrita; e a Log Loss pune o excesso de confiança em diagnósticos errados, avaliando a calibração probabilística.

Distribuir pesos iguais foi a estratégia adotada para evitar que uma única métrica canibalizasse as outras, garantindo que o valor final reflita um equilíbrio perfeito entre o poder de ranqueamento, a precisão da classificação e a qualidade das probabilidades estimadas.

Calculados os índices, os subconjuntos foram organizados em ordem decrescente. O topo do *ranking* aponta diretamente o arranjo de variáveis que alcançou a melhor sinergia e equilíbrio do estudo, enquanto a base da lista expõe as combinações de menor eficiência relativa.

3.5.4 Aplicação da GSFS

Após a definição do critério de seleção e da construção do score de avaliação, será aplicada a Seleção Sequencial Progressiva Generalizada. O objetivo dessa etapa é encontrar subconjuntos de variáveis que apresentem melhor desempenho para modelagem.

A seleção será feita com base na divisão por *holdout* estratificado definida anteriormente. Assim, os subconjuntos de variáveis serão avaliados sem utilizar o conjunto de teste final. Esse cuidado é importante, pois o teste deve permanecer reservado apenas para a avaliação final dos modelos, evitando que informações dessa etapa influenciem as escolhas realizadas durante a seleção.

A GSFS será aplicada em diferentes níveis de generalização, representados por r . Esse parâmetro indica quantas variáveis entram simultaneamente em cada etapa do processo. Neste trabalho, serão realizadas rodadas independentes com os seguintes valores:

$$r \in 1, 2, 3, 5. \quad (3.8)$$

Com isso, serão testadas seleções em que as variáveis entram uma a uma, duas a duas e três a três e cinco a cinco. Em cada rodada, o algoritmo avalia grupos de r variáveis ainda não selecionadas e calcula o score do subconjunto formado pela união entre o que já foi escolhido e o novo grupo candidato.

Para cada valor de r , o processo começa com um conjunto vazio de variáveis selecionadas:

$$\mathcal{S}_0 = \emptyset. \quad (3.9)$$

Em uma etapa genérica t , são formados grupos candidatos $\mathcal{G}_r$, compostos por r variáveis que ainda não foram selecionadas:

$$\mathcal{G}_r \subseteq \mathcal{X} \setminus \mathcal{S}_t, \quad |\mathcal{G}_r| = r. \quad (3.10)$$

Cada grupo candidato é combinado ao subconjunto já selecionado, formando um novo subconjunto de avaliação:

$$\mathcal{C} = \mathcal{S}_t \cup \mathcal{G}_r. \quad (3.11)$$

Para cada subconjunto candidato $\mathcal{C}$, o modelo será ajustado e serão calculadas as métricas AUC-PR, MCC normalizado e Log Loss normalizada. Depois disso, essas métricas serão combinadas no score final de avaliação. O grupo escolhido em cada etapa será aquele que apresentar o maior score:

$$\mathcal{G}_r^* = \arg \max_{\substack{\mathcal{G}_r \subseteq \mathcal{X} \setminus \mathcal{S}_t \\ |\mathcal{G}_r| = r}} \text{Score}(\mathcal{S}_t \cup \mathcal{G}_r). \quad (3.12)$$

Após a escolha do melhor grupo, o subconjunto selecionado é atualizado por:

$$\mathcal{S}_{t+1} = \mathcal{S}_t \cup \mathcal{G}_r^*. \quad (3.13)$$

Esse procedimento será repetido para cada valor de r . Ao final de cada rodada, serão armazenados os subconjuntos avaliados, seus respectivos scores e a posição de cada subconjunto no ranqueamento. Dessa forma, será possível comparar os resultados obtidos em diferentes níveis de generalização da GSFS.

Após a execução das rodadas, os subconjuntos resultantes serão comparados pelo score final. O subconjunto com maior score geral será selecionado como o mais adequado para as etapas posteriores de modelagem e avaliação.

A aplicação da GSFS permite avaliar não apenas variáveis isoladas, mas também grupos de variáveis com tamanhos diferentes. Isso é relevante porque algumas variáveis podem não se destacar quando analisadas sozinhas, mas passam a contribuir de forma mais clara quando aparecem junto de outras. Além disso, a comparação entre diferentes valores de r permite observar se grupos maiores melhoram ou prejudicam o desempenho de acordo com o critério adotado.

3.5.5 Definição do Número de Variáveis Selecionadas

A definição do número de variáveis selecionadas depende da finalidade de cada etapa da análise. Para as representações gráficas, esse número será determinado pela própria dimensão da visualização desejada. Já na modelagem final, a quantidade de variáveis será definida posteriormente, com base no melhor resultado obtido pela GSFS.

3.6 Redução de Dimensionalidade

3.6.1 Aplicação do PCA

A base de dados utilizada neste trabalho já possui parte de suas variáveis transformadas previamente por PCA. Mais especificamente, as variáveis ($V1, V2, \dots, V28$) correspondem a componentes principais obtidos a partir das variáveis originais. Essas variáveis originais não foram disponibilizadas por questões de confidencialidade.

Por esse motivo, as variáveis ($V1$) a ($V28$) não representam diretamente características brutas das transações, elas são combinações lineares resultantes da aplicação prévia do PCA. Esse ponto precisa ser levado em conta na interpretação dos resultados, pois essas variáveis preservam informação estatística dos dados originais, mas não possuem uma leitura direta em termos das características reais das transações.

As variáveis que não passaram por essa transformação na base original são `tempo_desde_a_primeira_transacao` e `valor_de_transacao`.

Neste trabalho, a aplicação do PCA será considerada a partir dessa estrutura da base. Como as variáveis $V1$ a $V28$ já correspondem a componentes principais, elas serão tratadas como variáveis numéricas provenientes de uma redução de dimensionalidade anterior, quando novas transformações por PCA forem aplicadas ao longo da metodologia, elas serão utilizadas apenas em etapas específicas de transformações e modelagem.

3.6.2 Aplicação do t-SNE

Para além das coordenadas geradas pela PCA, esta pesquisa incorpora a técnica T-SNE com o propósito de construir representações não lineares em baixa dimensão.

O algoritmo foi aplicado diretamente sobre a matriz de atributos previamente limpos e padronizados, para manter o escalonamento dos dados antes da projeção que é um requisito indispensável, já que o t-SNE calcula medidas de distância euclidiana no espaço original para estruturar suas distribuições de probabilidade de similaridade.

A calibração do T-SNE foi estruturada a partir de uma grade de busca de hiperparâmetros, desenhada para confrontar diferentes topologias e apontar a configuração que entrega a maior sinergia com o critério de seleção unificado.

A ancoragem do método utilizou uma parametrização de base composta por: `random_state = 42`, inicialização baseada nas componentes do PCA, taxa de aprendizado automática, teto de 250 iterações no processo de otimização e o mapeamento das projeções nas dimensões unidimensional, bidimensional e tridimensional. A varredura principal concentrou-se no parâmetro de perplexidade.

A fixação de `random_state = 42` blinda a reprodutibilidade científica do estudo, neutralizando a volatilidade estocástica inerente ao processo de descida de gradiente do algoritmo.

Por sua vez, injetar a inicialização via PCA confere uma estrutura geométrica preliminar robusta ao algoritmo. Essa estratégia acelera a convergência e reduz o risco de o mapa colapsar em organizações aleatórias nas fases iniciais de otimização.

A escolha por limitar o processo a 250 iterações justificou-se por restrições de infraestrutura de *hardware*. Testes preliminares indicaram que janelas de otimização mais longas sob perplexidades elevadas geravam um efeito cascata no consumo de memória RAM, sem trazer ganhos expressivos na definição geométrica. O teto adotado demonstrou, assim, um excelente equilíbrio entre nitidez analítica e viabilidade computacional. A taxa de aprendizado automática completou o arranjo de base, permitindo que o algoritmo modulasse o passo da otimização dinamicamente com base na densidade local dos dados.

O núcleo da nossa grade de testes concentrou-se na perplexidade. Valores mais baixos forçam o algoritmo a focar em microrregiões isoladas, destacando estruturas locais; já valores robustos expandem esse olhar, priorizando a organização global do ecossistema de dados.

Para cobrir esse espectro de forma justa, a grade de perplexidades foi dividida em três grandes zonas (baixa, média e alta). Dentro de cada faixa, os valores foram espaçados seguindo uma progressão geométrica. Esse desenho garante uma exploração homogênea do espaço de busca, evitando o viés de concentrar os testes em clusters de valores muito

próximos.

Matematicamente, para uma janela delimitada por um piso ($p_{\min}$), um teto ($p_{\max}$) e um número (n) de pontos desejados, o (i)-ésimo termo dessa escala geométrica é extraído por:

$$p_i = p_{\min} \left(\frac{p_{\max}}{p_{\min}} \right)^{\frac{i}{n-1}}, \quad i = 0, 1, \dots, n-1. \quad (3.14)$$

A modelagem calibrou a zona baixa no intervalo de 3 a 10; a zona média entre 15 e 65; e a zona superior cobrindo de 90 a 220. Dessa dinâmica, derivou-se o seguinte vetor final de testes:

$$\text{perplexidade} \in \{3, 4, 7, 10; 15, 24, 39, 65; 90, 121, 163, 220\}. \quad (3.15)$$

Dessa forma, a busca cobriu de maneira simétrica quatro configurações de sensibilidade puramente local, quatro arranjos intermediários e quatro mapeamentos de caráter global.

Concluída a projeção de cada mapa espacial, o Modelo de Mistura Gaussiana assume o papel de avaliador, ajustando-se sobre as novas coordenadas geradas. Extraem-se, então, a AUC-PR, o MCC e a Log Loss de cada cenário para consolidar o score unificado de avaliação.

Uma vez escolhido sobre a melhor configuração, as coordenadas ótimas passam a alimentar as fases de visualização e diagnóstico quantitativo do projeto.

3.7 Aplicação do modelo GMM

O Modelo de Mistura Gaussiana entra na arquitetura deste projeto para mapear a estrutura probabilística latente dos dados, assumindo que a população de transações pode ser representada por uma sobreposição de múltiplas distribuições normais. O grande trunfo desse classificador é fornecer as chamadas responsabilidades, que podem ser entendidas como probabilidades que indicam o grau de pertencimento de cada transação a cada uma das componentes gaussianas estimadas pelo sistema.

O algoritmo foi desenvolvido através da classe `GaussianMixture` do pacote *scikit-learn*, adotando a seguinte parametrização de controle:

- `n_components = 2`
- `covariance_type = full`
- `random_state = 42`

- `n_init = 3`
- `reg_covar = 10-6`

3.7.1 Ajuste do modelo

O treinamento do GMM é processado sobre os diferentes subconjuntos de variáveis filtrados nas etapas prévias da metodologia. A otimização dos parâmetros utiliza o EM, sendo assim ao atingir a convergência, o GMM devolve os pesos de relevância de cada componente, os vetores de médias, as matrizes de covariância e as matrizes de responsabilidade de cada registro. Esse conjunto de indicadores é o que viabilizará a leitura probabilística do problema e o cálculo das métricas de eficiência do trabalho.

3.7.2 Definição do número de componentes

O arranjo geométrico do modelo é ditado pelo parâmetro `n_components`, que fixa a quantidade de distribuições normais que tentarão descrever o espaço amostral. A definição por duas componentes reflete a própria natureza binária do nosso problema, caracterizado estritamente pelo binômio transação legítima versus operação fraudulenta. O modelo cria, portanto, dois grandes polos probabilísticos no espaço de atributos, associando cada transação a um vetor duplo de probabilidades de pertencimento.

É importante ressaltar que o GMM é um algoritmo de aprendizado não supervisionado, ou seja, ele calcula suas densidades sem olhar para as etiquetas reais de fraude durante o treino. Contudo, parametrizar o modelo com duas componentes nos permite, na fase de validação, confrontar as responsabilidades estimadas com os rótulos reais do banco de dados, auditando se uma das formas gaussianas naturalmente se especializou em isolar o comportamento dos golpes financeiros.

3.7.3 Tipo de matriz de covariância

O comportamento geométrico das curvas de densidade é controlado pelo parâmetro `covariance_type`. Ao optar pela configuração `full`, permite-se que cada uma das componentes gaussianas estime sua própria matriz de covariância de forma livre e independente.

Esse voto de flexibilidade é crucial porque garante que o modelo capture não apenas a dispersão isolada de cada atributo, mas também as correlações e dependências cruzadas entre as variáveis dentro de cada agrupamento.

3.7.4 Inicializações e reprodutibilidade

O hiperparâmetro `random_state` recebe uma semente fixa para neutralizar a sensibilidade do algoritmo em relação ao ponto de partida matemático. Como a convergência do algoritmo EM depende crucialmente de onde ele inicia sua busca, travar a semente garante que o ponto de partida seja idêntico em qualquer máquina, assegurando a consistência dos resultados.

Somado a isso, incorporou-se o parâmetro `n_init = 3`, que força o sistema a rodar o processo completo de otimização a partir de três pontos de partida totalmente distintos. Ao final das iterações, o algoritmo descarta as soluções de menor eficiência e retém apenas o ajuste que alcançou o maior limite inferior da log-verossimilhança.

3.7.5 Regularização da matriz de covariância

Fechando os parâmetros de controle, o argumento `reg_covar` atua como um mecanismo de segurança numérica, injetando uma constante infinitesimal positiva (10^{-6}) diretamente na diagonal principal das matrizes de covariância calculadas.

Essa estratégia de regularização é vital para evitar problemas numéricos.

3.7.6 Definição do Limiar de Decisão

Como o GMM fornece responsabilidades que podem ser interpretadas como probabilidades de pertencimento às componentes, é necessário definir um limiar de decisão para transformar essas probabilidades em classes previstas. Seja p_i a responsabilidade associada à componente interpretada como classe positiva. Nesse caso, a classificação binária pode ser definida por:

$$\hat{y}_i(t) = \begin{cases} 1, & \text{se } p_i \geq t, \\ 0, & \text{se } p_i < t. \end{cases} \quad (3.16)$$

em que (t) representa o limiar de decisão.

Neste trabalho, serão considerados dois tipos de limiar, também chamados de ponto de corte ou, em inglês, *threshold*. O primeiro é o limiar fixo de 0,50, utilizado como referência inicial. Esse valor representa uma regra simples de decisão, na qual observações com probabilidade estimada maior ou igual a (50%) são classificadas como pertencentes à classe positiva.

O segundo limiar será definido de forma orientada ao desempenho, por meio da maximização do Coeficiente de Correlação de Matthews. Para isso, serão avaliados diferentes valores de limiar t . Em cada caso, serão obtidas as classes previstas e calculado o respectivo (MCC t). Assim, o limiar ótimo será definido como:

$$t^* = \arg \max_t MCC(t). \quad (3.17)$$

Dessa forma, o valor de MCC utilizado na avaliação do modelo corresponderá ao melhor desempenho obtido entre os limiares testados:

$$MCC_{\max} = MCC(t^*). \quad (3.18)$$

A comparação entre o limiar fixo de 0,50 e o limiar ótimo baseado no MCC permitirá avaliar o impacto da escolha do ponto de corte sobre a classificação final. Essa análise é especialmente relevante em razão do desbalanceamento entre as classes, já que um limiar fixo pode não ser o mais adequado para equilibrar a identificação da classe minoritária e o controle de falsos positivos.

3.8 Modelos Comparativos

3.8.1 Ideia Central

Além do modelo principal baseado em Mistura Gaussiana, serão considerados modelos comparativos com o objetivo de fornecer referências adicionais para a interpretação dos resultados. Esses modelos não constituem o foco central do trabalho, mas funcionam como apoio metodológico, em outras palavras, eles ajudam a verificar se os padrões identificados pelo GMM permanecem coerentes quando observados por outras abordagens.

A utilização de modelos comparativos permite analisar o desempenho do GMM sob diferentes perspectivas. Enquanto o GMM é um modelo probabilístico não supervisionado, baseado em mistura de distribuições gaussianas, os modelos auxiliares apresentam características distintas. Essa comparação amplia a leitura dos resultados e permite verificar se as variáveis e representações selecionadas também apresentam desempenho consistente fora do modelo principal.

Nesta etapa, serão considerados a Regressão Logística e um modelo baseado em Estimativa de Densidade por Kernel. A Regressão Logística será utilizada como referência probabilística, paramétrica e supervisionada. Já o modelo baseado em KDE será utilizado como uma segunda abordagem probabilística, não paramétrica e não supervisionada. Ambos serão avaliados por meio das mesmas métricas quantitativas utilizadas nas demais etapas, permitindo uma comparação padronizada dos resultados.

3.9 Síntese do Fluxo Metodológico

3.9.1 Fluxo Metodológico

A metodologia proposta foi estruturada em etapas sequenciais, de modo a organizar o processo de preparação dos dados, seleção de variáveis, redução de dimensionalidade, modelagem e avaliação dos resultados.

Inicialmente, foi realizada a obtenção da base de dados. Em seguida, aplicou-se o processo de ETL, no qual foram feitas a leitura do arquivo original, a renomeação das variáveis, a verificação de inconsistências, a remoção de duplicatas e o tratamento de possíveis valores ausentes.

Depois dessa etapa, foi conduzida a análise da estrutura da base, incluindo a verificação dos tipos das variáveis, da quantidade de valores não nulos, dos valores únicos e da memória ocupada por cada coluna. Na sequência, as variáveis explicativas foram padronizadas, colocando-as em uma escala comum para a aplicação dos modelos e das técnicas de redução de dimensionalidade.

A base completa tratada foi então utilizada para a análise exploratória e para a construção das visualizações iniciais. Essa etapa teve como objetivo compreender a distribuição das variáveis, o desbalanceamento entre as classes e os padrões visuais presentes nos dados.

Para a etapa de modelagem final, será adotada uma divisão por *holdout* estratificado, preservando a proporção entre transações fraudulentas e não fraudulentas nos subconjuntos definidos. Esse cuidado busca tornar a avaliação mais consistente, especialmente por se tratar de uma base desbalanceada.

Por fim, os resultados obtidos pelo GMM serão comparados com modelos auxiliares, como a Regressão Logística e o modelo baseado em KDE. A avaliação será realizada por meio das métricas quantitativas e das análises gráficas definidas ao longo da metodologia. Dessa forma, o fluxo metodológico integra preparação dos dados, seleção de variáveis, visualização, modelagem probabilística e comparação de desempenho de maneira organizada e reprodutível.

4 Desenvolvimento

5 Conclusao

Referências

- CASTRO, C. L. d.; BRAGA, A. d. P. Aprendizado supervisionado com conjuntos de dados desbalanceados. **Sba: Controle & Automação**, v. 22, n. 5, p. 441–466, 2011.
- FILHO, M. **Guia completo da Log Loss (perda logarítmica) em machine learning**. 2023. Acesso em: 1 jun. 2026. Disponível em: <<https://mariofilho.com/guia-completo-da-log-loss-perda-logaritmica-em-machine-learning/>>.
- HOTELLING, H. Analysis of a complex of statistical variables into principal components. **Journal of Educational Psychology**, v. 24, p. 498–520, 1933.
- IBM. **O que é aprendizado não supervisionado?** 2024. Acesso em: 27 maio de 2026. Disponível em: <<https://www.ibm.com/br-pt/think/topics/unsupervised-learning/>>.
- IBM. **O que é aprendizado supervisionado?** 2024. Acesso em: 26 de maio de 2026. Disponível em: <<https://www.ibm.com/br-pt/think/topics/supervised-learning/>>.
- IBM. **O que é uma matriz de confusão?** 2024. Acesso em: 24 maio 2026. Disponível em: <<https://www.ibm.com/br-pt/think/topics/confusion-matrix/>>.
- KOHAVI, R. A study of cross-validation and bootstrap for accuracy estimation and model selection. In: **Proceedings of the 14th International Joint Conference on Artificial Intelligence**. Montreal, Canada: Morgan Kaufmann, 1995. p. 1137–1145. Disponível em: <<https://www.ijcai.org/Proceedings/95-2/Papers/016.pdf>>.
- MAATEN, L. v. d.; HINTON, G. Visualizing data using t-sne. **Journal of Machine Learning Research**, v. 9, p. 2579–2605, 2008.
- Machine Learning Group - ULB. **Credit Card Fraud Detection**. 2018. Base de dados pública disponível na plataforma Kaggle. Acesso em: 03 maio 2026. Disponível em: <<https://www.kaggle.com/datasets/mlg-ulb/creditcardfraud>>.
- MACQUEEN, J. Some methods for classification and analysis of multivariate observations. In: **Proceedings of the Fifth Berkeley Symposium on Mathematical Statistics and Probability**. [S.l.: s.n.], 1967. v. 1, p. 281–297.
- MATTHEWS, B. W. Comparison of the predicted and observed secondary structure of t4 phage lysozyme. **Biochimica et Biophysica Acta**, v. 405, n. 2, p. 442–451, 1975.
- MCLACHLAN, G.; PEEL, D. **Finite Mixture Models**. [S.l.]: Wiley, 2000.
- Nações Unidas Brasil. **Objetivos de Desenvolvimento Sustentável**. 2025. Acesso em: 19 maio 2026. Disponível em: <<https://brasil.un.org/pt-br/sdgs>>.
- PAPA, J. P. (APRENDIZADO DE MÁQUINA) **Aula 7.2 - Modelos de Misturas Gaussianas**. 2021. <<https://www.youtube.com/watch?v=0Hvoq4VsN0A>>. Acessado em: 23 maio 2026.
- PUDIL, P.; NOVOVIČOVÁ, J.; KITTLER, J. Floating search methods in feature selection. **Pattern Recognition Letters**, v. 15, n. 11, p. 1119–1125, 1993.

SANTOS, A. B. d.; SANTOS, I. D. B. d.; TOMA, K. M. Análise e detecção de fraudes em transações por meio de cartões de crédito: Uma abordagem investigativa. **15º Congresso de Inovação, Ciência e Tecnologia do IFSP**, 2024.

Scikit-learn developers. **Preprocessing data**. 2026. Acesso em: 16 maio 2026. Disponível em: <<https://scikit-learn.org/stable/modules/preprocessing.html>>.

Scikit-learn developers. **StandardScaler**. 2026. Acesso em: 15 maio 2026. Disponível em: <<https://scikit-learn.org/stable/modules/generated/sklearn.preprocessing.StandardScaler.html>>.

SONI, S. **Mastering t-SNE (t-distributed stochastic neighbor embedding)**. 2024. Medium. Acesso em: 21 maio 2026. Disponível em: <<https://medium.com/@sachinsoni600517/mastering-t-sne-t-distributed-stochastic-neighbor-embedding-0e365ee898ea>>.

The Financial Brand. **Credit Card Fraud is Rising. Are Your Cardmembers Protected?** 2024. Acesso em: 09 maio 2026. Disponível em: <<https://thefinancialbrand.com/news/credit-card-trends/fraud-is-rising-are-your-cardmembers-protected-178532>>.

TUKEY, J. W. **Exploratory Data Analysis**. Reading, Massachusetts: Addison-Wesley, 1977.