



**UNIVERSIDADE ESTADUAL PAULISTA
“JÚLIO DE MESQUITA FILHO”**

VITOR MARCHETTI CRAVEIRO

**TÉCNICAS DE VISUALIZAÇÃO DE DADOS E APLICAÇÃO DO MODELO DE
MISTURAS GAUSSIANAS NA DETECÇÃO DE FRAUDES EM CARTÕES DE CRÉDITO**

Presidente Prudente

2026

Vitor Marchetti Craveiro

Técnicas de Visualização de Dados e Aplicação do Modelo de Misturas Gaussianas na Detecção de Fraudes em Cartões de Crédito

Projeto para Trabalho de Conclusão de Curso apresentado ao Curso de Graduação em Estatística da FCT/Unesp para aproveitamento na disciplina de Trabalho de Conclusão de Curso I.

Universidade Estadual Paulista “Júlio de Mesquita Filho”

Faculdade de Ciências e Tecnologia

Curso de Estatística

Orientador: Prof. Guilherme Aparecido Santos Aguiar

Presidente Prudente

2026

Agradecimentos

Primeiramente, agradeço a Jesus pela concessão da vida, da saúde e pela fortaleza espiritual, sabedoria e perseverança concedidas não apenas ao longo da graduação, mas em toda a minha vida.

Expresso minha profunda gratidão ao meu orientador, Prof. Guilherme Aparecido Santos Aguilar. Sua condução foi indispensável para a conclusão deste trabalho e mais do que isso, agradeço pelas portas abertas por meio dos programas de iniciação científica e de aluno mentor, experiências que transformaram minha trajetória acadêmica e profissional. À minha família, estendo meu mais sincero obrigado. O apoio emocional e financeiro contínuo, somado à compreensão e ao auxílio nos momentos de abdução, foram os alicerces que tornaram possível a chegada a esta etapa. À minha noiva, agradeço imensamente pelo companheirismo e pelo suporte incondicional já que sua presença e incentivo constantes se fizeram sentir e foram determinantes, mesmo nos períodos em que a distância geográfica se fez presente. Presto também minha homenagem aos pesquisadores e à comunidade *open source* pois seus esforços e contribuições ao longo de gerações pavimentaram os caminhos da Estatística, do Aprendizado de Máquina e da Ciência de Dados, fornecendo a base teórica e prática que sustenta esta pesquisa.

Por fim, agradeço aos amigos, colegas de curso e demais docentes que, direta ou indiretamente, compartilharam desta jornada, colaborando para a minha formação acadêmica e pessoal.

Resumo

Com o aumento da geração de dados em vários locais da sociedade, a identificação de padrões anormais se tornou uma tarefa cada vez mais importante em áreas ligadas à segurança cibernética, transações financeiras e e-commerce. Nesse sentido, as técnicas de aprendizado de máquina, do inglês *machine learning* (ML) são comumente aplicadas para a detecção de anomalias e fraudes, principalmente no cenário em que os dados possuem alta complexidade, alta dimensionalidade e grande desbalanceamento entre observações normais e suspeitas.

Diante deste cenário, o presente trabalho tem o objetivo geral de aplicar técnicas de visualização e de aprendizagem de máquinas na detecção de anomalias associadas a possíveis fraudes em transações financeiras, tendo em especial a aplicação do modelo de Misturas Gaussianas, do inglês *Gaussian Mixture Model* (GMM) e na redução de dimensionalidade, com o uso da Análise de Componentes Principais, do inglês *Principal Component Analysis* (PCA), e também da Incorporação de vizinhos estocásticos distribuída pela distribuição t de student, do inglês *t-Distributed Stochastic Neighbor Embedding* (T-SNE).

A metodologia que foi proposta conta com etapas de pré-processamento da base de dados, têm tratamento e padronização das variáveis, também tem etapas de diminuição de dimensionalidade, ajuste do modelo GMM e ainda cálculo de responsabilidades estimadas e baseadas nas regiões de densidade probabilística. . O projeto propõe-se a trabalhar com a modelagem estatística, bem como a explorar representações em uma, duas e três dimensões, visando tornar a interpretação mais intuitiva e a avaliação visual, além de verificar a eficiência do modelo em cada uma delas.

Palavras-chave: Aprendizado de Máquina; Visualização de Dados; Detecção de fraudes; Gaussian Mixture Model; PCA; t-SNE.

Abstract

With the rise of data generation across various sectors of society, identifying anomalous patterns has become an increasingly vital task in fields like cybersecurity, financial transactions, and e-commerce. In this context, machine learning (ML) techniques are commonly applied to anomaly and fraud detection, especially in scenarios involving highly complex, high-dimensional data with a severe imbalance between normal and suspicious observations.

Given this scenario, the main objective of this study is to apply visualization and machine learning techniques to detect anomalies associated with potential fraud in financial transactions. Specifically, it focuses on the application of the Gaussian Mixture Model (GMM) alongside dimensionality reduction techniques, such as Principal Component Analysis (PCA) and t-Distributed Stochastic Neighbor Embedding (t-SNE).

The proposed methodology includes data preprocessing steps, such as variable treatment and standardization, as well as dimensionality reduction, GMM model fitting, and the calculation of estimated responsibilities based on probability density regions.

The project aims to work with statistical modeling while exploring one, two and three dimensional representations to make interpretation more intuitive for visual evaluation, ultimately verifying the model's efficiency in each of these dimensions.

Keywords: Machine Learning; Data Visualization; Fraud detection; Gaussian Mixture Model; PCA; t-SNE.

Lista de ilustrações

Lista de tabelas

Tabela 1	– Ambiente Python utilizado	39
Tabela 2	– Principais bibliotecas utilizadas	40
Tabela 3	– Resumo do processo inicial de ETL	42
Tabela 4	– Estrutura das variáveis da base de dados	43

Lista de abreviaturas e siglas

GMM	Gaussian Mixture Model
PCA	Principal Component Analysis
T-SNE	T-Distributed Stochastic Neighbor Embedding
KDE	Kernel density estimation
MCC	Matthews correlation coefficient
AUC-PR	Area under the precision recall curve
GSFS	Genealized sequential foward selection
AI	Artificial intelligence
ML	Machine learning
EM	Expectation-Maximization algorithm
MB	Megabyte
GB	Gigabyte
ODS	Objetivos De Desenvolvimento Sustentável
ONU	Organização Das Nações Unidas

Sumário

1	INTRODUÇÃO	11
1.1	Contextualização	11
1.1.1	Contextualização Global	11
1.2	Problema De Pesquisa	12
1.2.1	Problemas A Serem Contornados	12
1.3	Objetivo	13
1.3.1	Objetivos Gerais	13
1.3.2	Objetivos Específicos	13
1.3.2.1	Visualização Dos Dados E Estudo Sobre Principais Variáveis	13
1.3.2.2	Aplicação Do GMM Com Todas As Variáveis Disponíveis E Comparação Com Outros Modelos	14
1.4	Justificativa	15
1.4.1	Organização Do Trabalho	16
2	REFERENCIAL TEORICO	17
2.0.1	Sinópse	17
2.0.1.1	Resumo	17
2.1	Aprendizado De Máquina	17
2.1.1	Visão Geral	17
2.1.2	Aprendizado Supervisionado	18
2.1.3	Aprendizado Não Supervisionado	18
2.1.4	Abordagem Do Problema	18
2.2	Dados Desbalanceados	19
2.2.1	Definição E Consequências	19
2.3	Redução De Dimensionalidade	20
2.3.1	PCA	20
2.3.2	T-SNE	20
2.3.2.1	Formulação Matemática E Espaço De Origem	20
2.3.2.2	O Espaço De Destino E O Problema De Aglomeração	23
2.3.2.3	Otimização Via Divergência De Kullback-Leibler	24
2.3.2.4	Perplexidade	25
2.4	Modelos Utilizados	25
2.4.1	GMM	25
2.5	Seleção de Features	29
2.5.1	Motivação	29

2.5.2	Métricas Analíticas de Avaliação	30
2.5.2.1	AUC-PR	30
2.5.2.2	Coeficiente De Correlação De Matthews	31
2.5.2.3	Log Loss	32
2.5.3	Métricas Gráficas De Avaliação	33
2.5.3.1	Boxplot	33
2.5.3.2	Matriz De Confusão	33
2.5.3.3	Matriz De Correlação De Spearman	34
2.5.3.4	Visualização Das Responsabilidades Estimadas Pelo GMM	35
2.5.4	Seleção De Variáveis	35
2.5.4.1	Busca Exaustiva Combinatória Para Seleção De Variáveis	35
2.5.4.2	GSFS	36
3	METODOLOGIA	38
3.1	Caracterização da pesquisa	38
3.1.1	Natureza da pesquisa	38
3.1.2	Abordagem metodológica	38
3.2	Ferramentas e ambiente computacional	38
3.2.1	Importância	38
3.2.2	Ambiente de execução	39
3.2.3	Linguagem de programação e ambiente interativo	39
3.2.4	Bibliotecas utilizadas	39
3.2.5	Repositório do projeto	40
3.2.6	Ferramentas de escrita e documentação	40
3.3	Base de dados	40
3.3.1	Origem da base de dados	40
3.3.2	Descrição da base	41
3.3.3	Processo de Extração, Transformação e Carga dos Dados	41
3.3.4	Estrutura das variáveis	42
3.3.5	Padronização dos dados	43
3.4	Divisão da base de dados	44
3.4.1	Uso da base completa para análise exploratória e seleção visual de variáveis	44
3.4.2	Divisão para modelagem final por <i>holdout</i> estratificado	45
3.5	Seleção de variáveis	46
3.5.1	Objetivo	46
3.5.2	Critério de seleção	46
3.5.3	Construção do score de avaliação e ranqueamento	47
3.5.4	Aplicação da GSFS	48
3.5.5	Definição do Número de Variáveis Seleccionadas	50
3.6	Redução de Dimensionalidade	50