

3.6.1	Aplicação do PCA	50
3.6.2	Aplicação do t-SNE	51
3.7	Aplicação do modelo GMM	52
3.7.1	Ajuste do modelo	53
3.7.2	Definição do número de componentes	53
3.7.3	Tipo de matriz de covariância	53
3.7.4	Inicializações e reprodutibilidade	54
3.7.5	Regularização da matriz de covariância	54
3.7.6	Definição do Limiar de Decisão	54
3.8	Modelos Comparativos	55
3.8.1	Ideia Central	55
3.9	Síntese do Fluxo Metodológico	56
3.9.1	Fluxo Metodológico	56
4	DESENVOLVIMENTO	57
5	CONCLUSAO	58
	REFERÊNCIAS	59

1 Introdução

1.1 Contextualização

1.1.1 Contextualização Global

O que se percebe é que com o crescimento das transações digitais da últimas décadas, em particular o crescimento acelerado do comércio eletrônico, também houve um aumento significativo na geração de dados por consumidores, empresas e instituições financeiras sendo que simultaneamente houve um aprimoramento na segurança digital, podemos assim ver os casos de fraudes em cartão de crédito, casos esses que se mostram como um problema importante para instituições financeiras, empresas de tecnologia, plataformas de e-commerce e consumidores que acabam por pagar por isso, pois geram prejuízos financeiros, perda de confiabilidade e necessidade constante de ampliação dos sistemas de monitoramento.

De acordo com dados do portal The Financial Brand (2024), as perdas globais de fraude no cartão foram acima de US\$ 36 bilhões de dólares e estima-se que perdas acumuladas devem rondar a casa dos 397,4 bilhões de dólares na próxima década.

Segundo este, esses números demonstram a dimensão econômica do problema e a necessidade de métodos cada vez mais eficazes para identificar comportamentos suspeitos em volumes de transações muito elevado

Conforme o estudo de Santos, Santos e Toma (2024), as fraudes com cartões de crédito no Brasil requerem uma análise profunda da sua realidade, dado que os dados do Mapa da Fraude da ClearSale indicam que em 2023, foram analisadas cerca de 277,4 milhões de transações, sendo que mais de 3 milhões foram tentativas de fraude, além disso, totalizam valores de perda que arredondam a ordem de R\$3,5 bilhões, essas métricas reafirmam a relevância do problema no Brasil, além da necessidade da utilização da automatização e melhora de estratégias para análise e identificação de operações fraudulentas.

A gravidade do problema e o aumento constante da quantidade de dados torna a aplicação das técnicas automatizadas para detecção de fraude não só desejável mas necessária, nessa situação o aprendizado de máquina surge como uma alternativa importante uma vez que pode ser utilizado para reconhecer padrões, estruturas e comportamentos atípicos a partir dos dados e em particular, os métodos não supervisionados são úteis quando se têm dados previamente rotulados em quantidade não suficiente ou quando inexistem ou ainda quando se verifica uma alteração nos padrões de fraude ao longo do tempo.

Uma vez que o aprendizado de máquina não supervisionado se destaca pela habilidade de conseguir identificar agrupamentos e anomalias em dados sem necessidade de que eles dependam da classe ser definidos antes, demonstra que é uma característica relevante para problemas de fraude já que a maioria das transações suspeitas não são conhecidas a priori e muitas vezes se alteram e se aprimoram ao decorrer do tempo . Entre os algoritmos a serem usados para essa finalidade estão o algoritmo K-Médias, do inglês K-Means, apresentado em MacQueen (1967) e o GMM que permite representar os dados por meio de agrupamentos probabilísticos, tais misturas em geral são um tema discutido por McLachlan e Peel (2000).

No entanto, as bases de dados com transações financeiras são, de um modo geral, complexas e multidimensionais, pois podem ter um elevado número de variáveis relacionadas aos valores, geolocalização, horário, perfil do utilizador, padrões de compra etc, essa alta dimensionalidade, por um lado, pode dificultar a visualização e interpretação dos dados analisados e, por outro lado, também pode afetar a performance computacional dos algoritmos, então afim de evitar esses males são aplicadas técnicas de redução de dimensionalidade, como a PCA formalizada por Hotelling (1933) e a T-SNE proposta por Maaten e Hinton (2008).

Nesse sentido, sugere-se a opção da utilização de técnicas de visualização de dados que associadas a modelos probabilísticos possam auxiliar na identificação de anomalias que possam ser relacionadas a fraudes financeiras, logo a proposta consiste em reduzir a dimensionalidade dos dados, visualizá-los graficamente e aplicar o modelo GMM, fazendo análises sobre a posteriori.

1.2 Problema De Pesquisa

1.2.1 Problemas A Serem Contornados

A detecção de fraudes é um problema complexo, pois os dados geralmente apresentam alto desbalanceamento entre as classes, grande quantidade de variáveis e padrões difíceis de serem identificados visualmente, além disso em muitos casos as observações fraudulentas representam uma pequena parcela do conjunto de dados, o que dificulta o treinamento e a avaliação dos modelos.

Dessa forma, este trabalho busca responder à seguinte questão: técnicas de redução de dimensionalidade combinadas com o modelo Gaussian Mixture Model podem auxiliar na identificação de anomalias e possíveis fraudes em conjuntos de dados?

1.3 Objetivo

1.3.1 Objetivos Gerais

O objetivo geral deste trabalho é aplicar técnicas de visualização de dados e aprendizado de máquina na detecção de fraudes em transações com cartões de crédito, utilizando o modelo GMM para identificação de anomalias e análise de padrões nos dados, para isso foram construídos scores de avaliação destinados à seleção de variáveis e combinações de variáveis mais relevantes para visualização e predição, além disso, busca-se analisar diferentes representações dos dados por meio de técnicas de redução de dimensionalidade, como PCA e T-SNE; Após todo o processo e escolha dos hiperparâmetros, tem-se como o objetivo a comparação com o modelo supervisionado de regressão logística, com o modelo não supervisionado de Estimativa de Densidade por Kernel, do inglês *Kernel Density Estimation* (KDE) e com a base de dados real rotulada.

1.3.2 Objetivos Específicos

Para alcançar o objetivo geral, foram definidos os seguintes objetivos específicos:

1.3.2.1 Visualização Dos Dados E Estudo Sobre Principais Variáveis

- Pré-processar a base de dados mediante o tratamento, a normalização ou a padronização das variáveis do ponto.
- Mapear, de forma individual, todas as variáveis disponíveis que compõem a base de dados, a fim de avaliar como estas se comportam em função da variável rótulo.
- Mapear todas as combinações duas a duas das variáveis, de forma a analisar pares de variáveis que tenham maior capacidade de separação entre transações normais e fraudulentas.
- Mapear todas as combinações três a três das variáveis, de forma a analisar trios de variáveis que tenham melhor desempenho
- Analisar a variável rótulo, do inglês *label*, observando a distribuição das classes e o desbalanceamento entre transações normais e fraudulentas.
- Usar o GMM e, em seguida, as métricas Área Sob a Curva Precisão-Revocação, do inglês *Area Under the Precision-Recall Curve* (AUC-PR), Coeficiente de Correlação de Matthews, do inglês *Matthews Correlation Coefficient* (MCC) e Perda Logarítmica, do inglês *Log Loss*, para a construção de scores de avaliação sobre as variáveis e suas combinações.

- Preparar as visualizações de dados em uma, duas e três dimensões, a partir das 3 melhores combinações escolhidas pelos scores de avaliação aplicados às representações obtidas por PCA, tendo em vista obter padrões, agrupamentos e separações entre as transações normais e fraudulentas.
- Realizar uma comparação gráfica e analítica das representações obtidas, pelo PCA e pelo T-SNE, em relação a combinações de variáveis e regiões associadas a possíveis anomalias.
- Analisar os resultados finais

1.3.2.2 Aplicação Do GMM Com Todas As Variáveis Disponíveis E Comparação Com Outros Modelos

- Escolher as melhores combinações de variáveis através da seleção sequencial progressiva generalizada, do inglês *Generalized Sequential Forward Selection* (GSFS).
- Aplicar o GMM sobre subconjuntos de variáveis selecionadas para identificação de padrões, agrupamentos e possíveis anomalias associadas a fraudes em cartões de crédito.
- Testar diferentes configurações de hiperparâmetros do GMM, incluindo número de gaussianas, tipo de matriz de covariância e tipo de critério de inicialização, e diferentes pontos de corte para a classificação das observações, avaliando quais que se comportam melhor.
- Aplicar o modelo supervisionado de Regressão Logística ao subconjuntos das variáveis selecionadas utilizando como variável rótulo para avaliar a sua habilidade classificativa entre as transações normais e fraudulentas, além de avaliar diferentes cortes para a classificação das observações, ao fim concluir qual é a configuração que melhor se comporta.
- Realizar testes no modelo da Regressão Logística, mais especificamente em relação ao tipo de penalização e à função de ligação, o objetivo é melhorar o desempenho da Regressão Logística numa base desbalanceada.
- Aplicar o modelo KDE sobre subconjuntos de variáveis selecionados com o intuito de identificar observações com comportamentos anômalos , e posteriormente lhe avaliar pelos mesmos métodos dos outros modelos.
- Avaliar o desempenho dos modelos pelas métricas visuais: Matriz de Confusão, Matriz de Correlação de Spearman, gráfico que mostra os dados plotados e pela visualização das responsabilidades estimadas.

- Comparar os resultados proporcionados pelo GMM com um método supervisionado (Regressão Logística) e um não supervisionado (KDE), todos métodos probabilísticos, tendo como critério o desempenho quantitativo e a separação entre transações normais e fraudulentas.
- Analisar os resultados das previsões dos vários modelos e comparar com a base de dados.
- Verificar os resultados finais.

1.4 Justificativa

A fraude em cartões de crédito é um problema cada vez mais sério, com consequências econômicas e sociais profundas, por um lado, a digitalização dos meios de pagamento democratizou o acesso a serviços financeiros, por outro, expôs consumidores, empresas e bancos a uma onda crescente de golpes e fraudes.

Com isso, o uso combinado de métodos estatísticos, de aprendizado de máquina e técnicas de visualização de dados ingles *data visualization* se tornam uma estratégia indispensável para o mapeamento de comportamentos inadequados e robustecimentos da segurança do ecossistema financeiro.

Este trabalho se justifica, exatamente, pela necessidade de se desenvolver e testar metodologias adequadas e eficazes no rastreamento de anomalias em grandes volumes de dados financeiros, usando GMM para analisar o múltiplo ângulo das transações e também os transformando em base de dados visuais. Para enriquecer o debate, também se confronta o presente trabalho com métodos supervisionados e não supervisionados da questão, para entender qual ferramenta se adapta melhor à volatilidade do problema.

Essa pesquisa tece uma conexão direta com os Objetivos de Desenvolvimento Sustentável (ODS), da Organização das Nações Unidas (ONU), do inglês *united nations organization*, especialmente com a meta 8, 9 e 16 (Nações Unidas Brasil, 2025). No que diz respeito a ODS 8, que diz respeito ao crescimento económico inclusivo e ao trabalho digno, salvaguardar a integridade das transações digitais é um passo vital para a construção de uma economia digital resiliente.

A ODS 9 que se trata da inovação e a infraestrutura resiliente, da promoção da industrialização inclusiva e sustentável e do fomento a inovação, a aplicação de técnicas de análise dados, aprendizado de máquina e visualização computacional contribui para a modernização de sistemas financeiros e para o desenvolvimento tecnológico.

Por fim, mediante a sua implementação, o projeto converge para o ODS 16, que preconiza a transparência e a solidez institucional. Em suma, os estudos são justificados