

pela modificação da estatística e do ML que se transformaram em vetores de inovação e responsabilidade social.

1.4.1 Organização Do Trabalho

O trabalho se divide em cinco capítulos articulados entre si para que haja linearidade e clareza no desenvolvimento da pesquisa.

O primeiro capítulo trata da comoção que deu ensejo à contextualização do tema, delimitação do problema de pesquisa, justificção e objetivos gerais e específicos.

A partir do momento seguinte inicia-se a fundamentação teórica já no Capítulo 2, nele acoplam-se as principais ideias que são necessárias para a sustentação do trabalho com as técnicas de redução de dimensionalidade, seleção de atributos, modelos probabilísticos, métricas de desempenho e as abordagens mais usadas na literatura para a detecção de anomalias e fraudes.

No Capítulo 3, a metodologia utilizada na pesquisa será abordada, além dos procedimentos práticos, este segmento corresponde à categorização da pesquisa, descrição do banco de dados e as etapas de preparação e pré-processamento, do mesmo modo, definem-se os critérios de seleção de variáveis, particionamento dos dados, implementação de técnicas de redução de dimensionalidade, configurações dos modelos de previsão e ajuste das métricas de avaliação.

O Capítulo 4 mostra como foi a pesquisa e os resultados. Na seção prática e analítica do artigo, demonstra-se a realização do delineamento metodológico, que compreende a utilização de uma análise exploratória dos dados dos experimentos computacionais, resultados quantitativos obtidos e interpretação das visualizações e dos cálculos das métricas.

Por fim, as considerações finais da pesquisa estão no capítulo 5, esse fechamento traz de volta os objetivos, resume o principal resultado e apresenta as contribuições da pesquisa tanto acadêmicas, quanto práticas, sugestões para o futuro foram abordadas, bem como limitações do estudo

2 Referencial Teorico

2.0.1 Sinópse

2.0.1.1 Resumo

Este capítulo apresenta as definições e conceitos presentes neste estudo, primeiramente são delimitados os conceitos básicos de aprendizado de máquina.

A seguir, destaca-se o problema das fraudes em cartão de crédito, o que acontece sob o desbalanceamento severo das bases de dados. Posteriormente são apresentados os métodos de redução de componentes, das quais foram utilizados o PCA e o T-SNE como proposta de mitigação da alta dimensionalidade e facilitar a visualização.

A elaborada escolha de variáveis, como o GFSF e a combinação de buscas exaustiva combinatória também são detalhadas por último, e antes se apresentam os modelos estatísticos que foram utilizados, com destaque para o GMM, seguido das métricas de avaliação que fundamentam a comparação dos resultados.

2.1 Aprendizado De Máquina

2.1.1 Visão Geral

A Inteligência Artificial, do inglês, *Artificial Intelligence* (AI) é um ramo da ciência que abrange o estudo e desenvolvimento de sistemas que são capazes de executar tarefas que se pressupõem envolver algum tipo de inteligência humana, como reconhecimento, decisão, classificação ou previsão. O aprendizado de máquina é uma ferramenta relevante para a detecção de fraudes em cartões de crédito, isso porque esse tipo de modelo permite analisar padrões de comportamento em conjuntos grandes e complexos, além do mais, fraudes costumam ser pequenas em comparação ao total de observações e mudam ao longo do tempo, dessa forma, modelos capazes de obter padrões não informados, são uma boa ferramenta de tomada decisão.

A aprendizagem máquina pode ser dividida essencialmente em aprendizagem supervisionada, aprendizagem não supervisionada e aprendizagem por reforço, dado que os modelos supervisionados se utilizam dos dados rotulados para aprender uma relação entre as variáveis explicativas e a resposta, ou seja, no caso dos dados já serem rotulados, o que significa que já sabemos a resposta que queremos, dessa forma os modelos conseguem aprender de forma eficiente, uma vez que já tem um padrão que serve como base para procurar as soluções, já no caso da aprendizagem não supervisionada, o objetivo é organizar

os dados e identificar estruturas, agrupamentos ou anomalias que não estão explicitamente rotulados, neste tipo de situação como os dados não têm rótulos e o algoritmo ou modelo deve aprender com os dados a estrutura dos dados, por fim e não trabalhada nesse projeto, a aprendizagem por reforço que envolve agentes que aprendem a tomar decisões a partir de uma interação com o ambiente.

2.1.2 Aprendizado Supervisionado

Segundo a IBM, o aprendizado supervisionado pode ser definido da seguinte forma:

Aprendizado supervisionado é uma técnica de aprendizado de máquina que usa conjuntos de dados rotulados para treinar modelos de inteligência artificial (IA) para identificar os padrões e as relações subjacentes. O objetivo do processo de aprendizado é criar um modelo capaz de prever saídas corretas em novos dados do mundo real.

(IBM, 2024b)

2.1.3 Aprendizado Não Supervisionado

Ainda segundo a IBM, o aprendizado não supervisionado pode ser definido da seguinte forma:

O aprendizado não supervisionado, também conhecido como aprendizado de máquina não supervisionado, utiliza algoritmos de aprendizado de máquina (ML) para analisar e agrupar conjuntos de dados sem rótulos. Esses algoritmos descobrem padrões ocultos ou agrupamentos de dados sem a necessidade de intervenção humana. A capacidade do aprendizado não supervisionado de identificar semelhanças e diferenças nas informações o torna uma solução ideal para análise exploratória de dados, estratégias de venda cruzada, segmentação de clientes e reconhecimento de imagens.

(IBM, 2024a)

2.1.4 Abordagem Do Problema

Neste trabalho, a abordagem executada é uma abordagem híbrida, isso porque o modelo GMM é primeiramente ajustado, sem o uso da variável rótulo em que as componentes gaussianas são estimadas sem que a variável rótulo entre em cena, contudo após o ajuste, a variável rótulo é utilizada para interpretação das componentes obtidas, assim são verificadas a proporção de transações fraudulentas e não fraudulenta em cada componente deduzindo assim qual gaussiana gera as fraudes e qual gera as transações normais, além disso, a variável rótulo também é utilizada na construção dos scores de avaliação e seleção de variáveis, assim, embora o primeiro ajuste sob a metodologia GMM

tenha um caráter não supervisionado, a posterior avaliação, interpretação e seleção de variáveis passam a incorporar informação supervisionada, dessa forma a metodologia proposta pode ser entendida como uma abordagem misturada de ajuste não supervisionado com avaliação supervisionada; essa estratégia é adequada ao problema de detecção, pois permite explorar a estrutura dos dados por meio de componentes probabilísticas e, ao mesmo tempo, utilizar a variável rótulo disponível para a avaliação da qualidade das representações, seleção de variáveis e interpretação dos agrupamentos encontrados.

2.2 Dados Desbalanceados

2.2.1 Definição E Consequências

Os dados desbalanceados caracterizam-se por apresentar uma disparidade significativa na quantidade de observações entre as classes de uma base de dados. Em problemas de classificação binária, essa condição implica que uma das categorias dispõe de um volume de registros substancialmente superior à outra. A classe com maior representatividade é denominada majoritária, ao passo que aquela com menor quantitativo de registros é chamada de minoritária.

Esse fenômeno é frequente em aplicações reais de aprendizado de máquina, manifestando-se sobretudo em cenários onde o evento de interesse é estocasticamente raro. No contexto da detecção de fraudes em cartões de crédito, o desbalanceamento assume um papel central: a esmagadora maioria das transações financeiras é legítima, enquanto as operações fraudulentas correspondem a uma fração ínfima do montante global.

Nesse sentido, Castro e Braga (2011) destacam que, em um problema com classes desbalanceadas, “a solução ótima (f^*), buscada pelas máquinas de aprendizado, naturalmente deve favorecer a classe majoritária”.

Para mitigar esse viés, a abordagem metodológica deste estudo preconiza o emprego de métricas de desempenho estritamente adequadas à avaliação da categoria minoritária. Dessa forma, utilizam-se os critérios da Área Sob a Curva de Precisão e Recall (AUC-PR), o Coeficiente de Correlação de Matthews (MCC) e a perda logística (Log Loss). Essas métricas viabilizam uma análise rigorosa e abrangente da capacidade preditiva dos modelos na identificação de fraudes, ponderando tanto os erros de classificação quanto a calibração das probabilidades estimadas.

Desse modo, o enfrentamento do desbalanceamento de dados transcende a escolha do algoritmo isolado, englobando a definição criteriosa das métricas e da estratégia de validação. Nesta pesquisa, tal peculiaridade é considerada tanto na formulação dos escores de avaliação das variáveis quanto na análise comparativa entre o Modelo de Mistura Gaussiana (GMM), a Regressão Logística e a Estimação de Densidade por Kernel (KDE).

2.3 Redução De Dimensionalidade

2.3.1 PCA

A Análise de Componentes Principais é um dos procedimentos de estatística multivariada que serve para transformar, um conjunto de variáveis que normalmente estão correlacionadas entre si, em um novo conjunto de variáveis que são não correlacionadas. A combinação linear das variáveis originais dá origem às novas variáveis e estas recebem o nome de componentes principais. Os componentes são organizados pela quantidade de variância que explicam, assim, os primeiros componentes são aqueles que concentram a maior parte da informação existente na base.

A PCA é importante, pois permite dimensionalmente reduzir o número de variáveis com perdas mínimas. Em bases com várias variáveis, pode ocorrer a repetição de parte da informação ou a sua distribuição em variáveis correlacionadas e nesses casos, permite-se de forma mais fácil representar os dados em um espaço de menor dimensão em comparação a representação original, além disso, como os componentes principais são ortogonais, a técnica também serve para reduzir os problemas da multicolinearidade.

Devido a essas razões, PCA é muitas vezes utilizado em diferentes estágios de pré-processamento, compactação, visualização e exploração de dados. Nesse trabalho foi utilizada com a finalidade de ter uma diminuição da dimensão da base de dados, exclusão de multicolinearidade, mas em paralelo, ter uma proteção aos dados sensíveis da Instituição e dos clientes.

2.3.2 T-SNE

Conforme explica SONI (2024), a ideia do método é mapear dados de alta dimensão para um espaço bem menor, geralmente em duas ou três dimensões, buscando preservar a estrutura local dos dados. Em outras palavras, o método procura fazer com que pontos próximos no espaço original continuem próximos na representação visual final.

Em bases financeiras complexas, é comum que existam relações não lineares entre as variáveis, nesses casos, o PCA pode não capturar toda a estrutura presente nos dados. O t-SNE atua justamente nesse ponto, pois ajuda a trazer à tona agrupamentos, ou em inglês *clusters*, que podem estar pouco evidentes no espaço original. Para isso, o algoritmo não trabalha apenas com distâncias de forma direta; ele transforma essas distâncias em medidas probabilísticas de similaridade.

2.3.2.1 Formulação Matemática E Espaço De Origem

Para formalizar o problema, considere inicialmente uma matriz contendo (n) transações vetorizadas. Essas observações são representadas pelos vetores:

$$\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_n. \quad (2.1)$$

Assume-se que cada uma dessas observações pertence a um espaço (p)-dimensional. Assim:

$$\mathbf{x}_i \in \mathbb{R}^p. \quad (2.2)$$

O objetivo do t-SNE é encontrar uma configuração correspondente em baixa dimensão, representada pelos vetores:

$$\mathbf{y}_1, \mathbf{y}_2, \dots, \mathbf{y}_n. \quad (2.3)$$

Nesse novo espaço, a dimensão de destino é representada por (q) sendo menor que a dimensão original (p). Portanto:

$$\mathbf{y}_i \in \mathbb{R}^q, \quad q < p. \quad (2.4)$$

A construção do método começa pelo cálculo da distância euclidiana ao quadrado entre cada par de observações $\mathbf{x}_i$ e $\mathbf{x}_j$. Essa distância é dada por:

$$d_{ij}^2 = |\mathbf{x}_i - \mathbf{x}_j|^2. \quad (2.5)$$

Os resultados dessas distâncias cruzadas formam uma matriz global de distâncias ao quadrado, indicada por $\mathbf{D}^2$. Como a distância de um ponto para ele mesmo é igual a zero, tem-se $d_{ii}^2 = 0$. Além disso, como a distância euclidiana é simétrica, tem-se $d_{ij}^2 = d_{ji}^2$. Dessa maneira, a matriz pode ser escrita como:

$$\mathbf{D}^2 = \begin{bmatrix} 0 & d_{12}^2 & \cdots & d_{1n}^2 \\ d_{21}^2 & 0 & \cdots & d_{2n}^2 \\ \vdots & \vdots & \ddots & \vdots \\ d_{n1}^2 & d_{n2}^2 & \cdots & 0 \end{bmatrix}. \quad (2.6)$$

O passo seguinte consiste em transformar essa matriz de distâncias em probabilidades. Para isso, o t-SNE considera uma distribuição gaussiana centralizada em cada ponto $\mathbf{x}_i$. A densidade multivariada resultante, considerando um ponto vizinho $\mathbf{x}_j$, é modelada por:

$$f(\mathbf{x}_j | \mathbf{x}_i, \sigma_i^2) = \frac{1}{(2\pi\sigma_i^2)^{p/2}} \exp\left(-\frac{|\mathbf{x}_i - \mathbf{x}_j|^2}{2\sigma_i^2}\right). \quad (2.7)$$