

O parâmetro σ_i^2 representa a variância associada à vizinhança ao redor de $\mathbf{x}_i$. A partir dessa densidade, define-se $(s_{j|i})$, para $j \neq i$, como:

$$s_{j|i} = \frac{1}{(2\pi\sigma_i^2)^{p/2}} \exp\left(-\frac{|\mathbf{x}_i - \mathbf{x}_j|^2}{2\sigma_i^2}\right), \quad j \neq i. \quad (2.8)$$

Para transformar essa similaridade em uma probabilidade condicional, normaliza-se $(s_{j|i})$ pela soma das similaridades entre $\mathbf{x}_i$ e todos os demais pontos:

$$p_{j|i} = \frac{\frac{1}{(2\pi\sigma_i^2)^{p/2}} \exp\left(-\frac{|\mathbf{x}_i - \mathbf{x}_j|^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \frac{1}{(2\pi\sigma_i^2)^{p/2}} \exp\left(-\frac{|\mathbf{x}_i - \mathbf{x}_k|^2}{2\sigma_i^2}\right)}. \quad (2.9)$$

Utilizando a notação $d_{ij}^2 = |\mathbf{x}_i - \mathbf{x}_j|^2$, chega-se à forma compacta:

$$p_{j|i} = \frac{\exp\left(-\frac{d_{ij}^2}{2\sigma_i^2}\right)}{\sum_{k \neq i} \exp\left(-\frac{d_{ik}^2}{2\sigma_i^2}\right)}, \quad j \neq i. \quad (2.10)$$

Essa normalização garante que, para cada ponto $\mathbf{x}_i$, a soma das probabilidades condicionais em relação aos demais pontos seja igual a 1. Portanto:

$$\sum_{j \neq i} p_{j|i} = 1. \quad (2.11)$$

Note que cada ponto possui seu próprio parâmetro σ_i . Essa flexibilidade é importante, pois permite que o método adapte a largura da vizinhança de acordo com a densidade local dos dados. Apesar disso, as probabilidades condicionais ainda apresentam uma assimetria. Em geral:

$$p_{j|i} \neq p_{i|j}. \quad (2.12)$$

Essa assimetria ocorre porque cada ponto possui seu próprio desvio padrão local σ_i . Para contornar esse problema e construir uma matriz de probabilidades conjuntas simétrica, o T-SNE combina as probabilidades condicionais $p_{j|i}$ e $p_{i|j}$. A probabilidade conjunta p_{ij} é definida por:

$$p_{ij} = \frac{p_{j|i} + p_{i|j}}{2n}, \quad i \neq j. \quad (2.13)$$

Definindo:

$$p_{ii} = 0. \quad (2.14)$$

O denominador $(2n)$ aparece porque:

$$\sum_{j \neq i} p_{j|i} = 1 \quad \Rightarrow \quad \sum_i \sum_{j \neq i} p_{j|i} = n. \quad (2.15)$$

De forma análoga:

$$\sum_{i \neq j} p_{i|j} = 1 \quad \Rightarrow \quad \sum_j \sum_{i \neq j} p_{i|j} = n. \quad (2.16)$$

Portanto, ao somar as duas contribuições, obtém-se o valor $(2n)$.

Assim, a matriz de probabilidades conjuntas $\mathbf{P}$ pode ser representada por:

$$\mathbf{P} = \begin{bmatrix} 0 & p_{12} & \cdots & p_{1n} \\ p_{21} & 0 & \cdots & p_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ p_{n1} & p_{n2} & \cdots & 0 \end{bmatrix}. \quad (2.17)$$

Como $p_{ij} = p_{ji}$, a matriz $\mathbf{P}$ é simétrica. Cada elemento p_{ij} representa a probabilidade conjunta de vizinhança entre as observações $\mathbf{x}_i$ e $\mathbf{x}_j$ no espaço original de alta dimensão.

2.3.2.2 O Espaço De Destino E O Problema De Aglomeração

Após a construção da matriz $\mathbf{P}$, o próximo passo é obter uma representação dos dados em um espaço de menor dimensão. Neste trabalho, em vez de inicializar os pontos de forma totalmente aleatória, considera-se a inicialização via PCA. Essa escolha fornece um ponto de partida linearmente mais organizado para as coordenadas $\mathbf{y}_i$.

No espaço reduzido, calcula-se uma nova matriz de probabilidades, chamada $\mathbf{Q}$. A diferença importante é que, nessa etapa, o t-SNE não utiliza uma distribuição normal para medir a proximidade entre os pontos $\mathbf{y}_i$ e $\mathbf{y}_j$, em vez disso utiliza uma distribuição T de Student com um grau de liberdade, equivalente à distribuição de Cauchy.

Essa escolha busca mitigar o chamado *crowding problem*, ou problema de aglomeração. Ao reduzir muitas dimensões para apenas duas ou três, pode faltar espaço no plano para representar adequadamente todas as relações de distância. Se fosse utilizada uma distribuição normal, pontos moderadamente distantes poderiam colapsar em uma região muito concentrada. Como a distribuição T possui caudas mais pesadas, ela permite maior separação entre agrupamentos no espaço reduzido.

A probabilidade condicional $q_{i|j}$ no espaço projetado é calculada por:

$$q_{i|j} = \frac{\left(1 + |\mathbf{y}_i - \mathbf{y}_j|^2\right)^{-1}}{\sum_{k \neq l} \left(1 + |\mathbf{y}_k - \mathbf{y}_l|^2\right)^{-1}}, \quad i \neq j, \quad q_{i|i} = 0. \quad (2.18)$$

A partir desse ponto, repete-se a ideia utilizada para $\mathbf{P}$, obtendo-se a matriz de probabilidades no espaço reduzido:

$$\mathbf{Q} = \begin{bmatrix} 0 & q_{12} & \cdots & q_{1n} \\ q_{21} & 0 & \cdots & q_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ q_{n1} & q_{n2} & \cdots & 0 \end{bmatrix}. \quad (2.19)$$

Como os valores q_{ij} são normalizados, a soma total das probabilidades conjuntas no espaço reduzido é igual a 1. Logo:

$$\sum_{i=1}^n \sum_{j \neq i} q_{ij} = 1 \quad (2.20)$$

2.3.2.3 Otimização Via Divergência De Kullback-Leibler

O objetivo final do t-SNE é aproximar a matriz de probabilidades do espaço reduzido, $\mathbf{Q}$, da matriz de probabilidades do espaço original, $\mathbf{P}$. Para medir essa diferença, utiliza-se a divergência de Kullback-Leibler como função de custo:

$$C = KL(\mathbf{P} \parallel \mathbf{Q}) = \sum_{i=1}^n \sum_{j \neq i} p_{ij} \log \left(\frac{p_{ij}}{q_{ij}} \right). \quad (2.21)$$

Minimizar C significa penalizar configurações nas quais pontos próximos no espaço original aparecem distantes no espaço reduzido. Dessa forma, o método procura preservar, principalmente, as relações locais entre as observações.

Essa otimização é resolvida de forma iterativa por meio do gradiente descendente. A atualização das posições dos pontos a cada iteração pode ser escrita como:

$$\mathbf{y}_i^{(t+1)} = \mathbf{y}_i^{(t)} \eta \frac{\partial C}{\partial \mathbf{y}_i}. \quad (2.22)$$

Nessa expressão, η representa a taxa de aprendizado, $\mathbf{y}_i^{(t)}$ é a posição do ponto i na iteração t , e $\frac{\partial C}{\partial \mathbf{y}_i}$ representa o gradiente da função custo em relação à posição do ponto $\mathbf{y}_i$.

O gradiente utilizado para direcionar essa movimentação é dado por:

$$\frac{\partial C}{\partial \mathbf{y}_i} = 4 \sum_j (p_{ij} - q_{ij})(\mathbf{y}_i - \mathbf{y}_j) \left(1 + |\mathbf{y}_i - \mathbf{y}_j|^2\right)^{-1}. \quad (2.23)$$

Ao longo das iterações, esse processo ajusta a posição dos pontos no espaço reduzido. Quando o algoritmo converge, obtém-se uma representação visual que busca preservar a estrutura local dos dados originais. No contexto de transações financeiras, essa representação pode auxiliar na identificação de padrões, agrupamentos e possíveis separações entre transações legítimas e fraudulentas.

2.3.2.4 Perplexidade

Um hiperparâmetro importântissimo do T-SNE é a perplexidade que está diretamente ligada ao σ_i^2 , em que pode ser interpretada como uma medida suave do número efetivo de vizinhos relevantes.

De acordo com Maaten e Hinton (2008), a *perplexity* é definida por:

$$\text{Perp}(P_i) = 2^{H(P_i)}, \quad (2.24)$$

em que $H(P_i)$ representa a entropia de Shannon de P_i , dada por

$$H(P_i) = - \sum_j p_{j|i} \log_2 p_{j|i}. \quad (2.25)$$

2.4 Modelos Utilizados

2.4.1 GMM

O GMM, ou modelo de Mistura de Gaussianas, assume, conforme descrito em Papa (2021), que as observações são independentes e identicamente distribuídas e que podem ter sido gerados por uma mistura de K distribuições gaussianas. Cada componente da mistura representa uma parte da estrutura dos dados, e sua contribuição é controlada por um peso. Assim, a densidade total não é descrita por uma única gaussiana, mas por uma combinação ponderada de várias delas.

De modo geral, uma mistura de densidades pode ser escrita como:

$$p(\mathbf{x}|\Theta) = \sum_{k=1}^K w_k p(\mathbf{x}|\theta_k). \quad (2.26)$$

Nessa expressão, (w_k) representa o peso do (k) -ésimo componente da mistura. Já $p(\mathbf{x}|\theta_k)$ indica a densidade de probabilidade associada a esse componente, enquanto Θ representa o conjunto de parâmetros do modelo. Em termos práticos, o peso w_k indica a participação relativa de cada componente na formação da densidade total.

Para que essa mistura possa ser interpretada como uma função densidade de probabilidade, os pesos devem satisfazer duas condições. Eles não podem ser negativos e precisam somar 1. Portanto:

$$w_k \geq 0, \quad \sum_{k=1}^K w_k = 1. \quad (2.27)$$

Essas restrições garantem que a densidade resultante continue válida do ponto de vista probabilístico. Ou seja, a função assume apenas valores não negativos e sua integral, considerando todo o espaço amostral, é igual a (1).

No caso específico do GMM, cada componente da mistura é representado por uma distribuição normal multivariada e com isso, a densidade do modelo pode ser escrita como:

$$p(\mathbf{x}|\Theta) = \sum_{k=1}^K w_k \times \mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (2.28)$$

O conjunto de parâmetros do modelo reúne os pesos, os vetores de médias e as matrizes de covariância de cada componente. Assim:

$$\Theta = w_k, \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k. \quad (2.29)$$

Nessa notação, w_k é o peso da k -ésima componente, $\boldsymbol{\mu}_k$ representa seu vetor de médias e $\boldsymbol{\Sigma}_k$ representa sua matriz de covariância. Esses parâmetros definem não apenas a posição das componentes no espaço, mas também sua dispersão e orientação.

A distribuição normal multivariada associada a cada componente é dada por:

$$\mathcal{N}(\mathbf{x}|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) = \frac{1}{(2\pi)^{d/2}|\boldsymbol{\Sigma}_k|^{1/2}} \exp \left[-\frac{1}{2}(\mathbf{x} - \boldsymbol{\mu}_k)^T \boldsymbol{\Sigma}_k^{-1}(\mathbf{x} - \boldsymbol{\mu}_k) \right]. \quad (2.30)$$

Nessa equação, d indica a dimensão dos dados, $\boldsymbol{\mu}_k$ é o vetor de médias e $\boldsymbol{\Sigma}_k$ é a matriz de covariância da componente k . A presença da matriz de covariância é importante porque permite que cada componente represente diferentes formatos de dispersão no espaço dos dados.

A densidade da mistura descreve o comportamento global dos dados. No entanto ela não informa diretamente qual componente gaussiana foi responsável por gerar cada observação. Para representar essa informação não observada, introduz-se uma variável latente z_i , associada à observação $\mathbf{x}_i$. Essa variável indica a qual componente da mistura a observação está vinculada:

$$z_i \in 1, 2, \dots, K. \quad (2.31)$$

Na prática, observa-se apenas $\mathbf{x}_i$. O valor de z_i , por sua vez, permanece desconhecido. Por isso, z_i é chamada de variável latente. Ela existe na formulação do modelo, mas não aparece diretamente na base de dados.

Como não se sabe previamente qual componente gerou cada observação, o GMM estima essa relação de forma probabilística. Em vez de classificar cada ponto em apenas um grupo, o modelo calcula a probabilidade de esse ponto pertencer a cada componente da mistura. Essa probabilidade recebe o nome de responsabilidade. Formalmente:

$$\gamma_{ik} = P(z_i = k | \mathbf{x}_i, \Theta). \quad (2.32)$$

Aplicando o Teorema de Bayes, a responsabilidade da componente k pela observação $\mathbf{x}_i$ é dada por:

$$\gamma_{ik} = \frac{w_k \times \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k)}{\sum_{j=1}^K w_j \times \mathcal{N}(\mathbf{x}_i | \boldsymbol{\mu}_j, \boldsymbol{\Sigma}_j)}. \quad (2.33)$$

O valor de γ_{ik} indica o grau de associação da observação $\mathbf{x}_i$ com a componente k . Esse ponto diferencia o GMM de métodos de agrupamento rígido, como o k-médias porque Enquanto o k-médias força cada observação a pertencer a um único grupo, o GMM permite uma atribuição mais flexível, deste modo Uma mesma observação pode estar fortemente associada a uma componente e, ao mesmo tempo, manter alguma probabilidade de pertencer a outras.

Essa característica é relevante quando as fronteiras entre grupos não são bem definidas. Em dados financeiros, por exemplo, algumas transações podem apresentar comportamento intermediário. Nesses casos, uma classificação probabilística pode oferecer uma interpretação mais rica do que uma separação rígida.

As responsabilidades de todas as observações podem ser reunidas em uma matriz, chamada matriz de responsabilidades:

$$\mathbf{\Gamma} = \begin{bmatrix} \gamma_{11} & \gamma_{12} & \cdots & \gamma_{1K} \\ \gamma_{21} & \gamma_{22} & \cdots & \gamma_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ \gamma_{N1} & \gamma_{N2} & \cdots & \gamma_{NK} \end{bmatrix}. \quad (2.34)$$

Cada linha dessa matriz corresponde a uma observação, enquanto cada coluna corresponde a uma componente gaussiana. Assim, o elemento γ_{ik} informa a responsabilidade da componente k sobre a observação i . Dessa forma, a matriz $\mathbf{\Gamma}$ resume o grau de pertencimento de cada observação a cada componente do modelo. Ela também funciona como uma ponte entre os dados observados e a estrutura latente da mistura.

A densidade marginal de uma observação $\mathbf{x}_i$ é obtida somando-se sobre todos os possíveis valores da variável latente z_i . Assim:

$$p(\mathbf{x}_i|\Theta) = \sum_1^K p(\mathbf{x}_i, z_i = k|\Theta). \quad (2.35)$$

Pela regra do produto $p(A, B) = p(A|B) \times P(B)$, a probabilidade pode ser decomposta em duas partes:

$$p(\mathbf{x}_i, z_i = k|\Theta) \rightarrow p(\mathbf{x}_i|z_i = k, \Theta) \times p(z_i = k|\Theta). \quad (2.36)$$

No GMM, a probabilidade de uma observação pertencer ao componente (k), antes de observar seus valores, é dada pelo peso da mistura:

$$p(z_i = k|\Theta) \rightarrow w_k. \quad (2.37)$$

Além disso, ao condicionar a observação ao componente (k), assume-se que ela segue a distribuição gaussiana associada a esse componente:

$$p(\mathbf{x}_i|z_i = k, \Theta) \rightarrow \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (2.38)$$

Substituindo essas relações, chega-se à densidade marginal da observação:

$$p(\mathbf{x}_i|\Theta) = \sum_{k=1}^K w_k \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (2.39)$$

Essa expressão mostra que cada observação é avaliada em relação a todas as componentes gaussianas, e não apenas em relação a uma delas. A densidade final é resultado da soma das contribuições de cada componente, ponderadas pelos pesos da mistura.

Considerando agora um conjunto de dados com (N) observações independentes e identicamente distribuídas, denotado por $\mathbf{X} = \mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_N$, a função de verossimilhança é dada pelo produto das densidades marginais de todas as observações:

$$p(\mathbf{X}|\Theta) = \prod_{i=1}^N \sum_{k=1}^K w_k \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k). \quad (2.40)$$

Aplicando o logaritmo nessa expressão, obtém-se a log-verossimilhança:

$$\mathcal{L}(\Theta) = \sum_{i=1}^N \log \left[\sum_{k=1}^K w_k \mathcal{N}(\mathbf{x}_i|\boldsymbol{\mu}_k, \boldsymbol{\Sigma}_k) \right]. \quad (2.41)$$