

Estimar os parâmetros do GMM significa encontrar os valores de w_k , μ_k e Σ_k que maximizam essa log-verossimilhança. A ideia é escolher os parâmetros que tornam os dados observados mais prováveis segundo o modelo. Apesar disso, a otimização não é direta. O obstáculo aparece porque o logaritmo envolve uma soma de componentes gaussianas, o que impede separar facilmente a contribuição individual de cada componente.

Para lidar com essa dificuldade, utiliza-se o algoritmo de Maximização da Expectativa, conhecido em inglês como *Expectation-Maximization* (EM). O algoritmo funciona de forma iterativa. Primeiro, na etapa E, calculam-se as responsabilidades, ou seja, as probabilidades de pertencimento de cada observação a cada componente. Depois, na etapa M, os parâmetros do modelo são atualizados usando essas responsabilidades como base.

Esse ciclo se repete até que a log-verossimilhança apresente convergência ou até que algum critério de parada seja satisfeito. Com isso, o EM permite ajustar o modelo de Mistura de Gaussianas mesmo quando existem variáveis latentes não observadas, como z_i . No contexto deste trabalho, essa formulação é importante porque permite analisar os dados de maneira probabilística, sem obrigar que cada observação pertença exclusivamente a um único padrão.

2.5 Seleção de Features

2.5.1 Motivação

A seleção de variáveis é uma etapa importante em problemas de aprendizado de máquina, análise estatística e visualização de dados, principalmente quando a base possui muitas variáveis explicativas. Em conjuntos multidimensionais, nem todas as variáveis ajudam da mesma forma na identificação de padrões, algumas carregam pouca informação, outras repetem sinais já presentes em variáveis correlacionadas e há aquelas que acabam colocando ruído no processo de modelagem.

No contexto deste trabalho, essa etapa ganha importância porque o objetivo não se limita à detecção de fraudes, mas também se busca construir visualizações em duas e três dimensões, por isso, escolher variáveis, ou combinações de variáveis, com maior capacidade de separação entre transações normais e fraudulentas pode facilitar a leitura gráfica dos dados e destacar regiões associadas a possíveis anomalias.

Além disso, uma boa seleção pode melhorar o desempenho computacional, reduzir a complexidade da análise e tornar os resultados mais interpretáveis. Em modelos como o GMM, variáveis pouco informativas ou muito correlacionadas podem dificultar a estimação das componentes gaussianas e prejudicar a identificação de estruturas relevantes nos dados.

Assim, antes da aplicação final dos modelos, este trabalho considera uma etapa de seleção e avaliação de variáveis, buscando subconjuntos que favoreçam tanto a modelagem

quanto a clareza das visualizações.

2.5.2 Métricas Analíticas de Avaliação

2.5.2.1 AUC-PR

Em detecção de fraudes, a classe positiva corresponde às transações fraudulentas, que são o principal interesse da análise. A classe negativa corresponde às transações não fraudulentas.

Quando o modelo classifica uma transação como fraude e ela realmente é fraude, tem-se um verdadeiro positivo (VP). Quando o modelo classifica uma transação como fraude, mas ela não é fraude, tem-se um falso positivo (FP). Já quando uma transação é fraude, mas o modelo a classifica como não fraude, tem-se um falso negativo (FN).

Com esses valores, calculam-se a precisão e a revocação. A precisão mede, entre todas as observações classificadas como positivas, quantas realmente pertencem à classe positiva. Neste trabalho, isso significa verificar, entre todas as transações apontadas como fraude, quantas de fato são fraudulentas:

$$Precisao = \frac{VP}{VP + FP}. \quad (2.42)$$

A revocação, também chamada de sensibilidade, mede, entre todas as observações realmente positivas, quantas foram corretamente identificadas. No caso da detecção de fraudes, indica quantas fraudes reais foram encontradas:

$$Revocacao = \frac{VP}{VP + FN}. \quad (2.43)$$

A precisão está ligada à qualidade dos alertas gerados pelo modelo, enquanto a revocação está associada à capacidade de encontrar as fraudes existentes. Uma precisão alta indica poucos alertas falsos; uma revocação alta indica poucas fraudes não detectadas.

Muitos modelos não produzem diretamente uma classe final, mas sim uma probabilidade associada à classe positiva. Esse é o caso de modelos probabilísticos, como o GMM. Para transformar essa probabilidade em classificação binária, define-se um limiar de decisão, também chamado de ponto de corte, ou *classification threshold*. Para um limiar t , a classe predita pode ser escrita como:

$$\hat{y}_i(t) = \begin{cases} 1, & \text{se } s_i \geq t, \\ 0, & \text{se } s_i < t. \end{cases} \quad (2.44)$$

em que s_i representa a probabilidade atribuído pelo modelo à observação i , e $\hat{y}_i(t)$ representa a classe predita a partir do limiar (t). O valor 1 indica fraude, enquanto 0 indica não fraude.

A escolha do limiar influencia diretamente a precisão e a revocação. Um limiar mais baixo tende a classificar mais observações como fraude, aumentando a chance de detectar fraudes reais, mas também elevando falsos positivos. Já um limiar mais alto gera menos alertas e pode aumentar a precisão, mas algumas fraudes podem passar despercebidas.

A curva Precisão-Revocação é construída variando esse limiar. Para cada valor de t , calcula-se um par formado pela revocação e pela precisão:

$$(Revocação(t), Precisão(t)). \quad (2.45)$$

Graficamente, a revocação fica no eixo horizontal e a precisão no eixo vertical. Cada ponto da curva mostra o desempenho do modelo para um determinado limiar.

A AUC-PR corresponde à área sob essa curva. Ela resume, em um único valor, a capacidade do modelo de manter bons níveis de precisão e revocação ao longo de diferentes limiares. Em geral, quanto maior a AUC-PR, melhor é o desempenho na identificação da classe positiva.

Como precisão e revocação variam entre 0 e 1, a AUC-PR também assume valores nesse intervalo:

$$0 \leq AUC-PR \leq 1. \quad (2.46)$$

Um valor igual a 1 representa o caso ideal, em que o modelo separa perfeitamente as classes. Valores menores indicam menor capacidade de separação entre a classe positiva e a negativa.

Na prática, a curva Precisão-Revocação é construída empiricamente a partir das probabilidades produzidas pelo modelo. O algoritmo avalia diferentes limiares, calcula precisão e revocação em cada ponto e forma a curva.

Neste trabalho, a AUC-PR é usada para avaliar variáveis e combinações de variáveis na etapa de seleção. Combinações com maiores valores de AUC-PR são consideradas mais adequadas, pois indicam maior capacidade de identificar transações fraudulentas mantendo bom equilíbrio entre precisão e revocação.

2.5.2.2 Coeficiente De Correlação De Matthews

O Coeficiente de Correlação de Matthews, conhecido como MCC, é uma métrica utilizada para avaliar modelos de classificação binária. Ele considera todos os elementos

da matriz de confusão: verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos. Por isso, costuma oferecer uma visão mais equilibrada do desempenho do modelo.

Em problemas de classificação, a matriz de confusão permite comparar as classes reais com as classes preditas. O MCC foi originalmente proposto por Matthews (1975) e pode ser interpretado como uma medida de correlação entre essas duas informações. Sua fórmula é:

$$MCC = \frac{VP \cdot VN - FP \cdot FN}{\sqrt{(VP + FP)(VP + FN)(VN + FP)(VN + FN)}}. \quad (2.47)$$

O valor do MCC varia entre -1 e 1 . Um valor igual a 1 indica classificação perfeita. Um valor igual a 0 indica ausência de correlação entre previsões e classes reais, representando desempenho semelhante ao aleatório. Já um valor igual a -1 indica classificação completamente invertida.

Essa métrica é especialmente útil em bases desbalanceadas. Em problemas de fraude, a classe de interesse costuma ser muito menor do que a classe majoritária. O MCC considera simultaneamente o desempenho nas classes positiva e negativa, penalizando classificações desequilibradas e fornecendo uma medida mais robusta do desempenho global.

2.5.2.3 Log Loss

De acordo com Filho (2023), “Log loss (ou perda logarítmica) é uma métrica de avaliação de modelos de classificação em machine learning, tanto binários quanto multiclasse”.

Diferentemente de métricas baseadas apenas na classe final predita, a *Log Loss* considera o grau de confiança atribuído à classe correta. Modelos que atribuem alta probabilidade à classe correta recebem perdas menores. Quando o modelo atribui baixa probabilidade à classe correta, a penalização aumenta.

Em classificação probabilística, é comum que o modelo produza, para cada observação, uma probabilidade associada à classe positiva. Neste trabalho, considerando fraude como classe positiva, seja p_i a probabilidade estimada de que a observação i pertença à classe fraudulenta, e seja y_i a classe real, com $y_i = 1$ para fraude e $y_i = 0$ para não fraude. A *Log Loss* binária é definida por:

$$LogLoss = -\frac{1}{n} \sum_{i=1}^n [y_i \ln(p_i) + (1 - y_i) \ln(1 - p_i)], \quad (2.48)$$

em que n representa o número total de observações e $\ln$ representa o logaritmo natural.

Essa expressão pode ser entendida separando os dois casos possíveis. Quando a observação pertence à classe positiva, isto é, $y_i = 1$, a perda individual é:

$$LogLoss_i = -\ln(p_i). \quad (2.49)$$

Nesse caso, quanto maior a probabilidade atribuída à classe correta, menor será a perda. Se o modelo atribuir probabilidade muito baixa a uma fraude real, a penalização será alta.

Quando a observação pertence à classe negativa, isto é, $y_i = 0$, a perda individual é:

$$LogLoss_i = -\ln(1 - p_i). \quad (2.50)$$

Nesse caso, $1 - p_i$ representa a probabilidade estimada de a observação pertencer à classe não fraudulenta. Assim, a *Log Loss* avalia se o modelo atribuiu alta probabilidade à classe correta, seja ela positiva ou negativa.

A *Log Loss* assume valores não negativos, e valores menores indicam melhor desempenho. O mínimo é 0, obtido quando o modelo atribui probabilidade 1 para a classe correta em todas as observações. Por outro lado, quando o modelo atribui probabilidade próxima de zero à classe correta, a perda cresce rapidamente.

2.5.3 Métricas Gráficas De Avaliação

2.5.3.1 Boxplot

Segundo Tukey (1977), o *box-and-whisker plot*, mais usualmente chamado por boxplot, é uma representação gráfica baseada em medidas resumo de um conjunto de dados, especialmente os extremos, a mediana e os quartis. A caixa representa o intervalo entre os quartis, enquanto a mediana é indicada por uma linha interna, permitindo visualizar de forma sintética a posição, a dispersão e possíveis valores extremos da distribuição.

Usar essa ferramenta pode ser muito útil pois se avalia as diferenças entre as variáveis e a quantidade de outliers nelas, ajudando a ter uma primeira impressão da capacidade de separação.

2.5.3.2 Matriz De Confusão

A matriz de confusão é um recurso clássico para mapear o desempenho de modelos de classificação, cruzando as classes reais com as previsões feitas pelo algoritmo. Como

apontado por IBM (2024c), ela facilita o diagnóstico do modelo ao organizar os acertos e erros em uma estrutura prática e visualizável.

Em cenários de classificação binária onde lidamos com apenas duas respostas possíveis, costuma-se convencionar uma delas como a classe positiva e a outra como a negativa. A partir daí, a matriz estrutura quatro métricas fundamentais: os verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos.

Essa estrutura pode ser representada da seguinte forma:

	Predito Negativo	Predito Positivo
Real Negativo	VN	FP
Real Positivo	FN	VP

(2.51)

Nessa matriz, VP representa os verdadeiros positivos; VN , os verdadeiros negativos; FP , os falsos positivos; e FN , os falsos negativos.

2.5.3.3 Matriz De Correlação De Spearman

Para entender a força da associação entre pares de variáveis, recorreremos à matriz de correlação de Spearman. Diferente do coeficiente de Pearson, que foca estritamente em relações lineares, o método de Spearman avalia relações monotônicas. Como o cálculo se baseia nos postos (ranques) dos valores observados, a métrica se torna bem mais robusta contra distribuições não normais e *outliers*.

O coeficiente de correlação de Spearman entre duas variáveis X e Y é denotado por ρ_s e varia no seguinte intervalo:

$$-1 \leq \rho_s \leq 1. \quad (2.52)$$

Resultados próximos de 1 indicam uma forte associação monotônica positiva (quando uma variável cresce, a outra tende a acompanhar). Valores perto de -1 apontam para uma forte associação negativa (o crescimento de uma implica no decréscimo da outra). Já os valores que orbitam o 0 sugerem que não há uma dependência monotônica expressiva entre elas.

No processo de seleção de atributos, essa matriz ajuda a detectar redundâncias. Quando duas variáveis apresentam uma alta correlação em módulo, significa que compartilham praticamente a mesma informação. Manter ambas pode inflar o modelo sem necessidade e prejudicar sua interpretabilidade. Em contrapartida, correlações baixas indicam que as variáveis trazem perspectivas diferentes e complementares para a análise.

Para um conjunto amplo de variáveis $\{X_1, X_2, \dots, X_p\}$, a matriz de correlação de Spearman é estruturada como: