

Esse conjunto traz o histórico de transações financeiras feitas por cartões de crédito na Europa durante o mês de setembro de 2013. Trata-se de um retrato de dois dias de operações, que carrega o desafio do mundo real: o registro misto de compras legítimas e fraudes confirmadas. Por ser uma base de acesso público e amplamente consagrada pela comunidade científica, ela funciona como um excelente *benchmark*, permitindo que os resultados conversem diretamente com a literatura internacional sobre o tema.

3.3.2 Descrição da base

A estrutura dos dados funciona como uma grande planilha onde cada linha representa uma transação comercial isolada e as colunas revelam os detalhes técnicos daquela operação. Ao todo, lidamos com um universo de 284.807 registros. O grande desafio analítico aqui é o desbalanceamento desse cenário: desse montante massivo de dados, apenas 492 são transações fraudulentas confirmadas.

O vetor de características que descreve cada transação é composto pelas colunas originais *Time*, *Amount*, a variável resposta *Class*, além de 28 atributos numéricos identificados de *V1* a *V28*.

A variável *Class* funciona como a variável alvo do inglês, *target*, assumindo o valor 0 quando a transação é perfeitamente legítima e 1 quando é uma fraude. Um detalhe importante sobre as colunas de *V1* a *V28* é que elas não revelam as informações comerciais puras, como nome do estabelecimento ou dados do cliente; por questões de segurança e privacidade da empresa e de seus usuários, esses dados passaram por uma transformação matemática via (PCA) antes de se tornarem públicos. Fechando o conjunto, a variável *Time* mede o tempo em segundos decorrido entre a transação atual e o primeiro registro do histórico, e a *Amount* indica o valor monetário movimentado na transação.

3.3.3 Processo de Extração, Transformação e Carga dos Dados

Antes de submeter os dados aos algoritmos de seleção de variáveis, redução de dimensionalidade e modelagem, foi necessário estruturar a esteira de Extração, Transformação e Carga, amplamente conhecida pela sigla ETL Extract, Transform and Load. O objetivo central dessa engrenagem é organizar, sanear e preparar o banco de dados bruto, deixando-o no formato ideal para as análises estatísticas e o treinamento dos classificadores.

A etapa de extração consistiu no resgate da base de dados em formato CSV, disponível publicamente na plataforma Kaggle. Após o *download*, o arquivo original foi importado para o ambiente Python, permitindo o mapeamento inicial de todas as observações e variáveis disponíveis.

Na fase de transformação, foram conduzidas as primeiras auditorias na estrutura dos dados, checando as dimensões da base, a tipagem das variáveis, a existência de valores

ausentes, a contagem de registros únicos e a distribuição da variável resposta. Para tornar a interpretação dos resultados mais intuitiva, algumas colunas estratégicas foram renomeadas: a variável *Time* passou a se chamar *tempo_desde_a_primeira_transacao*; *Amount* foi traduzida como *valor_de_transacao*; e a variável alvo *Class* foi convertida em *status_fraude*.

Ainda nessa etapa de higienização, removeu-se o excedente de linhas duplicadas, preservando apenas uma ocorrência única de cada registro, além de descartar linhas com eventuais dados faltantes. Eliminar essas inconsistências é um passo crítico na modelagem, pois evita distorções matemáticas nas análises descritivas, atenua redundâncias na base e assegura que os algoritmos operem apenas com dados completos e íntegros.

Na sequência, realizou-se a separação clássica entre a matriz de variáveis explicativas e o a variável que é um vetor de respostas. Os atributos foram reservados para alimentar as etapas subsequentes de seleção, projeção e modelagem, ao passo que o vetor *status_fraude* foi guardado para atuar como o gabarito de avaliação do desempenho dos modelos.

Finalmente, a etapa de carga organizou os dados já tratados em estruturas de dados otimizadas para processamento em memória, como matrizes estruturadas e vetores de rótulos. Concluído o tratamento, essa nova base consolidada foi exportada para um novo arquivo intitulado *creditcard.csv*, que serviu de matéria-prima para o restante do estudo.

O processo de ETL cumpriu, assim, o seu papel fundamental: garantir a consistência, a organização e o alinhamento dos dados para as fases analíticas do projeto, minimizando ruídos e blindando a reprodutibilidade de todo o fluxo metodológico.

Tabela 3 – Resumo do processo inicial de ETL

Etapa	Quantidade antes	Quantidade depois
Colunas da base	31 colunas	31 colunas
Remoção de duplicatas	284.807 linhas	283.726 linhas
Remoção de dados faltantes	283.726 linhas	283.726 linhas
Base final tratada	284.807 linhas	283.726 linhas

Fonte: Elaborado pelo autor.

3.3.4 Estrutura das variáveis

Após a consolidação da base no ambiente Python, realizou-se um mapeamento detalhado da arquitetura das variáveis, identificando a tipagem de dados alocada para cada coluna. Essa verificação é um pré-requisito indispensável para entender como os recursos são interpretados computacionalmente e assegurar que as variáveis numéricas e categóricas estejam nos formatos exigidos pelas rotinas de pré-processamento e modelagem.

Tabela 4 – Estrutura das variáveis da base de dados

Variável	Tipo	Não nulos	Nulos	% nulos	Valores únicos	Memória (MB)
V1 a V28	float64	283.726	0	0,0%	275.663	2,1647
tempo_desde_a_primeira_transacao	float64	283.726	0	0,0%	124.592	2,1729
valor_de_transacao	float64	283.726	0	0,0%	32.767	2,1647
status_fraude	int64	283.726	0	0,0%	2	2,1647

Fonte: Elaborado pelo autor.

A métrica **Tipo** aponta a classe primitiva reconhecida pelo Python, o formato `float64` denota variáveis numéricas contínuas armazenadas com alta precisão de casas decimais, ao passo que o `int64` indica variáveis do tipo inteiro, com isso, constata-se que todos os atributos preditivos entraram no sistema como valores contínuos, enquanto o rótulo `status_fraude` foi assimilado como um número inteiro, condizente com sua natureza discreta que assume apenas as respostas 0 ou 1.

As colunas **Não nulos** e **Nulos** confirmam a completude do banco de dados pós-higienização. Como todas as variáveis exibem rigorosamente 283.726 registros válidos e nenhuma lacuna vazia, confirma-se o sucesso do descarte de dados omissos na fase de ETL.

A coluna **Valores únicos** reflete a grande quantidade de valores distintos observada de V1 a V28 que ratifica seu caráter contínuo. Em contrapartida, a variável `status_fraude` condensa apenas dois valores únicos, o que corrobora matematicamente a estrutura de uma classificação binária pura, garantindo que o rótulo não carregue ruídos ou classificações espúrias.

Por fim, o campo **Memória (MB)** rastreia a pegada de armazenamento físico em megabytes que cada variável consome no Python. Esse monitoramento é essencial para antecipar o estresse computacional e otimizar o consumo de *hardware*, principalmente nas rotinas que realizam buscas combinatórias exaustivas ou iterações pesadas em matrizes de alta dimensão.

3.3.5 Padronização dos dados

Antes de aplicar os modelos estatísticos e as técnicas de projeção espacial, as variáveis preditivas precisam ser submetidas a um processo de padronização, trazendo todas para uma mesma escala de grandeza, essa etapa é mandatória porque a grande maioria dos algoritmos de aprendizado de máquina e modelagem estatística é altamente sensível à escala dos dados de entrada. Atributos com ordens de magnitude muito discrepantes tendem a enviesar os cálculos que envolvem distâncias, covariâncias, densidades ou variâncias, conferindo um peso artificial e desproporcional a certas variáveis e prejudicando a estabilidade do modelo.

Neste trabalho, a harmonização das escalas utilizou o módulo `StandardScaler` da

biblioteca *scikit-learn*. Segundo as especificações técnicas do pacote, essa rotina opera centrando a média das variáveis em zero e escalonando os dados de forma a obter uma variância unitária (Scikit-learn developers, 2026b).

A transformação é executada de forma independente em cada coluna preditiva. Esse cuidado preserva as distribuições relativas originais de cada recurso, mas neutraliza os abismos de escala entre variáveis distintas, um passo vital para o bom funcionamento do PCA, t-SNE e do Modelo de Mistura Gaussiana (GMM).

Para garantir o rigor metodológico e blindar contra o vazamento de informações do inglês *data leakage*, os parâmetros de padronização são calibrados estritamente com os dados destinados ao treinamento. As estatísticas de média e desvio padrão resultantes desse primeiro ajuste são salvas e aplicadas de forma passiva para transformar os dados de validação e teste. Esse protocolo segue rigidamente o fluxo operacional do **StandardScaler**, que mapeia as propriedades dos dados por meio do método **fit** e estende essa mesma régua matemática aos demais subconjuntos utilizando o método **transform** (Scikit-learn developers, 2026a).

A padronização consolida-se, portanto, como uma etapa de infraestrutura analítica indispensável, assegurando a comparabilidade justa entre os recursos e estabilizando o comportamento dos estimadores que virão adiante.

3.4 Divisão da base de dados

O ciclo de vida dos dados foi planejado e segmentado para atender aos requisitos específicos de cada etapa da pesquisa. Num primeiro momento, a base completa e saneada serviu de insumo para as análises descritivas e mapeamentos visuais. Posteriormente, para as rodadas de modelagem definitiva e homologação dos classificadores, adotará-se um protocolo de divisão estratificada, garantindo a manutenção exata das proporções das classes e mitigando vieses de validação.

3.4.1 Uso da base completa para análise exploratória e seleção visual de variáveis

A base de dados integral depois do fim ETL funcionou como o ponto de partida para a análise exploratória e para a geração dos primeiros mapas visuais, essa estratégia de olhar para o conjunto completo de dados justifica-se pela necessidade de obter um panorama abrangente sobre a distribuição dos recursos, identificar possíveis padrões geométricos naturais e mensurar a escala real do desbalanceamento entre as operações normais e os episódios de fraude.

Durante essa sondagem, o volume total de dados sustentou o cálculo de estatísticas

descritivas, tabelas de distribuição de frequência, diagramas de boxplot, e matrizes de correlação.

Além de abrir caminhos na exploração inicial, a base completa também deu suporte ao processo de seleção de variáveis, esse filtro preliminar teve como objetivo detectar quais variáveis e combinações de variáveis possuíam a maior capacidade de gerar projeções gráficas interpretáveis, tanto ao analisar o espaço original reduzido via PCA quanto ao estudar as coordenadas de baixa dimensão geradas pelo t-SNE.

3.4.2 Divisão para modelagem final por *holdout* estratificado

Para a etapa de modelagem definitiva e homologação dos resultados, a estratégia escolhida para gerenciar os dados foi o método conhecido na literatura como *holdout*.

Esse procedimento consiste em segmentar a base original em subconjuntos disjuntos e mutuamente exclusivos. Uma parte dos dados é destinada exclusivamente ao desenvolvimento e ajuste fino dos algoritmos, enquanto a parcela restante é rigidamente preservada para a validação final.

De acordo com Kohavi (1995), uma prática comum é reservar cerca de $(2/3)$ dos dados para treinamento e $(1/3)$ para teste. O autor enfatiza também que o método *holdout* pode produzir uma estimativa pessimista do desempenho retratado, pois apenas uma fração da base é, de fato, entregue ao indutor durante a fase de treinamento. Mesmo assim, separar os dados entre treino e avaliação é uma prática que proporciona uma estimativa mais honesta da capacidade de generalização do modelo face a observações que não foram utilizadas no ajuste.

No escopo deste trabalho, implementará-se o *holdout* estratificado. Essa variação do *holdout* tradicional garante que cada um dos subconjuntos gerados mantenha exatamente a mesma proporção entre transações legítimas e fraudulentas observada na base original. Trata-se de um cuidado metodológico vital ao lidar com dados severamente desbalanceados pois impede que a divisão aleatória crie subconjuntos distorcidos, desprovidos de amostras da classe minoritária.

A divisão estratificada blinda a modelagem final, assegurando que o veredito sobre a eficiência dos algoritmos ocorra em um ambiente de testes puro. Esse isolamento neutraliza o risco de sobreajuste, em inglês *overfitting* e fornece métricas realistas sobre como o classificador se comportará ao processar transações que ele nunca viu.