

3.5 Seleção de variáveis

3.5.1 Objetivo

Neste estudo, o processo de seleção de variáveis foi conduzido sob duas perspectivas complementares. A primeira delas é orientada à interpretação visual, buscando extrair um conjunto enxuto de atributos capaz de gerar representações gráficas claras e inteligíveis, isso tanto no espaço original transformado por PCA quanto nas projeções de baixa dimensão geradas pelo t-SNE. A segunda vertente foca estritamente no poder preditivo da modelagem final, onde os subconjuntos de variáveis são selecionados e testados por meio de métricas quantitativas, sem qualquer restrição quanto ao volume de atributos utilizados.

O fluxo de triagem segue uma lógica sistemática: para cada subconjunto de variáveis testado, o modelo era ajustado e suas respectivas métricas de desempenho eram calculadas. Na sequência, esses indicadores eram normalizados para uma escala comum e combinados em um índice sintético *score* final. Os arranjos que alcançaram as maiores pontuações foram promovidos para as etapas posteriores de análise e treinamento.

3.5.2 Critério de seleção

O critério para avaliar o potencial de cada variável baseou-se em um *score* composto por três métricas quantitativas distintas. A meta desse índice unificado foi fundir diferentes dimensões do desempenho do classificador em uma única métrica padronizada, permitindo um ranqueamento justo e direto de todos os subconjuntos candidatos.

O *score* combinou a AUC-PR, o MCC e a Log Loss. Essas três métricas foram escolhidas por cobrirem facetas perfeitamente complementares da eficiência de um modelo.

A AUC-PR mediu a capacidade geral das responsabilidades calculadas pelo modelo em segregar a classe positiva da negativa ao longo de toda a variação dos limiares de decisão. Como essa métrica, por definição, já transita naturalmente no intervalo entre 0 e 1, ela foi integrada diretamente à fórmula do *score*:

$$AUC-PR_{norm} = AUC-PR. \quad (3.1)$$

O MCC foi convocado para auditar o equilíbrio da classificação binária, pesando em uma mesma equação os verdadeiros positivos, verdadeiros negativos, falsos positivos e falsos negativos. Dado que o MCC original oscila entre -1 (discordância total) e 1 (classificação perfeita), aplicou-se uma transformação linear para transportá-lo de forma justa para a régua de 0 a 1:

$$MCC_{norm} = \frac{MCC + 1}{2}. \quad (3.2)$$

Com essa calibração, os cenários onde $MCC = -1$, $MCC = 0$ e $MCC = 1$ passaram a equivaler, respectivamente, a $MCC_{norm} = 0$, $MCC_{norm} = 0,5$ e $MCC_{norm} = 1$. Vale destacar que essa abordagem também foi utilizada para rastrear o ponto de corte ideal com base nos critérios intrínsecos do próprio MCC.

Por fim, a Log Loss avaliou a qualidade e a calibração das probabilidades estimadas pelo modelo. Ao contrário da AUC-PR e do MCC, a Log Loss é uma métrica de erro, o que significa que quanto menor o seu valor, melhor é a previsão do algoritmo. Para que ela pudesse somar forças com as outras métricas em uma escala ascendente onde números maiores indicam maior qualidade foi necessário inverter a sua lógica matemática. Tomando como referência os limites mínimos e máximos observados em todos os testes, a normalização invertida foi estruturada da seguinte forma:

$$LogLoss_{padrao} = \frac{LogLoss_{max} - LogLoss}{LogLoss_{max} - LogLoss_{min}}. \quad (3.3)$$

Nessa equação, $LogLoss$ representa a perda logarítmica do subconjunto sob análise, enquanto $LogLoss_{min}$ e $LogLoss_{max}$ delimitam o melhor e o pior caso registrados em todo o experimento, respectivamente. Graças a essa transformação, o arranjo com a menor perda recebe uma nota próxima de 1, enquanto aquele com o pior erro é penalizado com uma nota perto de 0.

Essa inversão garantiu que todas as métricas passassem a apontar para o mesmo norte de otimização, ou seja:

$$LogLoss_{padrao} \approx 1 \quad \Rightarrow \quad \text{melhor desempenho}, \quad (3.4)$$

$$LogLoss_{padrao} \approx 0 \quad \Rightarrow \quad \text{pior desempenho}. \quad (3.5)$$

Para blindar o sistema contra instabilidades numéricas que pudessem empurrar o cálculo para fora do intervalo $[0, 1]$, impôs-se um teto e um piso matemáticos à função. Desse modo, qualquer resultado inferior a 0 foi fixado em 0, e qualquer valor acima de 1 foi limitado a 1:

$$LogLoss_{norm} = \min(1, \max(0, LogLoss_{padrao})). \quad (3.6)$$

3.5.3 Construção do score de avaliação e rankeamento

Com as três métricas dentro do intervalo de 0 a 1, o passo seguinte foi consolidar o *score* final de avaliação. Esse índice unificado cumpre o papel prático de resumir a qualidade

de cada variável ou subconjunto em um único indicador, viabilizando um ranqueamento padronizado de todos os candidatos.

Dada a uniformidade das escalas, tornou-se metodologicamente viável combiná-las diretamente por meio de uma média aritmética simples. Assim cada subconjunto foi definido por:

$$Score(\mathcal{S}) = \frac{AUC-PR_{norm}(\mathcal{S}) + MCC_{norm}(\mathcal{S}) + LogLoss_{norm}(\mathcal{S})}{3}, \quad (3.7)$$

onde $\mathcal{S}$ representa a variável ou o subconjunto de variáveis sendo julgado.

Nesta arquitetura, optou-se por atribuir pesos idênticos a cada um dos componentes. Essa escolha se justifica pelo fato de que cada indicador audita uma dimensão totalmente independente da performance do classificador: a AUC-PR afere a capacidade global de ordenação dos scores ao longo de múltiplos limiares; o MCC valida o equilíbrio da matriz de confusão para uma classificação binária estrita; e a Log Loss pune o excesso de confiança em diagnósticos errados, avaliando a calibração probabilística.

Distribuir pesos iguais foi a estratégia adotada para evitar que uma única métrica canibalizasse as outras, garantindo que o valor final reflita um equilíbrio perfeito entre o poder de ranqueamento, a precisão da classificação e a qualidade das probabilidades estimadas.

Calculados os índices, os subconjuntos foram organizados em ordem decrescente. O topo do *ranking* aponta diretamente o arranjo de variáveis que alcançou a melhor sinergia e equilíbrio do estudo, enquanto a base da lista expõe as combinações de menor eficiência relativa.

3.5.4 Aplicação da GSFS

Após a definição do critério de seleção e da construção do score de avaliação, será aplicada a Seleção Sequencial Progressiva Generalizada. O objetivo dessa etapa é encontrar subconjuntos de variáveis que apresentem melhor desempenho para modelagem.

A seleção será feita com base na divisão por *holdout* estratificado definida anteriormente. Assim, os subconjuntos de variáveis serão avaliados sem utilizar o conjunto de teste final. Esse cuidado é importante, pois o teste deve permanecer reservado apenas para a avaliação final dos modelos, evitando que informações dessa etapa influenciem as escolhas realizadas durante a seleção.

A GSFS será aplicada em diferentes níveis de generalização, representados por r . Esse parâmetro indica quantas variáveis entram simultaneamente em cada etapa do processo. Neste trabalho, serão realizadas rodadas independentes com os seguintes valores:

$$r \in 1, 2, 3, 5. \quad (3.8)$$

Com isso, serão testadas seleções em que as variáveis entram uma a uma, duas a duas e três a três e cinco a cinco. Em cada rodada, o algoritmo avalia grupos de r variáveis ainda não selecionadas e calcula o score do subconjunto formado pela união entre o que já foi escolhido e o novo grupo candidato.

Para cada valor de r , o processo começa com um conjunto vazio de variáveis selecionadas:

$$\mathcal{S}_0 = \emptyset. \quad (3.9)$$

Em uma etapa genérica t , são formados grupos candidatos $\mathcal{G}_r$, compostos por r variáveis que ainda não foram selecionadas:

$$\mathcal{G}_r \subseteq \mathcal{X} \setminus \mathcal{S}_t, \quad |\mathcal{G}_r| = r. \quad (3.10)$$

Cada grupo candidato é combinado ao subconjunto já selecionado, formando um novo subconjunto de avaliação:

$$\mathcal{C} = \mathcal{S}_t \cup \mathcal{G}_r. \quad (3.11)$$

Para cada subconjunto candidato $\mathcal{C}$, o modelo será ajustado e serão calculadas as métricas AUC-PR, MCC normalizado e Log Loss normalizada. Depois disso, essas métricas serão combinadas no score final de avaliação. O grupo escolhido em cada etapa será aquele que apresentar o maior score:

$$\mathcal{G}_r^* = \arg \max_{\substack{\mathcal{G}_r \subseteq \mathcal{X} \setminus \mathcal{S}_t \\ |\mathcal{G}_r| = r}} \text{Score}(\mathcal{S}_t \cup \mathcal{G}_r). \quad (3.12)$$

Após a escolha do melhor grupo, o subconjunto selecionado é atualizado por:

$$\mathcal{S}_{t+1} = \mathcal{S}_t \cup \mathcal{G}_r^*. \quad (3.13)$$

Esse procedimento será repetido para cada valor de r . Ao final de cada rodada, serão armazenados os subconjuntos avaliados, seus respectivos scores e a posição de cada subconjunto no ranqueamento. Dessa forma, será possível comparar os resultados obtidos em diferentes níveis de generalização da GSFS.

Após a execução das rodadas, os subconjuntos resultantes serão comparados pelo score final. O subconjunto com maior score geral será selecionado como o mais adequado para as etapas posteriores de modelagem e avaliação.

A aplicação da GSFS permite avaliar não apenas variáveis isoladas, mas também grupos de variáveis com tamanhos diferentes. Isso é relevante porque algumas variáveis podem não se destacar quando analisadas sozinhas, mas passam a contribuir de forma mais clara quando aparecem junto de outras. Além disso, a comparação entre diferentes valores de r permite observar se grupos maiores melhoram ou prejudicam o desempenho de acordo com o critério adotado.

3.5.5 Definição do Número de Variáveis Selecionadas

A definição do número de variáveis selecionadas depende da finalidade de cada etapa da análise. Para as representações gráficas, esse número será determinado pela própria dimensão da visualização desejada. Já na modelagem final, a quantidade de variáveis será definida posteriormente, com base no melhor resultado obtido pela GSFS.

3.6 Redução de Dimensionalidade

3.6.1 Aplicação do PCA

A base de dados utilizada neste trabalho já possui parte de suas variáveis transformadas previamente por PCA. Mais especificamente, as variáveis ($V1, V2, \dots, V28$) correspondem a componentes principais obtidos a partir das variáveis originais. Essas variáveis originais não foram disponibilizadas por questões de confidencialidade.

Por esse motivo, as variáveis ($V1$) a ($V28$) não representam diretamente características brutas das transações, elas são combinações lineares resultantes da aplicação prévia do PCA. Esse ponto precisa ser levado em conta na interpretação dos resultados, pois essas variáveis preservam informação estatística dos dados originais, mas não possuem uma leitura direta em termos das características reais das transações.

As variáveis que não passaram por essa transformação na base original são `tempo_desde_a_primeira_transacao` e `valor_de_transacao`.

Neste trabalho, a aplicação do PCA será considerada a partir dessa estrutura da base. Como as variáveis $V1$ a $V28$ já correspondem a componentes principais, elas serão tratadas como variáveis numéricas provenientes de uma redução de dimensionalidade anterior, quando novas transformações por PCA forem aplicadas ao longo da metodologia, elas serão utilizadas apenas em etapas específicas de transformações e modelagem.