

3.6.2 Aplicação do t-SNE

Para além das coordenadas geradas pela PCA, esta pesquisa incorpora a técnica T-SNE com o propósito de construir representações não lineares em baixa dimensão.

O algoritmo foi aplicado diretamente sobre a matriz de atributos previamente limpos e padronizados, para manter o escalonamento dos dados antes da projeção que é um requisito indispensável, já que o t-SNE calcula medidas de distância euclidiana no espaço original para estruturar suas distribuições de probabilidade de similaridade.

A calibração do T-SNE foi estruturada a partir de uma grade de busca de hiperparâmetros, desenhada para confrontar diferentes topologias e apontar a configuração que entrega a maior sinergia com o critério de seleção unificado.

A ancoragem do método utilizou uma parametrização de base composta por: `random_state = 42`, inicialização baseada nas componentes do PCA, taxa de aprendizado automática, teto de 250 iterações no processo de otimização e o mapeamento das projeções nas dimensões unidimensional, bidimensional e tridimensional. A varredura principal concentrou-se no parâmetro de perplexidade.

A fixação de `random_state = 42` blinda a reprodutibilidade científica do estudo, neutralizando a volatilidade estocástica inerente ao processo de descida de gradiente do algoritmo.

Por sua vez, injetar a inicialização via PCA confere uma estrutura geométrica preliminar robusta ao algoritmo. Essa estratégia acelera a convergência e reduz o risco de o mapa colapsar em organizações aleatórias nas fases iniciais de otimização.

A escolha por limitar o processo a 250 iterações justificou-se por restrições de infraestrutura de *hardware*. Testes preliminares indicaram que janelas de otimização mais longas sob perplexidades elevadas geravam um efeito cascata no consumo de memória RAM, sem trazer ganhos expressivos na definição geométrica. O teto adotado demonstrou, assim, um excelente equilíbrio entre nitidez analítica e viabilidade computacional. A taxa de aprendizado automática completou o arranjo de base, permitindo que o algoritmo modulasse o passo da otimização dinamicamente com base na densidade local dos dados.

O núcleo da nossa grade de testes concentrou-se na perplexidade. Valores mais baixos forçam o algoritmo a focar em microrregiões isoladas, destacando estruturas locais; já valores robustos expandem esse olhar, priorizando a organização global do ecossistema de dados.

Para cobrir esse espectro de forma justa, a grade de perplexidades foi dividida em três grandes zonas (baixa, média e alta). Dentro de cada faixa, os valores foram espaçados seguindo uma progressão geométrica. Esse desenho garante uma exploração homogênea do espaço de busca, evitando o viés de concentrar os testes em clusters de valores muito

próximos.

Matematicamente, para uma janela delimitada por um piso ($p_{\min}$), um teto ($p_{\max}$) e um número (n) de pontos desejados, o (i)-ésimo termo dessa escala geométrica é extraído por:

$$p_i = p_{\min} \left(\frac{p_{\max}}{p_{\min}} \right)^{\frac{i}{n-1}}, \quad i = 0, 1, \dots, n-1. \quad (3.14)$$

A modelagem calibrou a zona baixa no intervalo de 3 a 10; a zona média entre 15 e 65; e a zona superior cobrindo de 90 a 220. Dessa dinâmica, derivou-se o seguinte vetor final de testes:

$$\text{perplexidade} \in \{3, 4, 7, 10; 15, 24, 39, 65; 90, 121, 163, 220\}. \quad (3.15)$$

Dessa forma, a busca cobriu de maneira simétrica quatro configurações de sensibilidade puramente local, quatro arranjos intermediários e quatro mapeamentos de caráter global.

Concluída a projeção de cada mapa espacial, o Modelo de Mistura Gaussiana assume o papel de avaliador, ajustando-se sobre as novas coordenadas geradas. Extraem-se, então, a AUC-PR, o MCC e a Log Loss de cada cenário para consolidar o score unificado de avaliação.

Uma vez escolhido sobre a melhor configuração, as coordenadas ótimas passam a alimentar as fases de visualização e diagnóstico quantitativo do projeto.

3.7 Aplicação do modelo GMM

O Modelo de Mistura Gaussiana entra na arquitetura deste projeto para mapear a estrutura probabilística latente dos dados, assumindo que a população de transações pode ser representada por uma sobreposição de múltiplas distribuições normais. O grande trunfo desse classificador é fornecer as chamadas responsabilidades, que podem ser entendidas como probabilidades que indicam o grau de pertencimento de cada transação a cada uma das componentes gaussianas estimadas pelo sistema.

O algoritmo foi desenvolvido através da classe `GaussianMixture` do pacote *scikit-learn*, adotando a seguinte parametrização de controle:

- `n_components = 2`
- `covariance_type = full`
- `random_state = 42`

- `n_init = 3`
- `reg_covar = 10-6`

3.7.1 Ajuste do modelo

O treinamento do GMM é processado sobre os diferentes subconjuntos de variáveis filtrados nas etapas prévias da metodologia. A otimização dos parâmetros utiliza o EM, sendo assim ao atingir a convergência, o GMM devolve os pesos de relevância de cada componente, os vetores de médias, as matrizes de covariância e as matrizes de responsabilidade de cada registro. Esse conjunto de indicadores é o que viabilizará a leitura probabilística do problema e o cálculo das métricas de eficiência do trabalho.

3.7.2 Definição do número de componentes

O arranjo geométrico do modelo é ditado pelo parâmetro `n_components`, que fixa a quantidade de distribuições normais que tentarão descrever o espaço amostral. A definição por duas componentes reflete a própria natureza binária do nosso problema, caracterizado estritamente pelo binômio transação legítima versus operação fraudulenta. O modelo cria, portanto, dois grandes polos probabilísticos no espaço de atributos, associando cada transação a um vetor duplo de probabilidades de pertencimento.

É importante ressaltar que o GMM é um algoritmo de aprendizado não supervisionado, ou seja, ele calcula suas densidades sem olhar para as etiquetas reais de fraude durante o treino. Contudo, parametrizar o modelo com duas componentes nos permite, na fase de validação, confrontar as responsabilidades estimadas com os rótulos reais do banco de dados, auditando se uma das formas gaussianas naturalmente se especializou em isolar o comportamento dos golpes financeiros.

3.7.3 Tipo de matriz de covariância

O comportamento geométrico das curvas de densidade é controlado pelo parâmetro `covariance_type`. Ao optar pela configuração `full`, permite-se que cada uma das componentes gaussianas estime sua própria matriz de covariância de forma livre e independente.

Esse voto de flexibilidade é crucial porque garante que o modelo capture não apenas a dispersão isolada de cada atributo, mas também as correlações e dependências cruzadas entre as variáveis dentro de cada agrupamento.

3.7.4 Inicializações e reprodutibilidade

O hiperparâmetro `random_state` recebe uma semente fixa para neutralizar a sensibilidade do algoritmo em relação ao ponto de partida matemático. Como a convergência do algoritmo EM depende crucialmente de onde ele inicia sua busca, travar a semente garante que o ponto de partida seja idêntico em qualquer máquina, assegurando a consistência dos resultados.

Somado a isso, incorporou-se o parâmetro `n_init = 3`, que força o sistema a rodar o processo completo de otimização a partir de três pontos de partida totalmente distintos. Ao final das iterações, o algoritmo descarta as soluções de menor eficiência e retém apenas o ajuste que alcançou o maior limite inferior da log-verossimilhança.

3.7.5 Regularização da matriz de covariância

Fechando os parâmetros de controle, o argumento `reg_covar` atua como um mecanismo de segurança numérica, injetando uma constante infinitesimal positiva (10^{-6}) diretamente na diagonal principal das matrizes de covariância calculadas.

Essa estratégia de regularização é vital para evitar problemas numéricos.

3.7.6 Definição do Limiar de Decisão

Como o GMM fornece responsabilidades que podem ser interpretadas como probabilidades de pertencimento às componentes, é necessário definir um limiar de decisão para transformar essas probabilidades em classes preditas. Seja p_i a responsabilidade associada à componente interpretada como classe positiva. Nesse caso, a classificação binária pode ser definida por:

$$\hat{y}_i(t) = \begin{cases} 1, & \text{se } p_i \geq t, \\ 0, & \text{se } p_i < t. \end{cases} \quad (3.16)$$

em que (t) representa o limiar de decisão.

Neste trabalho, serão considerados dois tipos de limiar, também chamados de ponto de corte ou, em inglês, *threshold*. O primeiro é o limiar fixo de 0,50, utilizado como referência inicial. Esse valor representa uma regra simples de decisão, na qual observações com probabilidade estimada maior ou igual a (50%) são classificadas como pertencentes à classe positiva.

O segundo limiar será definido de forma orientada ao desempenho, por meio da maximização do Coeficiente de Correlação de Matthews. Para isso, serão avaliados diferentes valores de limiar t . Em cada caso, serão obtidas as classes preditas e calculado o respectivo (MCC t). Assim, o limiar ótimo será definido como:

$$t^* = \arg \max_t MCC(t). \quad (3.17)$$

Dessa forma, o valor de MCC utilizado na avaliação do modelo corresponderá ao melhor desempenho obtido entre os limiares testados:

$$MCC_{\max} = MCC(t^*). \quad (3.18)$$

A comparação entre o limiar fixo de 0,50 e o limiar ótimo baseado no MCC permitirá avaliar o impacto da escolha do ponto de corte sobre a classificação final. Essa análise é especialmente relevante em razão do desbalanceamento entre as classes, já que um limiar fixo pode não ser o mais adequado para equilibrar a identificação da classe minoritária e o controle de falsos positivos.

3.8 Modelos Comparativos

3.8.1 Ideia Central

Além do modelo principal baseado em Mistura Gaussiana, serão considerados modelos comparativos com o objetivo de fornecer referências adicionais para a interpretação dos resultados. Esses modelos não constituem o foco central do trabalho, mas funcionam como apoio metodológico, em outras palavras, eles ajudam a verificar se os padrões identificados pelo GMM permanecem coerentes quando observados por outras abordagens.

A utilização de modelos comparativos permite analisar o desempenho do GMM sob diferentes perspectivas. Enquanto o GMM é um modelo probabilístico não supervisionado, baseado em mistura de distribuições gaussianas, os modelos auxiliares apresentam características distintas. Essa comparação amplia a leitura dos resultados e permite verificar se as variáveis e representações selecionadas também apresentam desempenho consistente fora do modelo principal.

Nesta etapa, serão considerados a Regressão Logística e um modelo baseado em Estimativa de Densidade por Kernel. A Regressão Logística será utilizada como referência probabilística, paramétrica e supervisionada. Já o modelo baseado em KDE será utilizado como uma segunda abordagem probabilística, não paramétrica e não supervisionada. Ambos serão avaliados por meio das mesmas métricas quantitativas utilizadas nas demais etapas, permitindo uma comparação padronizada dos resultados.

3.9 Síntese do Fluxo Metodológico

3.9.1 Fluxo Metodológico

A metodologia proposta foi estruturada em etapas sequenciais, de modo a organizar o processo de preparação dos dados, seleção de variáveis, redução de dimensionalidade, modelagem e avaliação dos resultados.

Inicialmente, foi realizada a obtenção da base de dados. Em seguida, aplicou-se o processo de ETL, no qual foram feitas a leitura do arquivo original, a renomeação das variáveis, a verificação de inconsistências, a remoção de duplicatas e o tratamento de possíveis valores ausentes.

Depois dessa etapa, foi conduzida a análise da estrutura da base, incluindo a verificação dos tipos das variáveis, da quantidade de valores não nulos, dos valores únicos e da memória ocupada por cada coluna. Na sequência, as variáveis explicativas foram padronizadas, colocando-as em uma escala comum para a aplicação dos modelos e das técnicas de redução de dimensionalidade.

A base completa tratada foi então utilizada para a análise exploratória e para a construção das visualizações iniciais. Essa etapa teve como objetivo compreender a distribuição das variáveis, o desbalanceamento entre as classes e os padrões visuais presentes nos dados.

Para a etapa de modelagem final, será adotada uma divisão por *holdout* estratificado, preservando a proporção entre transações fraudulentas e não fraudulentas nos subconjuntos definidos. Esse cuidado busca tornar a avaliação mais consistente, especialmente por se tratar de uma base desbalanceada.

Por fim, os resultados obtidos pelo GMM serão comparados com modelos auxiliares, como a Regressão Logística e o modelo baseado em KDE. A avaliação será realizada por meio das métricas quantitativas e das análises gráficas definidas ao longo da metodologia. Dessa forma, o fluxo metodológico integra preparação dos dados, seleção de variáveis, visualização, modelagem probabilística e comparação de desempenho de maneira organizada e reprodutível.

4 Desenvolvimento

5 Conclusao